Introdução à Teoria de Redes

Alberto Saa
UNICAMP
Versão 2.0

27 de setembro de 2025

Sumário

1 Grafos **3**

1.1 Definições básicas . . . 3

1.1.1 Equivalência e simetria de grafos . . . 6

1.1.2 Grafos de linha . . . 10

1.1.3 Exercícios . . . 12

1.2 Passeios, caminhos e ciclos . . . 13

1.2.1 Conectividade . . . 15

1.2.2 Grafos bipartidos . . . 16

1.2.3 Grafos como espaços métricos . . . 18

1.2.4 Exercícios . . . 20

1.3 Teoria espectral de grafos . . . 20

1.3.1 Matriz de adjacência . . . 21

1.3.2 Exercícios . . . 24

1.3.3 Matriz Laplaciana . . . 24

1.3.4 Exercícios . . . 27

1.3.5 Matrizes normalizadas . . . 28

1.3.6 Espectro e simetrias . . . 29

1.4 Grafos mais gerais . . . 30

1.4.1 Grafos orientados . . . 33

1.4.2 Grafos ponderados . . . 36

1.5 Alguns exemplos e aplicações . . . 37

1.5.1 Espectro de alguns grafos notáveis . . . 37

Grafo completo . . . 37

Grafo estrela . . . 38

Grafo ciclo . . . 41

Grafo caminho . . . 43

1.5.2 Grafos regulares: algumas propriedades métricas . . . 46

1.5.3 Passeios Eulerianos e caminhos Hamiltonianos . . . 50

1.5.4 Problemas 2SAT e grafos orientados . . . 53

Grafo de implicações . . . 54

Ordem topológica em grafos orientados . . . 55

1.5.5 Medidas de centralidade . . . 57

1.5.6 Clusters e transitividade . . . 57

1.5.7 Conectividade algébrica e o vetor de Fiedler 57
1.5.8 Passeios aleatórios em grafos 57
Exercícios 60

2 Grafos aleatórios **62**
2.1 Grafos de Erdős-Rényi 63
2.1.1 Algumas propriedades dos grafos de Erdős-Rényi . . . 66
Matriz de adjacência 67
Triângulos em $G(n, p)$ 69
Conectividade de $G(n, p)$ 69
Distância típica em $G(n, p)$ 71
O paradoxo das amizades 73
2.2 Grafos de Barabasi-Albert 74
2.2.1 Distâncias em redes livres de escala 78
2.3 Exercícios 81

Capítulo 1

Grafos

1.1 Definições básicas

Nossa primeira definição será a de um grafo não orientado (também chamado não direcionado ou não dirigido na literatura matemática em língua portuguesa, ou *undirected graph* em inglês). Por simplicidade, vamos denominar os grafos não orientados apenas por grafos ou, ainda de maneira mais geral, também por redes (*networks*), como é mais comum na literatura física.

Definição 1 *Um grafo $G = (V, E)$ é uma estrutura composta por dois conjuntos:*

i) um conjunto $V = \{v_1, v_2, \ldots, v_n\}$ de elementos chamados vértices (ou nós, ou sítios);

ii) um conjunto $E = \{e_1, e_2, \ldots, e_k\} \subset V \times V$ de elementos denominados arestas (ligações, edges, links), sendo cada aresta $e_j(v_i, v_k)$ um par não ordenado de vértices distintos $v_i, v_k \in V$.

É comum dizermos que uma aresta conecta dois vértices. Além disso, dois vértices são ditos adjacentes sempre que houver uma aresta que os conecte. Duas arestas que se encontra em um vértice são ditas incidentes. Por ora, é claro que estamos excluindo a possibilidade de uma aresta conectar um vértice a ele mesmo, o que corresponde as chamadas auto-ligações ou laços (*loops*). Também admitiremos que um dado par de vértices pode acomodar apenas uma aresta. Grafos como os da definição 1, sem auto-ligações nem mais de uma aresta entre dois vértices, são chamados também de grafos simples. Mais adiante, discutiremos outras estruturas mais gerais que permitem auto-ligações e múltiplas arestas com outros atributos entre vértices.

Denominaremos os conjuntos de vértices e de arestas de um grafo G, respectivamente, por $V(G)$ e $E(G)$. A ordem de um grafo G corresponde ao seu número de vértices, e será denotada por $|G|$ ou $|V(G)|$. O número de

arestas de um grafo G sempre será denotado por $|E(G)|$ ou simplesmente $|E|$ se o contexto permitir. Há diversas maneiras para se representar um grafo. As representações gráficas são sempre muito atraentes para grafos não muito grandes. Vejam, por exemplo, o grafo representado na Fig. 1.1. Não é difícil

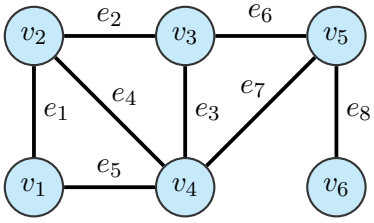

arestas	vértices
e_1	$v_1 \leftrightarrow v_2$
e_2	$v_2 \leftrightarrow v_3$
e_3	$v_3 \leftrightarrow v_4$
e_4	$v_2 \leftrightarrow v_4$
e_5	$v_1 \leftrightarrow v_4$
e_6	$v_3 \leftrightarrow v_5$
e_7	$v_4 \leftrightarrow v_5$
e_8	$v_5 \leftrightarrow v_6$

Figura 1.1: Exemplo de grafo com 6 vértices e 8 arestas.

perceber que ele corresponde aos conjuntos da nossa definição 1 com $|G| = 6$ e $|E(G)| = 8$, *i.e.*, um grafo de 6 vértices e 8 arestas, estando as arestas distribuídas como mostrado na tabela da figura. Há uma vasta e interessante literatura sobre o problema das representações gráficas de um grafo, mas não é este o nosso interesse primordial. Aos que se interessam e pretendem se aprofundar no problema da representação gráfica plana de grafos, sugere-se começar por dois célebres teoremas: de Fáry e de Kuratowski, e a relação desta questão com o famoso problema das 4 cores[1].

A representação matricial de um grafo será muito mais importante para os nossos propósitos. Podemos representar de maneira bastante condensada todas as informações pertinentes de um grafo utilizando a chamada matriz de adjacência: uma matriz A cujas entradas $[a_{ij}]$ são simplesmente

$$a_{ij} = \begin{cases} 1, & \text{se houver uma aresta } v_i \leftrightarrow v_j, \\ 0, & \text{se não houver.} \end{cases} \tag{1.1}$$

Por exemplo, a matriz de adjacência para o grafo da Fig. 1.1 será

$$A = \begin{pmatrix} 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 0 & 1 & 0 \end{pmatrix}. \tag{1.2}$$

Como vemos, trata-se, por construção, de uma matriz simétrica de entradas 0 ou 1, de diagonal nula. Uma outra matriz relevante é a chamada matriz

[1] Ver, por exemplo, J.A. Bondy e U.S.R. Murty, *Graph Theory*, Springer (2008).

de incidência M, uma matriz com $n = |G|$ linhas e $k = |E(G)|$ colunas cujas entradas são dadas por

$$m_{ij} = \begin{cases} 1, & \text{se a aresta } e_j \text{ contiver o vértice } v_i, \\ 0, & \text{caso contrário.} \end{cases} \tag{1.3}$$

Cada linha de M corresponde a um vértice de G, enquanto suas colunas estão associadas às arestas. Como ilustração, notem que a matriz de incidência para o grafo da Fig. 1.1 é

$$M = \begin{pmatrix} 1 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}. \tag{1.4}$$

Notem também que a soma das colunas (ou das linhas) da matriz de adjacência A nos dá o número de arestas de cada vértice. Chamamos esta importante quantidade de grau (*degree*) d_i do vértice v_i

$$d_i = \sum_{j=1}^{n} a_{ij} = \sum_{j=1}^{n} a_{ji}. \tag{1.5}$$

A soma de linhas e colunas da matriz de incidência M também nos pode fornecer informações interessantes sobre o grafo em questão. Por exemplo, somando suas colunas, temos

$$d_i = \sum_{j=1}^{k} m_{ij}. \tag{1.6}$$

Ao mesmo tempo, somando-se suas linhas, obtemos para todas colunas $\sum_{i=1}^{n} m_{ij} = 2$, que obviamente significa que cada aresta contém sempre 2 vértices. Ora, somando-se todas as entradas da matriz de incidência, temos a nossa primeira identidade notável para grafos como os da definição 1:

$$\boxed{\sum_{i=1}^{n} d_i = 2|E(G)|. \qquad (1.7)}$$

Vejam que, em particular, esta relação implica uma curiosa propriedade: o número de vértices com grau impar (denominados também vértices ímpares) de um grafo é sempre par. Este resultado é conhecido como lema do aperto de mão (*handshaking*), muito provavelmente em referência ao clássico problema do número de apertos de mão numa festa, ver os exercícios ao final desta seção.

A matriz de incidência M guarda uma relação simples com a matriz de adjacência A. Para revelá-la, vamos considerar as componentes $\left[m_{ij}^{(2)}\right]$ do produto MM^t

$$m_{ij}^{(2)} = \sum_{k=1}^{|E(G)|} m_{ik} m_{jk}. \tag{1.8}$$

Da definição da matriz de incidência, vemos que, para $i \neq j$, $m_{ij}^{(2)}$ será 1 se houver uma aresta conectando os vértices v_i e v_j, ou 0 zero não houver. Por outro lado, se $i = j$, teremos $m_{ii}^{(2)} = d_i$. Assim, temos a relação

$$MM^t = D + A, \tag{1.9}$$

sendo D a matriz diagonal contendo os graus dos vértices,

$$D = \mathrm{diag}(d_1, d_2, \ldots, d_n), \tag{1.10}$$

a qual denominamos simplesmente de matriz de graus do grafo. Uma outra matriz notável para grafos é a denominada matriz Laplaciana L, definida como

$$L = D - A. \tag{1.11}$$

Para o nosso exemplo da Fig. 1.1, a matriz Laplaciana é

$$L = \begin{pmatrix} 2 & -1 & 0 & -1 & 0 & 0 \\ -1 & 3 & -1 & -1 & 0 & 0 \\ 0 & -1 & 3 & -1 & -1 & 0 \\ -1 & -1 & -1 & 4 & -1 & 0 \\ 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & 0 & -1 & 1 \end{pmatrix}. \tag{1.12}$$

Claramente, L também é uma matriz simétrica, com a diagonal dada pelos graus dos vértices. A matriz $D + A$ de (1.9) também surge em algumas aplicações. É a chamada matriz Laplaciana sem sinal (*signless Laplacian*).

1.1.1 Equivalência e simetria de grafos

Dadas duas representações diferentes de um grafo, sejam elas gráficas ou matriciais, podemos determinar se elas realmente correspondem a grafos diferentes? Quando dois grafos podem ser considerados realmente diferentes? Estas perguntas supõem a existência de uma noção de equivalência entre grafos, cuja definição matemática precisa envolve o conceito de isomorfismo.

Definição 2 *Dois grafos G e H são ditos isomorfos se houver uma bijeção*

$$f : V(G) \to V(H)$$

tal que dois vértices quaisquer $v_i, v_j \in V(G)$ são adjacentes se e somente se $f(v_i)$ e $f(v_j) \in V(H)$ também o forem.

Vejam um exemplo de dois grafos isomorfos e o respectivo isomorfismo na Fig. 1.2. Nossa definição de isomorfismo corresponde a uma permutação

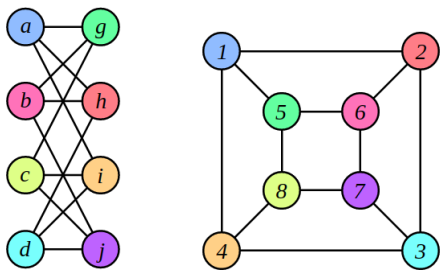

Isomorfismo
$f(a) = 1$
$f(b) = 6$
$f(c) = 8$
$f(d) = 3$
$f(g) = 5$
$f(h) = 2$
$f(i) = 4$
$f(j) = 7$

Figura 1.2: Exemplo de isomorfismo entre grafos de ordem 8.

de vértices que preserva a estrutura das arestas. Estes isomorfismos podem ser "visualizados" na representação gráfica como "deslocamentos" dos vértices mantendo-se suas arestas conectadas, as quais se comportam como se fossem ligações "elásticas". Assim, podemos "deformar" o grafo da esquerda da Fig. 1.2 e transformá-lo no grafo da direita movendo os vértices e "arrastando" suas respectivas arestas. Uma vez "deformado" o grafo da esquerda na forma do da direita, a operação de permutação é apenas a renomeação dos vértices, o que obviamente não altera em nada da estrutura do grafo. Assim, pode-se dizer que dois grafos isomorfos tem exatamente a mesma estrutura, apenas diferem nos nomes que atribuímos a seus vértices e arestas.

Para nossos propósitos, será sempre mais conveniente entender o isomorfismo de grafos a partir de suas representações matriciais. Considerem a matriz de adjacência do grafo da esquerda da Fig. 1.2, supondo os vértices ordenados alfabeticamente. As permutações da tabela implicam em permutações de linhas e colunas da matriz de adjacência A, cujo resultado será a matriz de adjacência do grafo da direita. Vemos que deve ser possível reformular a definição 2 em termos das matrizes de adjacência. Este é o conteúdo do seguinte teorema, cuja prova é simples.

Teorema 1 *Dois grafos G e H, com matrizes de adjacência A_G e A_H, são isomorfos se e somente se houver uma matriz de permutação P tal que*

$$P^t A_G P = A_H.$$

A prova do teorema vem da observação de que a permutação P leva os vértices v_i e v_j de $V(G)$ nos vértices v'_k e v'_ℓ de $V(H)$ e, segundo o teorema, a entrada a^G_{ij} de A_G na entrada $a^H_{k\ell}$ de A_H, de onde segue diretamente que somente haverá uma aresta entre v'_k e v'_ℓ de $V(H)$ se houver uma entre v_i e v_j de $V(G)$, e vice-versa.

O conteúdo do teorema 1 tem algumas implicações interessantes. Primeiro, notem que, se uma certa permutação P é dada, é bastante fácil verificar se ela corresponde a um isomorfismo entre os grafos G e H, basta calcular $P^t A_G P$ e comparar com A_H. Ao mesmo tempo, dada duas matrizes A_G e A_H, é computacionalmente muito custoso determinar se há permutações tais que $P^t A_G P = A_H$, pois essencialmente há $n!$ permutações para serem testadas. Esta situação é típica da classe de problemas chamada NP.[2] Normalmente, verificamos se dois grafos podem ser isomorfos examinando suas propriedades invariantes, *i.e.*, as propriedades que devem ser preservadas por isomorfismos. Por exemplo, é claro que se G e H são isomorfos, devemos ter $|G| = |H|$ e $|E(G)| = |E(H)|$. Os graus dos vértices também devem ser preservado, *i.e.* $d(v_i) = d(f(v_i))$. De maneira mais interessante, o teorema 1 garante também que o espectro das matrizes A_G e A_H devem ser idênticos, e o mesmo valerá para a matriz Laplaciana. Na prática, é muito comum demonstrarmos que dois grafos não são isomorfos mostrando que eles tem diferentes quantidades invariantes.

A noção de isomorfismo nos permite introduzir a ideia de equivalência de grafos. Grafos isomorfos são equivalentes no sentido de que suas estruturas de conexões das arestas e várias outras propriedades derivadas serão essencialmente as mesmas. Se aplicarmos a noção de isomorfismo ao caso em que $G = H$, estaremos introduzindo também a ideia de simetria em grafos. Um isomorfismo com $G = H$ é chamado automorfismo, e o teorema 1 nesse caso é enunciado como abaixo.

Teorema 2 *Uma permutação P de vértices de um grafo G é um automorfismo (ou simetria) de G se e somente se preservar a matriz de adjacência A de G,*

$$P^t A P = A.$$

O problema dos automorfismos de um grafo tem a mesma propriedade computacional do caso dos isomorfismos: é fácil verificar se uma dada permutação é um automorfismo, mas pode ser computacionalmente muito custoso

[2] Ver mais aqui.

encontrar todos os automorfismos de um grafo G dado. Os automorfismos de um grafo formam um grupo, o chamado grupo de automorfismos. Podemos ilustrar estes conceitos com alguns exemplos explícitos simples. Considerem o grafo (a) da Fig. 1.3. Sua matriz de adjacência é

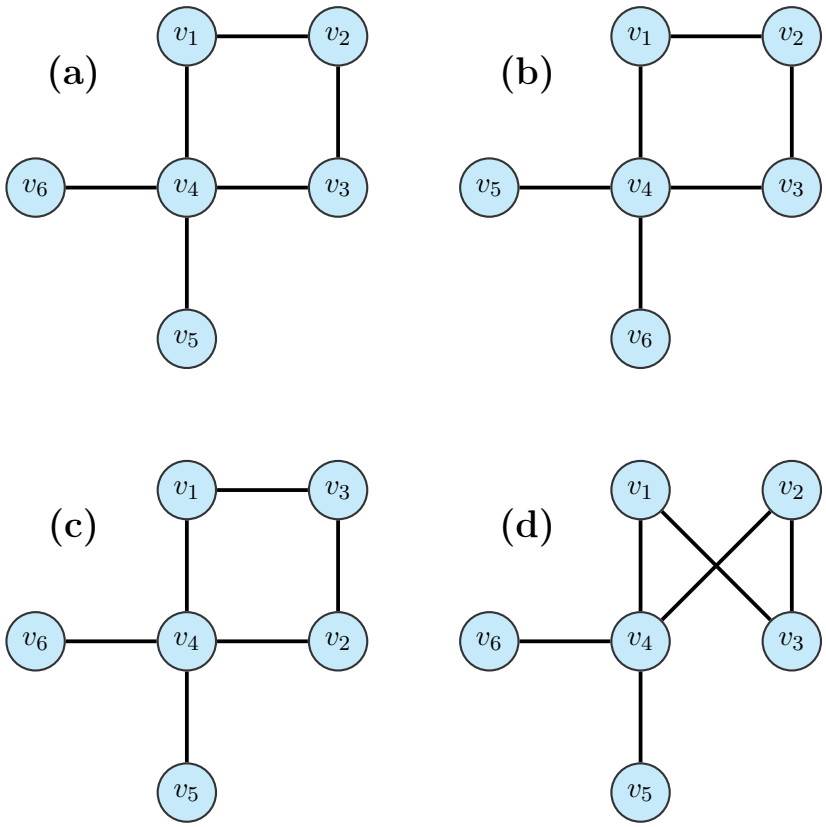

Figura 1.3: Exemplos de isomorfismo (equivalência) e automorfismo (simetria) de grafos.

$$A = \begin{pmatrix} 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}. \tag{1.13}$$

Considerem agora a permutação dos vértices $(1, 2, 3, 4, 5, 6) \to (1, 2, 3, 4, 6, 5)$, cuja matriz de permutação associada é P_{56}. Notem, primeiro, que

$$P_{56}^t A P_{56} = A, \tag{1.14}$$

de onde temos que a permutação $(5,6) \to (6,5)$ é um automorfismo, ou simetria, do grafo (a) da figura. O grafo (b) corresponde à "deformação" do grafo (a) na qual a posição dos vértices v_5 e v_6 foram trocadas, preservando-se ("arrastando") as arestas correspondentes. É evidente a noção de simetria relacionada ao automorfismo: os grafos (a) e (b) são mais do que simplesmente equivalentes, são *idênticos*. Por outro lado, considerem agora a permutação $(1,2,3,4,5,6) \to (1,3,2,4,5,6)$, cuja matriz de permutação associada é P_{23}. Notem que neste caso

$$P_{23}^t A P_{23} = \begin{pmatrix} 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix} \neq A \tag{1.15}$$

Obviamente não se trata de um automorfismo, mas de um isomorfismo, especificamente entre o grafo (a) e o grafo (c) da Fig. 1.3, que não são idênticos, mas são equivalentes. O grafo (d) corresponde a deformação do grafo (c) que o deixa com os vértices nas mesmas posições do grafo (a). É evidente que, apesar de equivalentes, (a) e (c) não são idênticos. Outro automorfismo do grafo (a) da figura é a permutação $(1,2,3,4,5,6) \to (3,2,1,4,5,6)$. É claro que esta permutação, assim como a que leva ao grafo (b), são instâncias da evidente simetria de reflexão que o grafo exibe em relação ao eixo que passa pelos vértices 2 e 4.

1.1.2 Grafos de linha

Dado um grafo $G = (V, E)$ define-se o grafo de linha L_G associado a G como sendo o grafo com vértices correspondentes às arestas E de G. Além disso, dois vértices de L_G serão adjacentes se, e somente se, as correspondentes arestas E de G são incidentes, *i.e.*, compartilharem um vértice. A Fig. 1.4 mostra o grafo de linha associado ao grafo da Fig 1.1. Os vértices foram mantidos mais ou menos na mesma posição das arestas do grafo original para melhor visualização. Como podemos ver, trata-se de um grafo de 8 vértices (o grafo da Fig 1.1 tem 8 arestas) e 16 arestas. Não é difícil determinar o número de arestas de L_G. Este é o conteúdo do seguinte teorema.

Teorema 3 *Seja G um grafo com n vértices e ℓ arestas. Seu gráfico de linha associado L_G terá ℓ vértices e*

$$q = \frac{1}{2} \operatorname{Tr} D^2 - \ell$$

arestas, sendo D a matriz de graus de G.

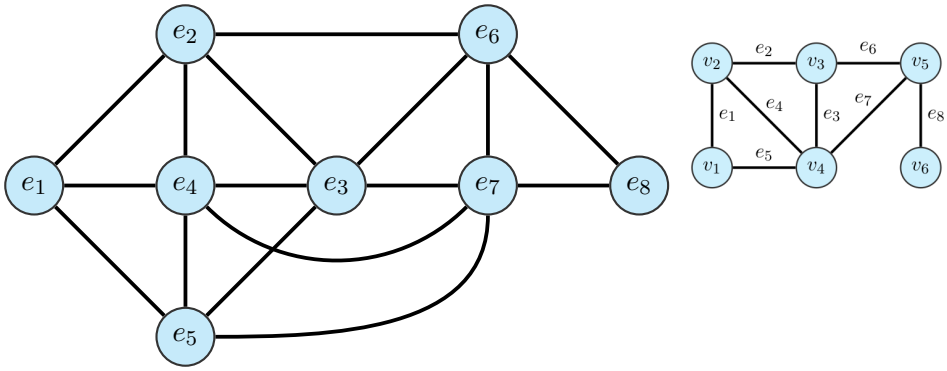

Figura 1.4: Grafo de linha associado ao grafo da Fig 1.1, reproduzido aqui no detalhe a direita.

A prova do teorema é simples. O número de vértices de L_G é ℓ por construção. Para determinar o número de arestas q de L_G, notem que um vértice $v_i \in G$ com grau d_i é o responsável por criar $d_i(d_i-1)/2$ arestas em L_G. Somando-se sobre todos os vértices de G, teremos

$$q = \frac{1}{2}\sum_{i=1}^{n}(d_i^2 - di) = \left(\frac{1}{2}\sum_{i=1}^{n} d_i^2\right) - \ell, \tag{1.16}$$

estabelecendo o teorema. O teorema abaixo também é útil para grafos linha.

Teorema 4 *Seja G um grafo com matriz de incidência M. A matriz de adjacência A de seu grafo de linha associado é*

$$A = M^t M - 2I.$$

Para provar, vamos considerar as componentes $\left[\tilde{m}_{ij}^{(2)}\right]$ do produto $M^t M$, de maneira semelhante com o que já fizemos em (1.8),

$$\tilde{m}_{ij}^{(2)} = \sum_{k=1}^{|V(G)|} m_{ki} m_{kj}. \tag{1.17}$$

Comecemos com o caso $i = j$. Teremos sempre $\tilde{m}_{ii}^{(2)} = 2$, pois esta é a soma ao longo de colunas da matriz de incidência. Para $i \neq j$, vemos que $m_{ij}^{(2)} = 0$ se as arestas i e j de G não são incidentes e $m_{ij}^{(2)} = 1$ caso sejam incidentes. Porém, esta é exatamente a relação que define as arestas do grafo de linha associado a G, de onde o teorema segue diretamente.

1.1.3 Exercícios

Apertos de mão Num passado distante, era comum que pessoas se reunissem em atividades chamadas "festas" e que se cumprimentassem com apertos de mão. Em festas normais, que são as que trataremos aqui, ninguém se auto-cumprimenta e os apertos de mão sempre se dão entre apenas duas pessoas.

1. Supondo-se que duas pessoas se cumprimentem uma única vez numa festa, determine o número máximo de apertos de mão que podem ocorrer numa festa com N pessoas.
2. Suponha que numa certa festa com N participantes, o i-ésimo participante tenha apertado m_i mãos. Mostre que o número de participantes com m_i impar necessariamente é par.
3. Considerem agora o número T de possíveis configurações de apertos de mão simultâneos que podem acontecer durante a festa. Para facilitar, vamos chamar de t_k o número de possíveis configurações de participantes da festa com k apertos de mão ocorrendo simultaneamente. Podemos considerar $t_0 = 1$, *i.e.*, há uma única maneira de ninguém estar se cumprimentando. O número que procuramos é
$$T = \sum_k t_k.$$
Determine-o. Basta obter a relação de recorrência, mas sua solução geral não é difícil de ser obtida. Este número é também conhecido como "número de telefones" e os apertos de mão neste contexto são também chamados de emparelhamentos (*matching*) do grafo. Dica: resolva explicitamente, na representação gráfica, o caso com $N = 4$. Você deverá obter $T = 10$.
4. Considere o grafo associado ao item 1, situação na qual o número máximo possível de apertos de mão ocorre. O que você pode dizer sobre as simetrias desse grafo?

Grafos regulares Um grafo é dito regular se todos seus vértices tiverem o mesmo grau, que chamamos de grau do grafo. Construa graficamente os menores grafos (menor número de vértices) regulares possíveis de grau 1, 2, 3 e 4. Mostre que se um grafo com n vértices é regular com grau k, então necessariamente nk será par, com $n \geq k + 1$.

Gênio Indomável Prestem atenção à figura abaixo.

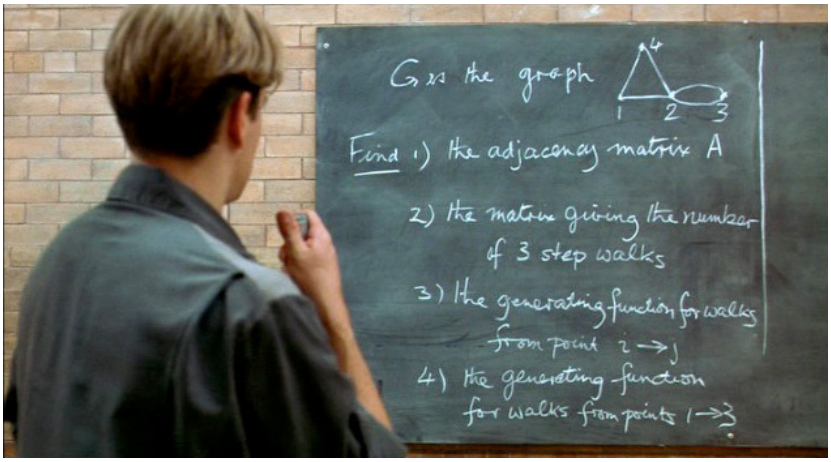

Trata-se de um fotograma do filme *Good Will Hunter* (Gênio Indomável), no qual o jovem Will, um faxineiro que na imagem segura uma vassoura, prova sua genialidade resolvendo o problema proposto no quadro como atividade da disciplina do Prof. Lambeau, grande eminência no filme em teoria de grafos. Vocês terão que trabalhar um pouco mais que o jovem Will.... ☺. Por agora, olhem apenas o item 1. Como você o acomodaria na discussão desta seção? Você pode propor matrizes de adjacência e de incidência para esse grafo?

1.2 Passeios, caminhos e ciclos

Chamaremos de passeio em um grafo uma sequência de vértices conectados por arestas. Se as arestas são entendidas como possíveis passos que podem ser dados entre os vértices, o nome passeio é bastante sugestivo para a sequência. Um passeio é dito um caminho se todos os vértices, com as únicas possíveis exceções do primeiro e do último, forem diferentes. Um ciclo é um caminho no qual os vértices iniciais e finais coincidem. Um grafo sem nenhum ciclo é chamado de árvore. O comprimento de passeios, caminhos e ciclos será sempre contado em "passos" (*steps*), sendo que cada passo corresponde a um deslocamento de um vértice a outro ao longo de uma aresta. Estas são as primeiras definições não universalmente empregadas que encontramos, e não serão as únicas. Portanto, para que não fique nenhuma dúvida, muitas vezes repetiremos o que queremos dizer, como "caminho sem repetição", "caminho fechado", etc. Caminhos, passeios e ciclos aparecem naturalmente na interpretação da matriz adjacência e suas potências. Analisemos, por exemplo, as componentes da matriz $A^2 = \left[a_{ij}^{(2)}\right]$ de um grafo. Notem, inicialmente, que

$$a_{ij}^{(2)} = \sum_{k=1}^{n} a_{ik}a_{kj}. \tag{1.18}$$

Os termos no somatório serão sempre 0 ou 1. Serão 1 se, e somente se, houver simultaneamente uma aresta $v_i \leftrightarrow v_k$ e uma aresta $v_j \leftrightarrow v_k$. Em palavras, a entrada (i, j) do quadrado da matriz de adjacência, para $i \neq j$, corresponde ao número de caminhos de 2 passos conectando os vértices v_i e v_j, de onde inferimos uma interpretação bastante simples para a matriz A^2. Em particular, é fácil mostrar que

$$\operatorname{Tr} A^2 = \sum_{k=1}^{n} d_k = 2|E(G)| \tag{1.19}$$

Notem que a própria matriz de adjacência pode ser interpretada de maneira semelhante: uma entrada não zero implica na existência de um caminho de um único passo entre os vértices correspondentes. Podemos facilmente estender o argumento para potências mais altas. Por exemplo, as componentes da matriz $A^3 = \left[a_{ij}^{(3)}\right]$ serão tais que

$$a_{ij}^{(3)} = \sum_{k=1}^{n} \sum_{\ell=1}^{n} a_{ik} a_{k\ell} a_{\ell j} \tag{1.20}$$

cuja interpretação é semelhante ao caso anterior: as entradas (i, j) da matriz A^3 correspondem ao número de passeios de 3 passos conectando os vértices v_i e v_j. Notem a crucial diferença: aqui falamos de passeios, não de caminhos, como no caso anterior. Um exemplo pode ajudar a ilustrar o que ocorre. Considerem novamente o grafo da Fig. 1.1, para o qual a matriz de adjacência é dada por (1.2). Teremos para esse caso

$$A^3 = \begin{pmatrix} 2 & 5 & 3 & 6 & 3 & 1 \\ 5 & 4 & 7 & 7 & 3 & 2 \\ 3 & 7 & 4 & 7 & 6 & 1 \\ 6 & 7 & 7 & 6 & 7 & 1 \\ 3 & 3 & 6 & 7 & 2 & 3 \\ 1 & 2 & 1 & 1 & 3 & 0 \end{pmatrix} \tag{1.21}$$

Como $a_{13}^{(3)} = 3$, sabemos que há 3 passeios de 3 passos conectando os vértices v_1 e v_3. Uma inspeção simples na figura revela quem são: $\{v_1 \to v_2 \to v_4 \to v_3\}$, $\{v_1 \to v_4 \to v_2 \to v_3\}$ e $\{v_1 \to v_4 \to v_5 \to v_3\}$. Nesse caso em particular, são três caminhos. Considerem agora o caso dos vértices v_1 e v_2. Do gráfico, é fácil perceber que há apenas um único caminho de 3 passos que conecta esses dois vértices: $\{v_1 \to v_4 \to v_3 \to v_2\}$. Porém, como $a_{12}^{(3)} = 5$, deve haver mais 4 passeios conectando esses vértices. E há. São eles: $\{v_1 \to v_2 \to v_1 \to v_2\}$, $\{v_1 \to v_4 \to v_1 \to v_2\}$, $\{v_1 \to v_2 \to v_3 \to v_2\}$ e $\{v_1 \to v_2 \to v_4 \to v_2\}$. É fácil ver que estes passeios são "remanescentes" de caminhos com número menor de passos. Por exemplo, o primeiro passeio é, na prática, o caminho $\{v_1 \to v_2\}$ repetido com um passo "ao contrário".

De fato, pode-se formular um teorema cuja prova é bastante simples: um passeio de k passos que não é um caminho, sempre engloba um caminho de $\ell < k$ passos. Este pequeno teorema tem um corolário muito útil. Se para algum k $a_{ij}^{(k)} \neq 0$ implicar na existência de passeios que não são caminhos entre os vértices v_i e v_j, então necessariamente há um $\ell < k$ para o qual $a_{ij}^{(\ell)} \neq 0$. Retornaremos a este ponto a seguir.

Os elementos da diagonal da matriz A^3 tem um significado interessante. Por construção, correspondem ao número de ciclos de três passos. Ora, um ciclo de três passos nada mais é do que um triângulo, a menos da orientação do ciclo. Assim, $a_{ii}^{(3)} = t_i$, sendo t_i o número de ciclos de três passos que contém o vértice v_i. O traço de A^3 será o número total de ciclos de três passos que o grafo possui. Para relacionar com o número de triângulos, basta lembrar que a permutação dos três vértices que compõe o ciclo dá origem ao mesmo triângulo. Há 6 possíveis permutações dessas, e portanto temos finalmente

$$\operatorname{Tr} A^3 = 6N_\Delta(G), \tag{1.22}$$

onde $N_\Delta(G)$ sempre denotará o número de triângulos no grafo G.

1.2.1 Conectividade

Um grafo é dito conexo se sempre houver um caminho conectando quaisquer pares de seus vértices. Denomina-se componente (ou parte) conexa de um grafo G qualquer subconjunto maximal[3] conexo de G. O grafo da Fig. 1.5, por exemplo, é claramente não conexo. Mais que isso, é evidente que ele se

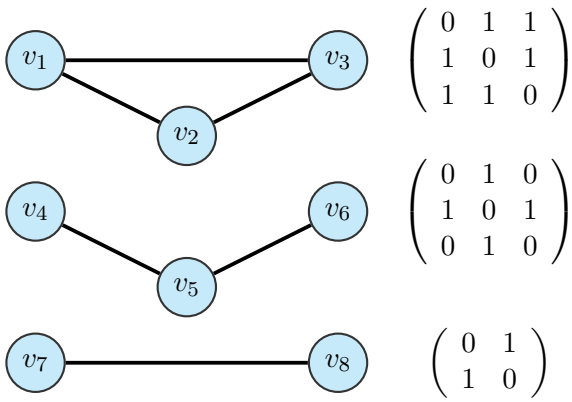

Figura 1.5: Grafo desconexo com três componentes conexas, com as respectivas matrizes de adjacência de cada componente.

constitui de três conjuntos de vértices conexos, *i.e.*, de três partes conexas.

[3]No sentido de ter o maior número possível de vértices

Suas matrizes de adjacência e Laplaciana serão, respectivamente,

$$A = \left(\begin{array}{ccc|ccc|cc} 0 & 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 & 0 \\ \hline 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 0 & 0 & 0 \\ \hline 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 1 & 0 \end{array}\right) \tag{1.23}$$

e

$$L = \left(\begin{array}{rrr|rrr|rr} 2 & -1 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 & 0 & 0 \\ -1 & -1 & 2 & 0 & 0 & 0 & 0 & 0 \\ \hline 0 & 0 & 0 & 1 & -1 & 0 & 0 & 0 \\ 0 & 0 & 0 & -1 & 2 & -1 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1 & 1 & 0 & 0 \\ \hline 0 & 0 & 0 & 0 & 0 & 0 & 1 & -1 \\ 0 & 0 & 0 & 0 & 0 & 0 & -1 & 1 \end{array}\right) \tag{1.24}$$

É claro que as matrizes de adjacência e Laplaciana de grafos desconexos tem forma bloco-diagonal. As expressões (1.23) e (1.24) têm explicitamente a aparência bloco-diagonal porque escolhemos convenientemente a ordenação dos vértices do grafo da Fig. 1.5. Esta é uma liberdade que sempre teremos a nossa disposição.

Notem que é fácil ver da forma da matriz de adjacência (1.23) que qualquer elemento $a_{ij}^{(k)}$ fora da diagonal de blocos será sempre nulo para qualquer potência k.

1.2.2 Grafos bipartidos

Um grafo é dito bipartido se seus vértices puderem ser separados em dois conjuntos, V_1 e V_2 disjuntos tais que vértices de V_1 se conectam apenas a vértices de V_2, e vice-versa. Vejam um exemplo na Fig. 1.6. Grafos bipartidos tem várias propriedades interessantes. Por exemplo, um grafo é bipartido se, e somente se, ele não contiver nenhum ciclo ímpar (ciclo com número impar de passos). Este resultado pode ser provado de maneira elementar. Primeiro, vamos mostrar que não ter nenhum ciclo impar é condição necessária para ser bipartido. Ora, qualquer caminho deve ser uma sucessão de vértices se alternando entre V_1 e V_2. Logo, qualquer ciclo que eventualmente exista deve ser par. Para mostrar que essa condição é também suficiente, vamos introduzir a noção de paridade de vértices. Vamos supor que o grafo seja conexo[4]. Escolhamos um vértice v_i qualquer do grafo. Como o grafo

[4]Se não for este o caso, repete-se o argumento para suas partes conexas.

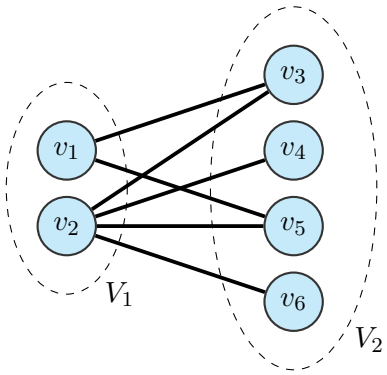

Figura 1.6: Grafo bipartido.

é conexo, haverá sempre pelo menos um caminho $C = (v_i, \ldots, v_k, \ldots, v_\ell)$ conectando v_i a qualquer outro vértice v_ℓ do grafo. Dizemos que o vértice v_k do caminho C é par se o número de passos no caminho a partir de v_i for par. Idem para o caso ímpar. O ponto interessante aqui é que se o grafo não contiver ciclos ímpares, esta classificação independe do caminho, desde que se inicie em v_i. Para demonstrar este fato, considere dois caminhos C_1 e C_2 conectando os vértices v_i e v_k. Se v_k for par ao longo de C_1 e impar ao longo de C_2, podemos construir um ciclo ímpar ao longo dos dois caminhos. Como não há por hipótese ciclos ímpares, a paridade de v_k será a mesma ao longo de qualquer caminho. Note que, por construção, vértices pares se conectam apenas a vértices ímpares, e vice-versa, o que implica na existência da nossa bipartição.

É instrutivo analisarmos a matriz de adjacência de um grafo bipartido. Para o caso particular da Fig. 1.6, teremos

$$A = \left(\begin{array}{cc|cccc} 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 1 & 1 & 1 & 1 \\ \hline 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \end{array}\right). \tag{1.25}$$

É evidente a forma

$$A = \begin{pmatrix} 0 & B \\ B^t & 0 \end{pmatrix}, \tag{1.26}$$

que implica em

$$A^2 = \begin{pmatrix} BB^t & 0 \\ 0 & B^tB \end{pmatrix}, \tag{1.27}$$

e

$$A^3 = \begin{pmatrix} 0 & BB^tB \\ B^tBB^t & 0 \end{pmatrix}. \tag{1.28}$$

De maneira mais geral, sempre teremos para grafos bipartidos

$$A^k = \begin{pmatrix} * & 0 \\ 0 & *^t \end{pmatrix}, \tag{1.29}$$

se k for par e

$$A^k = \begin{pmatrix} 0 & * \\ *^t & 0 \end{pmatrix}, \tag{1.30}$$

para k impar, em perfeito acordo com a inexistência de ciclos ímpares no grafo.

1.2.3 Grafos como espaços métricos

A seguinte definição de distância entre vértices da parte conexa de um grafo é bastante intuitiva e natural no contexto que nos interessa.

Definição 3 *A distância* $\mathrm{dist}(v_i, v_j)$ *entre dois vértices* v_i *e* v_j *pertencentes a uma parte conexa de um grafo é o comprimento do menor caminho entre* v_i *e* v_j*.*

É fácil mostrar que esta noção de distância satisfaz as seguintes propriedades:

1. $\mathrm{dist}(v_i, v_j) \geq 0$ e será zero se, e somente se, $v_i = v_j$,
2. $\mathrm{dist}(v_i, v_j) = \mathrm{dist}(v_j, v_i)$,
3. $\mathrm{dist}(v_i, v_j) \leq \mathrm{dist}(v_i, v_k) + \mathrm{dist}(v_k, v_j)$,

válidas para quaisquer vértices $v_i, v_j, v_k \in V(G)$. Estas propriedades implicam que a noção de distância 3 corresponde a uma métrica sobre o grafo G.

As propriedades já discutidas das potências da matriz de adjacência nos fornecem a seguinte definição equivalente para a distância entre dois vértices

$$\mathrm{dist}(v_i, v_j) = \text{menor inteiro positivo } k \text{ tal que } a_{ij}^{(k)} \neq 0. \tag{1.31}$$

Esta definição não nos fornece uma forma eficiente para se determinar efetivamente a distância entre vértices, mas ela tem uma outra utilidade. Suponha que não exista nenhum k para o qual $a_{ij}^{(k)} \neq 0$. Neste caso, a conclusão é que não existe nenhum caminho que conecta os vértices v_i e v_j. Isto significa obviamente que o grafo possui partes disjuntas, *i.e.*, que é um grafo desconexo. Notem que basta restringir a busca a $1 \leq k < n$, pois o maior caminho possível entre dois vértices distintos de um grafo com n vértices tem comprimento $n - 1$. Esta restrição também pode ser derivada como corolário do conhecido teorema de Caley-Hamilton, cuja discussão pode ser encontrada em qualquer texto de Álgebra Linear. Para o que nos interessa, o teorema

garante que, para qualquer matriz A quadrada $n \times n$, A^k para $k \geq n$ pode ser sempre escrita como combinação linear das potencias A^ℓ com $1 \leq \ell < n$. Assim, se mostrarmos que uma certa entrada é tal que $a_{ij}^{(\ell)} = 0$ para todo $1 \leq \ell < n$, teremos que ela será nula para todo ℓ não negativo.

A existência de uma métrica sobre o grafo G permite a introdução de certas estruturas métricas sobre G. É o caso da noção de "bola" em torno de um vértice, que naturalmente nos fornece também uma noção de vizinhança e, consequentemente, de topologia.

Definição 4 *Denomina-se bola $B_m(v)$ de raio m em torno do vértice $v \in V(G)$ o seguinte conjunto de vértices*

$$B_m(v) = \left\{ v' \in V(G) \quad | \quad \mathrm{dist}(v, v') \leq m \right\}.$$

Há duas quantidades relacionadas ao "tamanho total" de um grafo conexo.

Definição 5 *O raio de um grafo conexo G é o raio da menor bola que contém todos os vértices de G.*

Definição 6 *O diâmetro de um grafo conexo G é a maior distância entre dois vértices de G.*

Dá-se o nome de vértices centrais aos vértices que realizam o raio de um grafo, *i.e.*, os vértices em torno dos quais estão as bolas mínimas que contém G. Chama-se de centro do grafo o conjunto de todos seus vértices centrais. Vértices que realizam o diâmetro de um grafo são chamados de vértices periféricos.

Dado um vértice $v \in V(G)$, define-se a excentricidade $\mathrm{exc}(v)$ de v como o raio da menor bola em torno de v contendo todo o grafo G,

$$\mathrm{exc}(v) = \max_{v' \in V(G)} \mathrm{dist}(v, v'). \tag{1.32}$$

É fácil ver que o raio do grafo G é a mínima excentricidade do grafo, *i.e.*,

$$\mathrm{raio}(G) = \min_{v \in V(G)} \max_{v' \in V(G)} \mathrm{dist}(v, v'), \tag{1.33}$$

enquanto o diâmetro é máxima excentricidade

$$\boxed{\operatorname{diam}(G) = \max_{v \in V(G)} \max_{v' \in V(G)} \operatorname{dist}(v, v'). \qquad (1.34)}$$

Os vértices centrais e os periféricos são, respectivamente, os vértices de mínima e máxima excentricidade. O raio e o diâmetro de um grafo G satisfazem

$$\frac{1}{2}\operatorname{diam}(G) \leq \operatorname{raio}(G) \leq \operatorname{diam}(G). \qquad (1.35)$$

A desigualdade superior decorre diretamente da definição. Já a inferior vêm diretamente da desigualdade triangular, já que

$$\operatorname{diam}(G) = \operatorname{dist}(v, v') \leq \operatorname{dist}(v, z) + \operatorname{dist}(v', z) \leq 2\operatorname{raio}(G), \qquad (1.36)$$

sendo v e v' dois vértices periféricos de G e z um vértice central. É interessante olharmos para os casos que saturam desigualdade (1.35). Para os grafos completos K_n, por exemplo, sempre temos $\operatorname{raio}(G) = \operatorname{diam}(G) = 1$. Por outro lado, para grafos caminho com número ímpar de vértices, P_{2n+1}, sempre temos $\frac{1}{2}\operatorname{diam}(G) = \operatorname{raio}(G) = n$.

É muito comum nos referirmos à topologia de um grafo. Em geral, deve-se entender topologia aqui como o conjunto de vizinhanças dos vértices. Assim, a topologia de um grafo corresponde sempre a sua estrutura de conexões.

1.2.4 Exercícios

Grafos como espaços métricos Considerem o grafo da Fig. 1.

1. Determinem a excentricidade de todos seus vértices, o raio e o diâmetro do grafo.
2. Determine a distância entre v_4 e v_6 a partir das potências da matriz de adjacência A.
3. Determine o número de triângulos no grafo a partir da matriz de adjacência. Identifique graficamente esses triângulos.

Gênio Indomável Resolva o item 2 proposto pelo Prof. Lambeau.

1.3 Teoria espectral de grafos

Dá-se o nome de teoria espectral de grafos ao estudo dos problemas de autovalores e autovetores das matrizes, usualmente de adjacência e Laplaciana, associadas a grafos. Ambas matrizes de adjacência e Laplaciana são simétricas e, portanto, sabemos que são diagonalizáveis. Suas propriedades espectrais, que são invariantes por isomorfismos, podem revelar informações sobre a estrutura do grafo que representam. Comecemos pelo caso pela matriz de adjacência A.

1.3.1 Matriz de adjacência

Vamos supor que os autovalores λ_i da matriz de adjacência A estejam ordenados como

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n, \tag{1.37}$$

levando-se em conta possíveis multiplicidades que poderiam implicar, por exemplo, em $\lambda_k = \lambda_{k+1}$ para alguns valores de k. A primeira observação é que há um interessante limite superior para o maior autovalor λ_1 da matriz de adjacência de um grafo. Suponha que o autovetor associado a λ_1 seja X_1. Tomemos a componente $x_1^{(k)}$ de X_1 de maior módulo. Podemos admitir, sem perda de generalidade, que $x_1^{(k)} > 0$.[5] Consideremos agora a k-ésima linha da identidade $AX_1 = \lambda_1 X_1$, a qual nos fornece[6]

$$\lambda_1 x_1^{(k)} = \sum_{i=1}^{n} a_{ki} x_1^{(i)} \leq \sum_{i=1}^{n} a_{ki} x_1^{(k)} \leq d_{\max} x_1^{(k)} \tag{1.38}$$

de onde segue a restrição

$$\lambda_1 \leq d_{\max} \tag{1.39}$$

sendo $d_{\max}$ o grau máximo do grafo. Podemos obter também facilmente um limite inferior. Sejam os (λ_i, X_i) os pares de autovalores e autovetores ortonormais[7] de A, e Y um vetor arbitrário, que pode sempre ser escrito em termos dos autovetores X_i como

$$Y = \alpha_1 X_1 + \alpha_2 X_2 + \cdots + \alpha_n X_n. \tag{1.40}$$

Notem que

$$Y^t A Y = \lambda_1 \alpha_1^2 + \lambda_2 \alpha_2^2 + \cdots + \lambda_n \alpha_n^2. \tag{1.41}$$

É fácil mostrar[8] que

$$\lambda_1 = \max Y^t A Y, \qquad \text{com } Y^t Y = 1. \tag{1.42}$$

Tomem agora $Y = \frac{1}{\sqrt{n}}(1, 1, \ldots, 1)^t$ e teremos

$$Y^t A Y = \frac{1}{N} \sum_{i=1}^{n} \sum_{j=1}^{n} a_{ij} = \frac{1}{N} \sum_{i=1}^{n} d_i = d_{\text{avg}} \tag{1.43}$$

sendo d_{avg} o grau médio do grafo, de onde temos finalmente a interessante desigualdade

$$d_{\text{avg}} \leq \lambda_1 \leq d_{\max}. \tag{1.44}$$

[5] Caso não seja, bastaria considerar o vetor $-X_1$.

[6] Esta construção é, de fato, idêntica ao do teorema dos discos de Gershgorin.

[7] Chamaremos, daqui em diante, de autopar ao par autovalor-autovetor ortonormal de uma matriz.

[8] Mostrem!

Podemos também mostrar que o autovetor X_1 da matriz de adjacência tem todas suas entradas não negativas[9] se o grafo for conexo. Vamos explorar a expressão (1.42). Suponha que o autovetor $X_1 = (x_1, x_2, \ldots, x_n)^t$, normalizado como $X_1^t X_1 = 1$, tenha algumas componentes negativas, mas não todas. Nesse caso, considerem o vetor $Y = (|x_1|, |x_2|, \ldots, |x_n|)^t$, que igualmente será normalizado como $Y^t Y = 1$. Notem que

$$Y^t A Y = \sum_{i=1}^{n} |x_i| \sum_{k=1}^{n} a_{ik} |x_k| \geq \sum_{i=1}^{n} |x_i| \left| \sum_{k=1}^{n} a_{ik} x_k \right| = \lambda_1, \tag{1.45}$$

que só não será uma contradição se $x_k = |x_k|$, *i.e.*, nenhuma componente de X_1 pode ser negativa. Falta agora demonstrar que não pode haver componentes nulas em X_1. Para provar este fato, considerem a identidade

$$A^m X_1 = \lambda_1^m X_1. \tag{1.46}$$

O vetor X_1 não pode ser nulo e tem todas suas componentes não negativas. Suponha agora que ele possua uma componente $x_k = 0$. Nesse caso, a k-ésima componente do vetor $A^m X_1$ será

$$[A^m X_1]_k = \sum_{i=1}^{n} a_{ki}^{(m)} x_i = 0. \tag{1.47}$$

Porém, sabemos que as entradas $\left[a_{ki}^{(m)}\right]$ da matriz A^m correspondem ao número de passeios de m passos entre os vértices v_k e v_i. Em particular, se o grafo for conexo, sempre haverá um m para o qual $\left[a_{ki}^{(m)}\right] > 0$, o que nos leva a uma contradição. Dessa forma, temos que todas as componentes de X_1 são estritamente positivas.

Ainda sobre o autovetor X_1, podemos demonstrar que ele é único para grafos conexos, *i.e.*, que a multiplicidade de λ_1 é 1 para grafos conexos. Suponha que exista um segundo autovetor $\tilde{X}_1$ com autovalor λ_1 para um grafo conexo. Utilizando os mesmos argumentos dos parágrafos anteriores, concluímos que $\tilde{X}_1$ tem todas as componentes positivas. O vetor $Y_\beta = X_1 - \beta \tilde{X}_1$, para qualquer valor de $\beta \in \mathbb{R}$, será também autovetor de A, com o mesmo autovalor λ_1. Fixemos β como sendo o valor para o qual pelo menos uma componente de Y_β seja nula, mas ainda garantindo que todas as não nulas sejam positivas. Repitamos agora a análise de (1.47) para uma dessas componentes nulas de Y_β. Como sempre há um m tal que $\left[a_{ki}^{(m)}\right]$, para quaisquer i e k, a única possibilidade de (1.47) ser satisfeita é se $Y_\beta = 0$, que implica $X_1 \propto \tilde{X}_1$ e consequentemente que a multiplicidade de λ_1 é 1. Como a estrutura da matriz de adjacência para grafos desconexos é da forma bloco-diagonal, é fácil mostrar que a multiplicidade de λ_1 é o número de partes conexas do grafo.

[9] Ou não positivas, bastando tomar o autovalor $-X_1$.

Há outras propriedades do espectro de A que seguem diretamente dos conhecidos resultados de matrizes diagonalizáveis. Em particular, teremos

$$\sum_{i=1}^{n} \lambda_i = \operatorname{tr} A = 0, \tag{1.48}$$

e

$$\sum_{i=1}^{n} \lambda_i^2 = \operatorname{tr} A^2 = 2|E(G)|. \tag{1.49}$$

Como λ_1 é estritamente positivo, teremos da primeira condição que necessariamente $\lambda_n < 0$. É possível também obter certos limites inferiores e superiores para λ_2, mas a situação é muito mais complexa e é tema de estudos atualmente. Notem que podemos facilmente derivar uma condição semelhante a (1.49) para a soma dos cubos dos autovalores. Os dois teoremas a seguir resumem o que sabemos até agora sobre o espectro da matriz de adjacência A de um grafo G.

Teorema 5 *Sejam $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$ os autovalores da matriz de adjacência A de um grafo G de n vértices. Temos*

$$\begin{gathered} d_{\text{avg}} \leq \lambda_1 \leq d_{\max}, \\ \sum_{i=1}^{n} \lambda_i = 0, \\ \sum_{i=1}^{n} \lambda_i^2 = 2|E(G)|, \\ \sum_{i=1}^{n} \lambda_i^3 = 6N_\Delta(G). \end{gathered}$$

Sendo a multiplicidade de λ_1 igual ao número de partes conexas de G.

Teorema 6 *O autovetor correspondente ao maior autovalor da matriz de adjacência de um grafo conexo tem todas suas componentes positivas.*

O espectro da matriz de adjacência de grafos bipartidos tem uma propriedade extra especial. A matriz de adjacência A de um grafo bipartido tem sempre a forma (1.26). Considerem agora $\mathcal{P}$, a matriz diagonal cujas entradas são 1 ou -1, respectivamente, se a entrada corresponder a um vértice de V_1 ou de V_2. A primeira observação é que teremos neste caso

$$\mathcal{P}A\mathcal{P} = -A. \tag{1.50}$$

Suponha agora que λ_k seja um autovalor de A, com autovetor X_k. Teremos

$$AX_k = A\mathcal{P}^2 X_k = \lambda_k X_k, \tag{1.51}$$

já que $\mathcal{P}^2 = I$. Multiplicando-se ambos os lados por $\mathcal{P}$ pela esquerda, teremos

$$(\mathcal{P}A\mathcal{P})\,\mathcal{P}X_k = -A(\mathcal{P}X_k) = \lambda_k(\mathcal{P}X_k), \tag{1.52}$$

o que implica que $-\lambda_k$ também é autovalor de A, com autovetor correspondente $\mathcal{P}X_k$. Em particular, sempre teremos $\lambda_n = -\lambda_1$, $\lambda_{n-1} = -\lambda_2$, etc. Outra consequência interessante é que um grafo bipartido com número impar de vértices sempre terá matriz de adjacência singular, pois $\lambda = 0$ necessariamente estará no espectro de A.

1.3.2 Exercícios

Teorema dos discos de Gershgorin O chamado teorema dos discos (ou círculos) de Gershgorin foi importante na obtenção da desigualdade (1.39).

1. Enuncie e prove este teorema.
2. Sejam r_1, r_2, r_3 e r_4, respectivamente, o resto da divisão do seu RA por 11, 13, 17 e 23. Use o teorema de Gershgorin para localizar no plano complexo os autovalores da matriz

$$\begin{pmatrix} r_1 & -1 & 1 & 0 \\ 0 & r_2 & -1 & 1 \\ -1 & -1 & r_3 & 2 \\ 2 & 0 & 0 & r_4 \end{pmatrix}$$

Teorema min-max Por trás da construção (1.42) temos uma parte do famoso teorema min-max, conhecido na Física também como teorema variacional. Demonstre a expressão (1.42). Como você faria para obter dessa construção o menor autovalor? E para se obter um autovalor qualquer λ_k, supondo-os ordenados como (1.37). Respondida esta questão, você terá provado o teorema min-max! ☺

Espectro de K_4 Determine os autovalores e autovetores da matriz de adjacência do grafo K_4, i.e., o grafo completo de 4 vértices. (O grafo de 4 vértices com todas as arestas possíveis).

1.3.3 Matriz Laplaciana

Vamos supor agora que os autovalores da matriz laplaciana L, tendo em conta suas eventuais multiplicidades, estejam ordenados como

$$\mu_1 \geq \mu_2 \geq \cdots \geq \mu_n \tag{1.53}$$

Das propriedades elementares da diagonalização de matrizes, temos nossa primeira condição

$$\sum_{i=1}^{n} \mu_i = \operatorname{tr} L = \sum_{i=1}^{n} d_i = 2|E(G)|, \tag{1.54}$$

de onde já podemos inferir que $\mu_1 > 0$. Podemos estabelecer um limite superior para μ_1 de maneira semelhante a que fizemos para o caso da matriz de adjacência. Seja X_1 o autovetor associado a μ_1 e $x_1^{(k)} > 0$ sua componente de maior módulo, a qual admitimos, já sabendo que não há perda de generalidade, ser positiva. Consideremos agora a k-ésima linha da identidade $LX_1 = \mu_1 X_1$ que nos dá

$$\mu_1 x_1^{(k)} = \sum_{i=1}^{n} \ell_{ki} x_1^{(i)} \leq \sum_{i=1}^{n} |\ell_{ki}| x_1^{(k)} \leq 2d_{\max} x_1^{(k)} \tag{1.55}$$

de onde temos um limite superior para o maior autovalor da matriz Laplaciana. Podemos obter também um limite inferior de maneira semelhante ao caso da matriz de adjacência. De maneira análoga, temos agora

$$\mu_1 = \max Y^t L Y, \qquad \text{com } Y^t Y = 1. \tag{1.56}$$

Porém, para a matriz Laplaciana temos sempre[10]

$$Y^t L Y = \sum_{e(v_i, v_j)} \left(y^{(i)} - y^{(j)} \right)^2, \tag{1.57}$$

para qualquer vetor $Y = (y^{(1)}, y^{(2)}, \dots)^t$, entendendo-se a soma como feita sobre todas as arestas $e(v_i, v_j) \in E(G)$. Considere agora o vetor Z com todas entradas nulas exceto a $z^{(k)} = 1$, sendo k o vértice de maior grau do grafo. Teremos

$$\mu_1 \geq Z^t L Z = d_{\max} \tag{1.58}$$

de onde finalmente concluímos

$$d_{\max} \leq \mu_1 \leq 2d_{\max}. \tag{1.59}$$

Notem que a condição (1.57) implica que todos os autovalores de L são não negativos (provem!). Também é fácil ver que $\mu_n = 0$, com o autovetor associado (e normalizado) dado por $X_n = \frac{1}{\sqrt{n}}(1, 1, \dots, 1)^t$.

O menor autovalor da matriz Laplaciana μ_n, que já sabemos ser nulo, traz outras interessantes informações sobre o grafo. Vamos mostrar que sua multiplicidade é igual ao número de partes conexas do grafo. Já sabemos que as matrizes de adjacência e Laplaciana são do tipo bloco-diagonal para

[10] Provem!

grafos desconexos, ver (1.23) e (1.24), e ambas são compostas pelas matrizes de suas componentes conexas. Já sabemos que o vetor $X_n = \frac{1}{\sqrt{n}}(1, 1, \ldots, 1)^t$ é sempre autovetor com autovalor zero de L. Em outras palavras, já sabemos que sempre temos $X_n \in \operatorname{Ker} L$. A questão relevante aqui é determinar a dimensão do núcleo de L, pois ela nos dará exatamente a multiplicidade do autovalor nulo μ_n. É fácil mostrar que para uma matriz bloco diagonal como a Laplaciana (1.24), a dimensão do núcleo de L será a soma das dimensões dos núcleos de cada bloco. Agora vem o ponto crucial: o núcleo de L para um grafo conexo é sempre unidimensional, *i.e.*, é sempre o gerado pelo o vetor $X_n = \frac{1}{\sqrt{n}}(1, 1, \ldots, 1)^t$. Há inúmeras maneiras de se provar este resultado utilizando diversos resultados de álgebra linear. Porém, há uma que explora noções puramente de conectividade em grafos e, obviamente, será esta que exploraremos. Voltemos a expressão (1.57). Note que se $Z \in \operatorname{Ker} L$, então necessariamente devemos ter

$$Z^t L Z = \sum_{e(v_i, v_j)} (z_i - z_j)^2 = 0, \tag{1.60}$$

que implica que devemos ter $z_i = z_j$ para qualquer par de vértices conectados por uma aresta. Ora, se o grafo é conexo, então sempre haverá um passeio conectando todos os vértices, o que implica em

$$z_1 = z_2 = \cdots = z_n, \tag{1.61}$$

o que, em outras palavras, garante que a solução só pode ser o X_n introduzido acima, estabelecendo nosso resultado.

Há também uma condição sobre o menor autovalor não nulo de L, chamado também de conectividade algébrica do grafo. Vamos supor sem perda de generalidade que o grafo é conexo e chamá-lo de μ_{n-1}. Notem primeiro que[11]

$$\mu_{n-1} = \min Y^t L Y, \qquad \text{com } Y^t Y = 1 \text{ e } Y \in (\operatorname{Ker} L)^{\perp}. \tag{1.62}$$

De maneira análoga ao que fizemos acima, considere o vetor Z com todas entradas nulas exceto a $z^{(k)} = 1$, sendo k o vértice de menor grau do grafo. Notem que

$$Y = \sqrt{\frac{n}{n-1}} \left(Z - \frac{1}{\sqrt{n}} X \right) \tag{1.63}$$

é unitário e $Y \in (\operatorname{Ker} L)^{\perp}$ e, portanto,

$$\mu_{n-1} \leq Y^t L Y = \frac{n}{n-1} d_{\min}. \tag{1.64}$$

Nossos resultados podem ser sumarizados na forma de um teorema.

[11] Provem!

Teorema 7 *Sejam $\mu_1 \geq \mu_2 \geq \cdots \geq \mu_n$ os autovalores da matriz Laplaciana L de um grafo conexo G de n vértices. Temos*

$$d_{\max} \leq \mu_1 \leq 2d_{\max}$$
$$\sum_{i=1}^{n} \mu_i = 2|E(G)|$$
$$\mu_n = 0$$
$$0 < \mu_{n-1} \leq \tfrac{n}{n-1} d_{\min}$$

Para grafos desconexos, o teorema valerá para cada uma de suas partes conexas, implicando que a multiplicidade do autovalor nulo é igual ao número de partes conexas. O autovetor associado à conectividade algébrica é chamado de vetor de Fiedler, e ele possui uma interessante interpretação em problemas de particionamento de grafos, como veremos mais adiante.

1.3.4 Exercícios

Matriz Laplaciana elementar Muitas vezes é conveniente decompor uma matriz Laplaciana em termos de matrizes Laplacianas elementares

$$L = \sum_{e \in E(G)} L_e,$$

sendo a soma entendida como feita sobre todos as arestas e do grafo G e L_e representando a matriz Laplaciana do grafo G com todas as arestas removidas, exceto a aresta e. Este tipo de decomposição pode ser representada graficamente como ilustrado abaixo, a qual também se aplica às correspondentes matrizes Laplacianas.

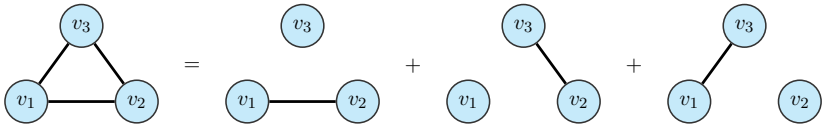

Explorando-se este tipo de decomposição, prove (1.57).

Teorema de Perron-Frobenius Enuncie o teorema de Perron-Frobenius e use-o para extrair o máximo de informações que puder sobre o maior autovalor e seu respectivo autovetor da matriz de adjacência. Compare com os que você sabe sobre o menor autovalor da matriz Laplaciana.

Teorema dos discos de Gershgorin Obtenha o limite superior para μ_1 a partir do Teorema dos discos de Gershgorin.

Espectro de grafos regulares Um grafo é dito regular se todos seus vértices têm o mesmo grau. Mostre que as matrizes de adjacência e La-

placiana de um grafo regular têm exatamente os mesmos autovetores. Que relação há entre seus autovalores?

1.3.5 Matrizes normalizadas

Em várias aplicações, as chamadas matrizes de adjacência e Laplaciana normalizadas surgem naturalmente. Elas são definidas, respectivamente, pelas expressões

$$\mathcal{A} = D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \tag{1.65}$$

e

$$\mathcal{L} = D^{-\frac{1}{2}} L D^{-\frac{1}{2}}. \tag{1.66}$$

Ambas matrizes são simétricas e, portanto, diagonalizáveis. Podemos inferir algumas propriedades de seus espectros. A primeira observação a ser feita é que temos a seguinte relação entre estas matrizes: $\mathcal{L} = I - \mathcal{A}$, de onde temos que se $(\tilde{\mu}_j, X_j)$ é um autopar de $\mathcal{L}$, temos que $(\tilde{\lambda}_j, X_{n+1-j})$, com $\tilde{\lambda}_j = 1 - \tilde{\mu}_{n+1-j}$ é autopar de $\mathcal{A}$. Ambas matrizes têm exatamente os mesmos autovetores. Na prática, basta determinarmos o espectro de uma das matrizes e teremos resolvido o problema da diagonalização de ambas.

Comecemos nossa análise pela matriz Laplaciana normalizada. É fácil ver que

$$Y^t \mathcal{L} Y = \left(Y^t D^{-\frac{1}{2}}\right) L \left(D^{-\frac{1}{2}} Y\right) = \sum_{e(v_i,v_j)} \left(\frac{y^{(i)}}{\sqrt{d_i}} - \frac{y^{(j)}}{\sqrt{d_j}}\right)^2 \tag{1.67}$$

para qualquer vetor $Y = (y^{(1)}, y^{(2)}, \dots)^t$. Como no caso da matriz Laplaciana usual, trata-se de uma matriz não negativa e, portanto, seu espectro também será não negativo. Pode-se verificar, por inspeção, que o vetor unitário

$$\tilde{X}_n = \frac{1}{\sqrt{2|E(G)|}} \left(\sqrt{d_1}, \sqrt{d_2}, \dots\right)^t \tag{1.68}$$

pertence ao núcleo de $\mathcal{L}$ e que, portanto, a matriz Laplaciana normalizada tem pelo menos um autovalor zero. De maneira análoga à análise da matriz Laplaciana usual, temos de (1.67) que a multiplicidade do autovalor zero da matriz Laplaciana normalizada também corresponde ao número de partes conexas do grafo. Notem que a multiplicidade do autovalor $\tilde{\mu}_n = 0$ de $\mathcal{L}$ será igual à multiplicidade do autovalor $\tilde{\lambda}_1 = 1$ de $\mathcal{A}$.

Podemos obter um limite superior para o maior autovalor $\tilde{\mu}_1$ de $\mathcal{L}$ de maneira análoga ao que fizemos no caso da matriz Laplaciana usual, lembrando que

$$\tilde{\mu}_1 = \max Y^t \mathcal{L} Y, \quad \text{com } Y^t Y = 1. \tag{1.69}$$

Porém, de (1.67) temos[12]

$$\max Y^t \mathcal{L} Y \leq 2 \sum_{e(v_i,v_j)} \left(\frac{\left(y^{(i)}\right)^2}{d_i} + \frac{\left(y^{(j)}\right)^2}{d_j} \right) = 2, \tag{1.70}$$

de onde temos $\tilde{\mu}_1 \leq 2$. Escolhendo-se um vetor Y com todas as entradas nulas exceto uma arbitrária que será 1, é fácil ver de (1.67) que teremos também $1 \leq \tilde{\mu}_1$. Estes resultados são sumarizados no seguinte teorema.

Teorema 8 *Sejam $\tilde{\mu}_1 \geq \tilde{\mu}_2 \geq \cdots \geq \tilde{\mu}_n$ os autovalores da matriz Laplaciana normalizada $\mathcal{L}$ de um grafo conexo G de n vértices. Temos*

$$1 \leq \tilde{\mu}_1 \leq 2$$
$$\sum_{i=1}^{n} \tilde{\mu}_i = n$$
$$\tilde{\mu}_n = 0$$

Como no caso anterior, para grafos desconexos, o teorema valerá para cada uma de suas partes conexas, implicando que a multiplicidade do autovalor nulo é igual ao número de partes conexas.

A análise de $\mathcal{A}$ também nos dá algumas informações interessantes. Notem que, se ordenamos os autovalores como $\tilde{\lambda}_1 \geq \tilde{\lambda}_2 \geq \cdots \geq \tilde{\lambda}_n$, já sabemos que $\lambda_1 = 1$. As matrizes normalizadas de grafos bipartidos têm uma propriedade interessante. Da mesma forma que fizemos no caso da matriz de adjacência usual, pode-se concluir que, para grafos bipartidos, teremos sempre $\tilde{\lambda}_n = -1$. Porém, esta condição implica que $\tilde{\mu}_1$ satura sua desigualdade no Teorema 8, *i.e.*, temos neste caso $\tilde{\mu}_1 = 2$.

1.3.6 Espectro e simetrias

Há alguns resultados simples que são bastante valiosos quando necessitamos diagonalizar matrizes. O teorema 2 define o que entendemos por simetria de um grafo a partir das permutações de linhas e colunas da matriz de adjacência A. É importante salientar que o mesmo vale para a matriz Laplaciana L, assim como para suas versões normalizadas. Suponha que um certo grafo com matriz de adjacência A tenha uma simetria dada pela permutação P. Seja agora (λ, X) um autopar de A. Teremos

$$\lambda X = AX = P^t APX. \tag{1.71}$$

Multiplicando-se por P pela esquerda, tem-se

$$A(PX) = \lambda(PX), \tag{1.72}$$

[12] Consequência elementar da identidade $(a+b)^2 + (a-b)^2 = 2(a^2+b^2)$.

de onde temo que se (λ, X) é um autopar de A, (λ, PX) também será.

A observação que nos será útil vem do caso em que a multiplicidade de λ é 1. Nesse caso, há apenas um autovetor associado, e necessariamente teremos que PX deve ser colinear a X. Porém, como a matriz de permutação P é ortogonal, esta condição implica necessariamente $PX = \pm X$. Vamos resumir este fato no seguinte lema.

Lema 1 *Seja P um automorfismo de um grafo com matriz de adjacência A. Se λ é um autovalor de A com multiplicidade 1, então seu autovetor correspondente X será também autovetor de P, com $PX = \pm X$.*

O caso $PX = X$ significa que o vetor X também exibe a simetria representada por P. Diz-se, nesse caso, que X é par com relação a permutação P. Já a situação $PX = -X$ corresponde a antissimetria, e X é dito impar nesse caso. O mesmo lema vale também para o caso da matriz Laplaciana L.

1.4 Grafos mais gerais

Nossa definição 1 de grafo simples não acomoda várias estruturas de interesse prático. Apesar de que basicamente só iremos considerar grafos simples em nossas análises futuras, convém apresentar também algumas das variantes mais gerais de grafos. Comecemos eliminando a restrição na definição 1 de que um par de vértices distintos admita no máximo uma aresta. Este é o caso, por exemplo, do grafo da Fig. 1.7. Como vemos, há duas arestas entre

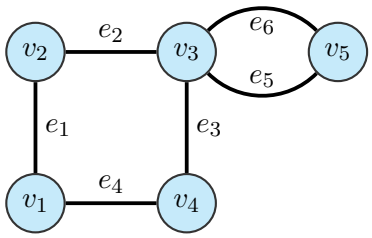

Figura 1.7: Exemplo de grafo com mais de uma aresta por par de vértices. Chamado também de multigrafo (*multigraph*).

os vértices v_3 e v_5. Vamos estender o formalismo matricial utilizado até agora a fim de permitir este tipo de situação. Comecemos pela matriz de incidência. A definição (1.3) pode ser aplicada diretamente nesta situação,

nos fornecendo a matriz

$$M = \begin{pmatrix} 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 \end{pmatrix}. \tag{1.73}$$

Notem que as duas últimas colunas são idênticas, pois as duas arestas e_5 e e_6 são, na prática, também idênticas (unem o mesmo par de vértices). A matriz de adjacência do grafo (1.7) pode também ser obtida de (1.9). Teremos

$$A = \begin{pmatrix} 0 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 2 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \end{pmatrix}, \tag{1.74}$$

sendo a matriz de graus $D = \mathrm{diag}\,(2, 2, 4, 2, 2)$. As matrizes de incidência (1.73) e adjacência (1.74) têm, na prática, as mesmas propriedades das matrizes correspondentes para grafos simples. Em particular, temos o lema do aperto de mão e as entradas da da n-ésima potência da matriz de adjacência continuam descrevendo o número possível de passeios de n passos conectando dois vértices. Notem que a matriz de adjacência (1.74) e a correspondente matriz Laplaciana podem também ser entendidas como a soma das matrizes de grafos elementares, *i.e.*, da decomposição representada diagramaticamente na Fig. 1.8. Este tipo de decomposição é muito útil em

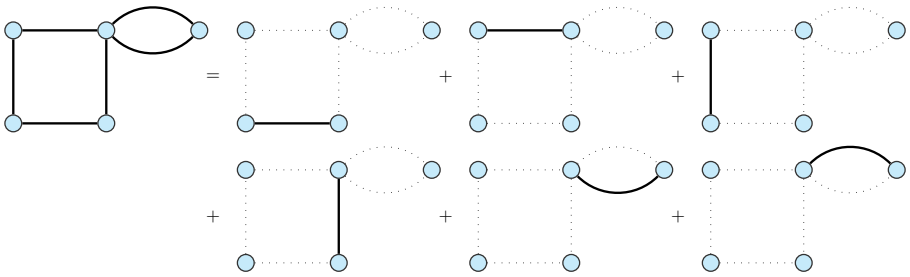

Figura 1.8: Decomposição do grafo (1.7 como soma de grafos elementares de uma única aresta.

diversas situações. Cada diagrama elementar corresponde a uma coluna da matriz de incidência e contribui com duas entradas (simétricas) da matriz de adjacência. A composição dos grafos, do ponto de vista da matriz de incidência, corresponde à justaposição de colunas, cada nova aresta incorporada corresponderá a uma nova coluna da matriz M. Já do ponto de vista da matriz de adjacência A, a composição dos grafos corresponde a soma das

matrizes de adjacência elementares. O caso da matriz Laplaciana é idêntico ao discutido no primeiro exercício da Seção 3.4.

O próximo passo na generalização de nossos grafos será considerar o caso auto-ligações, *i.e.*, o caso de arestas que começam e terminam no mesmo vértice, vejam a Figura 1.9. É claro que podemos encarar este grafo como a

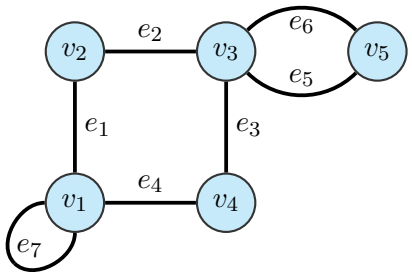

Figura 1.9: Exemplo de grafo com auto-ligações (laços, *loops*).

"soma" do grafo da Figura (1.7) com o grafo correspondente somente à auto-ligação, *i.e.*, à aresta e_7. A matriz de incidência será a matriz (1.73), porém com uma coluna extra, correspondendo a nova aresta. A questão é: qual a representação mais adequada para uma auto-ligação na matriz de incidência? Temos vários argumentos para justificar que a matriz de incidência do grafo da Fig. 1.9 é

$$M = \begin{pmatrix} 1 & 0 & 0 & 1 & 0 & 0 & 2 \\ 1 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 1 & 1 & 0 \end{pmatrix}, \tag{1.75}$$

i.e., a coluna correspondente à auto-ligação tem uma entrada 2 no vértice correspondente, sendo zero todas as outras. Primeiro, se quisermos continuar com o lema do aperto de mão (e queremos!), a soma de cada coluna da matriz de incidência deve ser 2. Além disso, usando-se a expressão (1.9) chegamos a matriz de adjacência

$$A = \begin{pmatrix} 2 & 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 1 & 2 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 & 0 \end{pmatrix}, \tag{1.76}$$

com a matriz de graus $D = \mathrm{diag}\,(4, 2, 4, 2, 2)$ para o grafo da Fig. 1.9, e ambas matrizes são compatíveis com as nossas interpretações até agora. Em particular, a entrada $a_{11} = 2$ em (1.76) pode ser interpretada como sendo devido as duas possibilidades de sair e retornar ao vértice v_1 com um único

passo. As duas possibilidades são percorrer a auto-ligação no sentido horário e anti-horário.

1.4.1 Grafos orientados

Os chamados grafos orientados[13], ou dirigidos, ou direcionados (*directed*) merecem uma atenção especial. Como o nome sugere, são grafos nos quais as arestas tem direção, *i.e.*, elas correspondem a um par **ordenado** de vértices. Um exemplo de grafo orientado está na Fig. 1.10. As direções das setas

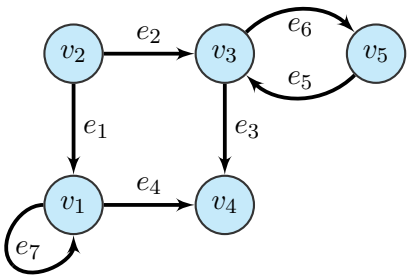

Figura 1.10: Exemplo de grafo orientado.

determinam as direções "permitidas" para darmos um passo ao longo das arestas. Assim, é possível sair de v_1 e chegar a v_4 com um passo, mas não é possível fazer o caminho reverso. Não é possível também sair de v_1 e chegar a v_2 com um passo, mas é possível na direção contrária. Notem que agora há um único caminho que sai e chega em v_1, é o que corresponde a percorrer a auto-ligação no sentido anti-horário, pois o outro sentido não está disponível nesse grafo.

Vamos começar com a matriz de adjacência para grafos orientados. Algumas definições são necessárias. Chamaremos de pé e cabeça (*foot* e *head*, ou origem e destino) de uma aresta, respectivamente, os vértices nos quais a aresta se origina e termina. Por exemplo, para o caso da Fig. 1.10, o pé e a cabeça da aresta e_4, são, respectivamente, os vértices v_1 e v_4. A aresta e_7 tem pé e cabeça no vértice v_1, etc. Lembrando que cada entrada da matriz de adjacência corresponde ao número de caminhos de um passo possíveis entre os vértices correspondentes, é fácil nos convencer que a matriz de adjacência correspondente ao grafo orientado (1.10) será

$$A = \begin{pmatrix} 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 \end{pmatrix}, \tag{1.77}$$

[13]Usa-se também a denominação digrafo (*digraph*).

lembrando que a entrada a_{ij} corresponde ao caminho que origina no vértice v_i e termina no vértice v_j. Em particular, o não há *nenhum* caminho que se origina em v_4, por isso a quarta linha da matriz A é repleta de entradas zero. Notem que a matriz de adjacência de um grafo orientado não é mais necessariamente simétrica. Além disso, a soma das colunas de A nos dá o número de arestas que "emanam" dos vértices v_i, *i.e.*, o número de arestas que tem o pé em v_i. Esta quantidade é denominado grau de saída (*outdegree*) do vértice v_i e é representada por

$$d_i^+ = \sum_{j=1}^{n} a_{ij}. \tag{1.78}$$

Por outro lado, a soma das linhas de A nos dá o número de arestas entrantes em cada vértice. Este é chamado grau de entrada (*indegree*) do vértice e é representado por

$$d_j^- = \sum_{i=1}^{n} a_{ij}. \tag{1.79}$$

Vértices com $d_j^- = 0$ e $d_j^+ > 0$ são chamados de "fontes" (*sources*), e vértices com $d_i^+ = 0$ e $d_j^- > 0$ são "sorvedouros" (*sinks*). Em nosso grafo, v_4 é um sorvedouro, v_2 é uma fonte. Um grafo orientado é dito "balanceado" se $d_i^+ = d_i^-$ para todo vértice $v_i \in G$. Nosso grafo da Fig. 1.10 claramente não é balanceado. Podemos introduzir duas matrizes Laplacianas diferentes para um grafo orientado,

$$L^{\pm} = D^{\pm} - A, \tag{1.80}$$

sendo $D^{\pm}$ a matriz dos graus de entrada $(-)$ ou de saída $(+)$ do grafo. Em geral, são as aplicações que determinam qual a matriz Laplaciana relevante a ser considerada. Obviamente, a teoria espectral de grafos orientados é bastante mais complicada, pois suas matrizes de adjacência e Laplaciana não são, em geral, diagonalizáveis sobre os reais.

Uma observação interessante vem da inspeção da transposta A^t da nossa matriz de adjacência (1.77). A transposição da matriz corresponde a troca das orientações do grafo. Por outro lado, a matriz $A + A^t$, simétrica por construção, corresponde ao grafo não orientado da seção anterior! Isto nos permite introduzir um novo tipo de decomposição de grafos, vejam a Fig. 1.11. Somando-se um grafo orientado e sua "reversão", obtém-se o grafo correspondente não orientado, o que é compatível com a interpretação que uma aresta não orientada corresponde a um caminho sem direção privilegiada. Esta construção é bastante útil em algumas aplicações.

É natural que a matriz de incidência de grafos orientados contenha informações sobre as orientações das arestas. Nesse sentido, uma definição conveniente para as entradas da matriz de incidência de um grafo orientado

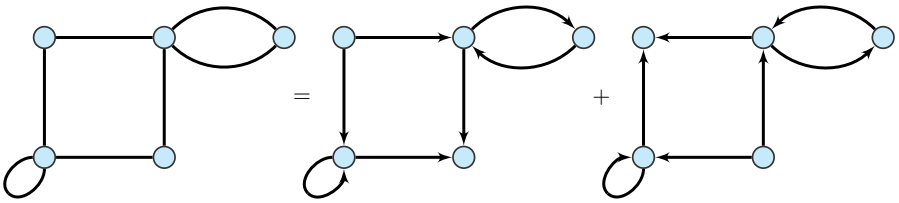

Figura 1.11: Decomposição do grafo (1.7 como soma de dois grafos com orientações contrárias.

é

$$m_{ij} = \begin{cases} -1, & \text{se a aresta } e_j \text{ se originar no vértice } v_i, \\ 1, & \text{se a aresta } e_j \text{ terminar no vértice } v_i, \\ 0, & \text{caso contrário.} \end{cases} \tag{1.81}$$

Por ora, vamos considerar o caso de grafos sem auto-ligações. Considerem o caso do grafo da Fig. 9, sem a aresta e_7. De acordo com a definição (1.81), a matriz de incidência será

$$M = \begin{pmatrix} 1 & 0 & 0 & -1 & 0 & 0 \\ -1 & -1 & 0 & 0 & 0 & 0 \\ 0 & 1 & -1 & 0 & 1 & -1 \\ 0 & 0 & 1 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 & -1 & 1 \end{pmatrix}. \tag{1.82}$$

Por construção, a soma ao longo de linhas é nula para todas as colunas (cada aresta tem um pé e uma cabeça). Para grafos direcionados, a matriz MM^t tem uma outra interessante interpretação. Da mesma maneira que em (1.8), temos neste caso que as componentes de MM^t são

$$m_{ij}^{(2)} = \sum_{k=1}^{E(G)} m_{ik} m_{jk}. \tag{1.83}$$

Comecemos pelos elementos da diagonal, $i = j$. Nesse caso em particular, é fácil ver que $m_{ii}^{(2)} = d_i^+ + d_i^-$. Para $i \neq j$, os produtos $m_{ik}m_{jk}$, para k fixo, só podem ter dois valores: 0, se a aresta e_k não conectar os vértices v_i e v_j, e -1 se houver uma aresta conectando v_i e v_j, independente de sua orientação. Assim, para $i \neq j$, o número de arestas conectando v_i e v_j, independentemente de sua orientação, será dadod por $-m_{ij}^{(2)}$. Finalmente, temos que para grafos orientados

$$MM^T = D^+ + D^- - A - A^t, \tag{1.84}$$

comparem com (1.9). É interessante notar que o lado direito de (1.82) é a matriz Laplaciana do grafo ignorando-se a orientação das arestas! Em particular, esta matriz **não** depende da orientação escolhida para as arestas.

Retornemos agora ao caso das auto-ligações orientadas. No caso não orientado, vimos que a coluna correspondente à auto-ligação tem uma entrada 2 na posição do vértice, e todas as outras são zero. No caso orientado, porém, a situação é diferente. A auto-ligação corresponde a uma coluna com **todas** as entradas nulas. Notem, primeiro, que isto é compatível com a definição (1.81) se exigirmos que as entradas não nulas correspondem às arestas que começam e terminam em vértices diferentes. A questão curiosa é que uma coluna repleta de zeros não irá contribuir para a quantidade MM^t, que de (1.84) sabemos ser igual a matriz Laplaciana do grafo não orientado subjacente, aquele da Fig. 1.9. Em particular, calculando-se (1.84) para o grafo da Fig (1.10) **com e sem** a auto-ligação e_7, obtemos a mesma matriz Laplaciana, que corresponde, de fato, ao grafo da Fig. 1.7. É fácil entender o que está acontecendo. A matriz Laplaciana é **insensível** às auto-ligações! Como as auto-ligações se manifestam como elementos na diagonal de A, eles não contribuem à matriz Laplaciana, como pode ser facilmente demonstrado[14]. Deste fato, conclui-se que dificilmente a matriz Laplaciana será relevante em problemas de grafos, orientados ou não, com auto-ligações. O mesmo se aplica às matrizes de incidência de grafos orientados com auto-ligações. O caso da matriz de adjacência é diferente, pois ela é sensível à existência das auto-ligações. Invocando-se a decomposição (1.11), vemos que a existência de uma auto-ligação orientada num vértice v_i implica que a matriz de adjacência deve ter $a_{ii} = 1$.

Um caminho sobre um grafo orientado G é uma sequência de vértices *compatível* com a orientação das arestas. Um grafo orientado é dito fortemente conexo se dois vértices quaisquer v_i e v_j estiverem conectados por algum caminho. Caso um grafo orientado não seja fortemente conexo, pode-se definir suas componentes fortemente conexas como os subconjuntos maximais vértices de G que são fortemente conexos. Note que esta definição implica que, se v_i e v_j pertencem a uma componente fortemente conexa de G, então existem simultaneamente caminhos de v_i a v_j e de v_j a v_i.

1.4.2 Grafos ponderados

Os grafos ponderados são grafos nos quais suas arestas, sejam elas orientadas ou não, possuem outros atributos, os quais denominaremos simplesmente por "pesos". Estes pesos podem representar custos, distâncias, capacidades ou quaisquer outras grandezas relacionadas ao caminho entre dois vértice do grafo. Por simplicidade, vamos considerar situações nas quais o peso de uma aresta é um número real[15]. Neste caso, as componentes $[a_{ij}]$ da matriz de

[14] Demonstrem!

[15] A generalização para o caso em que os pesos são um conjunto (vetor) de entradas reais é direta.

adjacência A para o grafo ponderado são dadas por

$$a_{ij} = \begin{cases} p_{ij}, & \text{se houver uma aresta } v_i \to v_j \text{ de peso } p_{ij}, \\ 0, & \text{se não houver aresta.} \end{cases} \tag{1.85}$$

A matriz Laplaciana associada é definida de maneira análoga aos casos anteriores, podendo utilizar os graus de saída ou de entrada de cada vértice. O caso de pesos inteiros pode ser sempre interpretado como derivados da existência de mais de uma aresta entre dois vértices. Os pesos são usualmente considerados como quantidades positivas, e um peso nulo corresponderia, de fato, a ausência da aresta.

Há mais de uma definição de matriz de incidência para grafos ponderados. Não empregaremos aqui nenhuma definição em particular. Vamos introduzir a matriz de pesos $W = \operatorname{diag}(p_{e_1}, p_{e_2}, \dots)$, sendo p_{e_i} o peso da aresta e_i. Se M é a matriz de incidência do grafo correspondente sem pesos, a matriz $M' = M\sqrt{W}$ exibe todas as propriedades que esperamos para uma matriz de incidência no caso de grafos ponderados.

1.5 Alguns exemplos e aplicações

Há alguns problemas clássicos e grafos especiais que merecem ser introduzidos. Aproveitaremos esta oportunidade para discutir alguns deles. Começaremos com o espectro de alguns grafos importantes.

1.5.1 Espectro de alguns grafos notáveis

Grafo completo

Denomina-se por K_n o grafo de n vértices com número máximo de arestas, ver Fig. 1.12. É fácil ver que o número de arestas do grafo completo K_n é dado por

$$|E(K_n)| = \binom{n}{2} = \frac{n(n-1)}{2}. \tag{1.86}$$

Além do mais, todos os vértices tem grau $d_i = n - 1$. Trata-se, portanto, de um grafo regular. As matrizes de adjacência e Laplaciana para K_n são, respectivamente

$$A = J - I \tag{1.87}$$

e

$$L = nI - J \tag{1.88}$$

sendo J a matriz $n \times n$ com todas suas entradas iguais a 1. Notem, inicialmente, que se (λ, X) for um autopar de J, sabemos que $(\lambda - 1, X)$ e $(n - \lambda, X)$ serão, respectivamente, autopares de A e de L.

Ocorre que o espectro de J é trivial. Notem, primeiro, que o posto de J é 1, o que implica em $\dim \operatorname{Ker} J = n - 1$, e portanto que 0 é autovalor de J

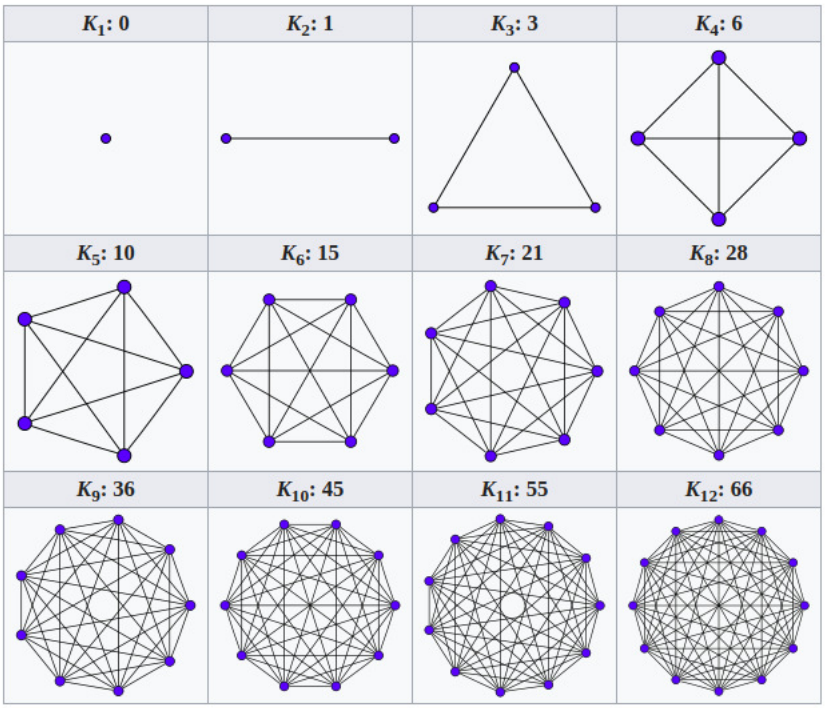

Figura 1.12: Grafos completos K_n, $n = 1, 2, \ldots, 12$, e o respectivo número de arestas $|E(K_n)|$. (Imagem da Wikipedia)

com multiplicidade $n-1$. Falta um autovalor, que pode ser determinado por inspeção: n, que é o autovalor associado ao autovetor $X = (1, 1, \ldots, 1)^t$. Finalmente, temos que os autovalores das matrizes de adjacência e Laplaciana do gráfico completo K_n são, respectivamente,

$$\lambda_1 = n - 1, \quad \lambda_2 = \lambda_3 = \cdots = \lambda_n = -1 \tag{1.89}$$

e

$$\mu_1 = \mu_2 = \cdots = \mu_{n-1} = n, \quad \mu_n = 0. \tag{1.90}$$

Notem que de (1.89) podemos determinar o número de triângulos de K_n e várias outra de suas propriedades. Em particular, como para K_n temos $d_{\max} = d_{\text{avg}} = d_{\min} = n - 1$, vemos que λ_1 já podia ser determinado diretamente a partir do teorema 5 e que μ_{n-1} satura superiormente a desigualdade do teorema 7.

Grafo estrela

Dá-se o nome de estrela a grafos como a da Fig. 1.13. O grafo estrela S_n é um grafo com n vértices e $n - 1$ arestas, sendo que um vértice, o qual

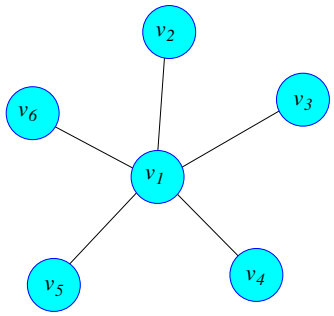

Figura 1.13: Grafo estrela S_6.

sem perda de generalidade consideraremos como sendo v_1, tem grau $n-1$ e todos os outros tem grau 1. Suas matrizes de adjacência e Laplaciana correspondentes são dadas, respectivamente, por

$$A = \begin{pmatrix} 0 & 1 & 1 & \dots & 1 \\ 1 & 0 & 0 & \dots & 0 \\ 1 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & \dots & 0 \end{pmatrix}. \tag{1.91}$$

e

$$L = \begin{pmatrix} n-1 & -1 & -1 & \dots & -1 \\ -1 & 1 & 0 & \dots & 0 \\ -1 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -1 & 0 & 0 & \dots & 1 \end{pmatrix}. \tag{1.92}$$

A primeira observação é que o posto de A é 2, de onde temos que $\dim \operatorname{Ker} A = n-2$ e que 0 é autovalor de A com multiplicidade $n-2$. Faltam dois autovalores para serem descobertos. Uma observação interessante pode nos ajudar com essa tarefa. O grafo estrela S_n é bipartido! Basta escolher $V_1 = \{v_1\}$ e V_2 com os restantes dos vértices de S_n e teremos a bipartição explícita. Isso implica que se λ é autovalor de A, $-\lambda$ também será. Portanto, falta apenas um autovalor para ser determinado, e será λ_1. Uma vez mais, é fácil encontrar este autovalor. Notem primeiro que todo vetor $X \in \operatorname{Ker} A$ deve ter a primeira componente nula. Uma outra observação é que o grafo estrela S_n tem uma série de simetrias (automorfismos) evidentes. Qualquer permutação que não envolva o vértice v_1 é uma simetria de S_n. Como λ_1 tem multiplicidade 1 neste caso, podemos invocar diretamente o Lema 1. Vamos escolher o caso em que o autovalor X é par. Desta forma, um bom candidato a ser o autovetor de A com autovalor $\lambda_1 > 0$ é $X = (a, 1, 1, \dots, 1)^t$,

com $a \neq 0$. Temos

$$AX = \begin{pmatrix} n-1 \\ a \\ \vdots \\ a \end{pmatrix} = a \begin{pmatrix} \frac{n-1}{a} \\ 1 \\ \vdots \\ 1 \end{pmatrix}. \tag{1.93}$$

Vemos que para $a = \sqrt{n-1}$, X será autovetor de A com autovalor $\sqrt{n-1}$. Assim, estabelecemos o espectro da matriz de adjacência para o grafo estrela S_n. Temos

$$\lambda_1 = \sqrt{n-1}, \quad \lambda_2 = \lambda_3 = \lambda_{n-1} = 0, \quad \lambda_n = -\sqrt{n-1}. \tag{1.94}$$

O espectro da matriz Laplaciana também pode ser determinado de maneira elementar. Notem, primeiro, que temos

$$L = N + I \tag{1.95}$$

com

$$N = \begin{pmatrix} n-2 & -1 & -1 & \dots & -1 \\ -1 & 0 & 0 & \dots & 0 \\ -1 & 0 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ -1 & 0 & 0 & \dots & 0 \end{pmatrix}. \tag{1.96}$$

Assim, se determinarmos o espectro da matriz N, teremos determinado também o da matriz Laplaciana L.[16] A matriz N tem posto 2, de onde sabemos que o zero será um de seus autovalores com multiplicidade $n-2$, o que implica que já conhecemos $n-2$ autovalores de L. Falta descobrir apenas um, pois sabemos que qualquer matriz Laplaciana tem sempre pelo menos um autovetor com autovalor nulo. Vamos determinar este autovalor da mesma maneira que fizemos para o caso da matriz de adjacência, testando os vetores $X = (a, 1, 1, \dots, 1)^t$, com $a \neq 0$, já que sabemos que eles serão tais que $X \notin \operatorname{Ker} N$ e têm simetrias compatíveis com as de S_n,

$$NX = \begin{pmatrix} a(n-2) - (n-1) \\ -a \\ \vdots \\ -a \end{pmatrix} = -a \begin{pmatrix} \frac{n-1}{a} - (n-2) \\ 1 \\ \vdots \\ 1 \end{pmatrix}, \tag{1.97}$$

de onde temos duas possibilidades para que X seja autovetor de N: $a = 1$ ou $a = -(n-1)$, o que nos dá finalmente o seguinte espectro para a matriz Laplaciana de S_n

$$\mu_1 = n, \quad \mu_2 = \mu_3 = \dots = \mu_{n-1} = 1, \quad \mu_n = 0. \tag{1.98}$$

[16] Notem que a hipótese $n > 2$ não é tão estranha para um grafo que mereça o nome de "estrela".

Grafo ciclo

Os grafos ciclos C_n, chamado também de grafos circulares ou cíclicos, como o nome sugere, são grafos como o da Fig. 1.14. Todos seus vértices têm grau

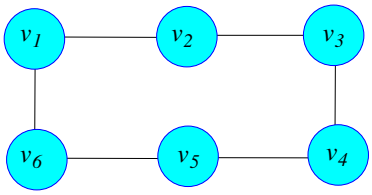

Figura 1.14: Grafo ciclo C_6.

2 e seu número de arestas é sempre igual a n. A matriz de adjacência para um grafo ciclo C_n terá a forma geral

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 & \dots & 0 & 1 \\ 1 & 0 & 1 & 0 & \dots & 0 & 0 \\ 0 & 1 & 0 & 1 & \dots & 0 & 0 \\ 0 & 0 & 1 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 & 1 \\ 1 & 0 & 0 & 0 & \dots & 1 & 0 \end{pmatrix}. \tag{1.99}$$

Para determinarmos o espectro de A, vamos considerar primeiro a matriz Q

$$Q = \begin{pmatrix} 0 & 1 & 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & 1 & 0 & \dots & 0 & 0 \\ 0 & 0 & 0 & 1 & \dots & 0 & 0 \\ 0 & 0 & 0 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \dots & 0 & 1 \\ 1 & 0 & 0 & 0 & \dots & 0 & 0 \end{pmatrix}, \tag{1.100}$$

que é diagonalizável em $\mathbb{C}$. Sua estrutura de permutação cíclica sugere que podemos procurar seus autovetores na forma $X = (1, \zeta, \zeta^2, \dots, \zeta^{n-1})^t$, com $\zeta \in \mathbb{C}$. Temos

$$QX = \begin{pmatrix} \zeta \\ \zeta^2 \\ \zeta^3 \\ \vdots \\ \zeta^{n-1} \\ 1 \end{pmatrix} = \zeta \begin{pmatrix} 1 \\ \zeta \\ \zeta^2 \\ \vdots \\ \zeta^{n-2} \\ \zeta^{-1} \end{pmatrix} \tag{1.101}$$

de onde temos que a condição $\zeta^n = 1$ nos garante que X é autovetor de Q com autovalor ζ. Em outra palavras, os autovalores serão as n raízes complexas da unidade, $\zeta_k = e^{\frac{2k\pi i}{n}}$, $k = 0, 1, \ldots, n-1$. Por outro lado, temos também

$$Q^t X = \begin{pmatrix} \zeta^{n-1} \\ 1 \\ \zeta \\ \vdots \\ \zeta^{n-2} \end{pmatrix} = \zeta^{-1} \begin{pmatrix} \zeta^{n} \\ \zeta \\ \zeta^{2} \\ \vdots \\ \zeta^{n-1} \end{pmatrix}, \tag{1.102}$$

de onde temos que Q^t tem os mesmos autovetores que Q, com autovalores correspondentes à ζ^{-1}. Porém, como $A = Q + Q^t$ temos que os autovalores de A serão

$$\lambda = \left\{ \zeta_k + \zeta_k^{-1} = 2\Re\zeta_k = 2\cos\frac{2k\pi}{n}, \quad k = 0, 1, \ldots, n-1 \right\}. \tag{1.103}$$

Discutiremos o ordenamento dos autovalores λ a seguir. O espectro da matriz Laplaciana de C_n segue diretamente deste resultado. Como para C_n temos $L = 2I - A$, teremos que se λ é autovalor de A, $\mu = 2 - \lambda$ será autovalor de L.

Podemos obter o ordenamento dos autovalores λ e μ a partir das propriedades elementares das raízes complexas da unidade, como representado na Fig. 1.15. Primeiro, notem que $\Re\zeta_0 = 1$ para qualquer n. Para n pares,

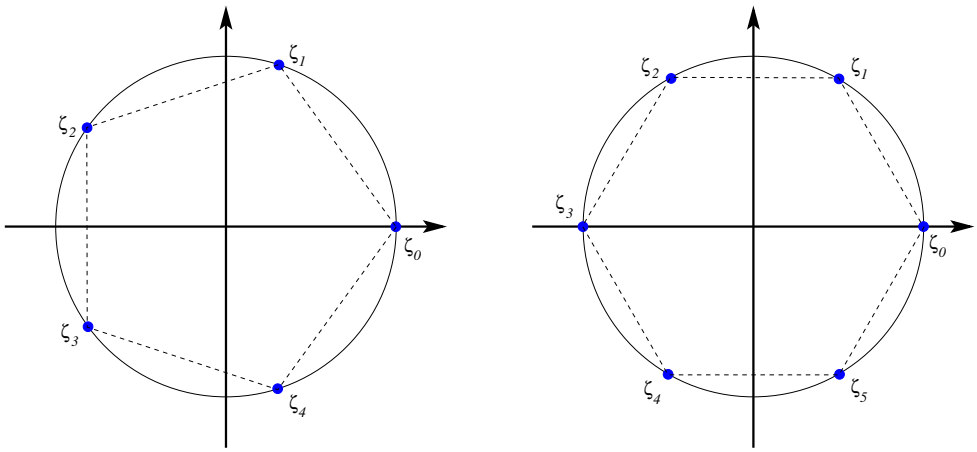

Figura 1.15: Raízes complexas da unidade $\zeta^n = 1$ para n ímpares e pares.

$\Re\zeta_{\frac{n}{2}} = -1$. Para todo n, temos $\Re\zeta_i = \Re\zeta_{n-i}$, com $i = 1, 2, \ldots, \left\lfloor \frac{n}{2} \right\rfloor$. Assim, podemos finalmente ordenar os autovalores λ de A para C_n. Teremos para n ímpar

$$\lambda_1 = 2, \quad \lambda_{k+1} = 2\cos\frac{2k\pi}{n}, \quad k = 1, 2, \ldots, \left\lfloor \frac{n}{2} \right\rfloor, \tag{1.104}$$

sendo que, com exceção de λ_1, todos autovalores têm multiplicidade 2. De maneira análoga, para n par[17], teremos

$$\lambda_1 = 2, \quad \lambda_{k+1} = 2\cos\frac{2k\pi}{n}, \quad k = 1, 2, \ldots, \frac{n}{2} - 1, \quad \lambda_n = -2, \tag{1.105}$$

sendo que todos autovalores têm multiplicidade 2, exceto λ_1 e λ_n. Notem que $\lambda_1 = d_{\text{avg}} = d_{\max} = 2$, já que C_n é um grafo regular, *i.e.*, um grafo no qual todos os vértices tem o mesmo grau.

O espectro da matriz Laplaciana de C_n vem diretamente de (1.104) e (1.105). Temos, sem nos preocupar com ordenamento,

$$\mu = \left\{ 2 - 2\cos\frac{2k\pi}{n} = 4\sin^2\frac{k\pi}{n}, \quad k = 0, 2, \ldots, n-1 \right\}. \tag{1.106}$$

Como esperado, temos $\mu_n = 0$. Para n pares, temos $\mu_1 = 4$, sendo este um caso interessante que satura a desigualdade para o máximo autovalor do teorema 7.

Grafo caminho

Dá-se o nome de grafo caminho, ou grafo linear, a um grafo árvore (sem ciclos) que só possui vértices com grau 2 e 1, sendo os de grau 1 as extremidades. Os grafos caminhos serão sempre denotados por P_n. Vejam um exemplo na Fig. 1.16. A matriz de adjacência para um grafo P_n será sempre

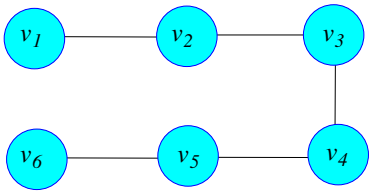

Figura 1.16: Grafo caminho P_6.

do tipo

$$A = \begin{pmatrix} 0 & 1 & 0 & 0 & \ldots & 0 & 0 \\ 1 & 0 & 1 & 0 & \ldots & 0 & 0 \\ 0 & 1 & 0 & 1 & \ldots & 0 & 0 \\ 0 & 0 & 1 & 0 & \ldots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \ldots & 0 & 1 \\ 0 & 0 & 0 & 0 & \ldots & 1 & 0 \end{pmatrix}, \tag{1.107}$$

que lembra bastante a matriz de adjacência (1.99) do grafo ciclo C_n. Vamos determinar o espectro de (1.107) explorando apenas noções de grafos.

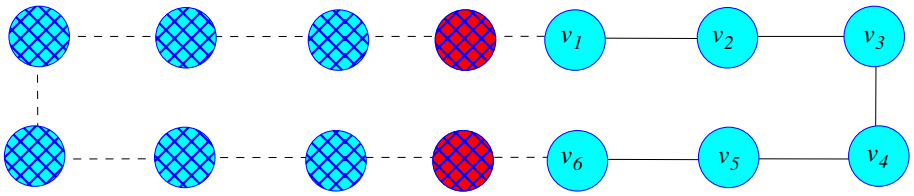

Figura 1.17: O grafo P_6 como um subconjunto de C_{14}: primeiro, faça uma cópia de P_6. Insira dois novos vértices e os conecte as extremidades de P_6 e de sua cópia. O resultado será um grafo C_{14}.

Primeiro, notem que sempre podemos considerar $P_n \subset C_{2n+2}$, vejam a Fig. 1.17 para uma ilustração deste fato. Já conhecemos o espectro da matriz de adjacência para C_{2n+2}, ele é completamente determinado pelas raízes complexas da unidade $\zeta^{2n+2} = 1$. Veremos que podemos determinar o espectro para o caso P_n a partir da construção da Fig. 1.17. Para isto, vamos olhar com um pouco mais de cuidado o sentido da expressão AX para um certo vetor X.

Podemos interpretar um vetor $X = (x^{(1)}, x^{(2)}, \ldots, x^{(n)})^t$ no contexto de um grafo como certas quantidade associadas aos vértices, *i.e.*, cada componente $x^{(i)}$ estará associada ao vértice v_i do grafo subjacente. Suponha um vetor X com todas as entradas nulas, exceto $x^{(k)} = \alpha$. O produto AX

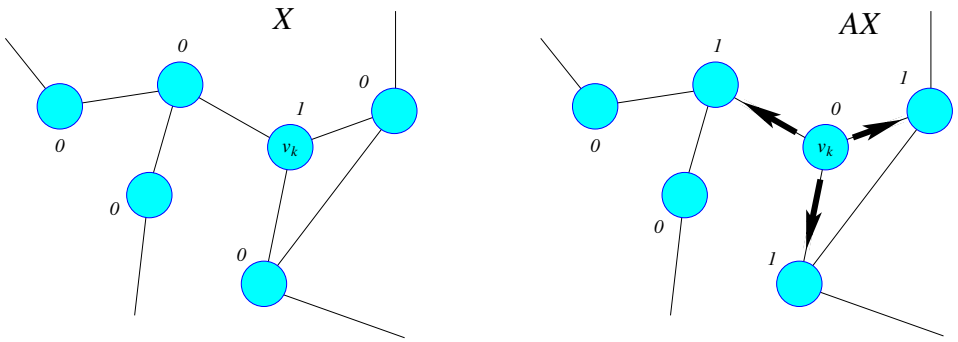

Figura 1.18: O produto AX como a "propagação" das componentes do vetor X sobre o grafo.

também será um vetor. Suas componente serão dadas por α para todos os vértices que compartem aresta com v_k, e zero para todos os outros vértices. Podemos interpretar AX como uma "propagação" das componentes do vetor X ao longo das arestas do grafo, ver Fig. 1.18. Considere agora um certo grafo G com uma matriz de adjacência A_G, e um outro grafo H obtido a

[17]Para n par, o grafo C_n é sempre bipartido.

partir de G eliminando-se todas as arestas de um certo vértice v_k. Sua matriz de adjacência será A_H. O ponto importante é que se $x^{(k)} = 0$ teremos sempre $A_G X = A_H X$. Em particular, se X for um autovetor de A_G com $x^{(k)} = 0$ e autovalor λ, será também um autovetor de A_H, com o mesmo autovalor.

Retornemos agora ao problema do espectro de (1.107). Da seção anterior, sabemos que os autovetores da matriz de adjacência de C_{2n+2} são da forma $X(\zeta) = (1, \zeta, \zeta^2, \ldots \zeta^{2n+1})^t$, com $\zeta^{2n+2} = 1$. Os autovalores correspondentes serão $\lambda(\zeta) = \zeta + \zeta^{-1}$. Notem que $X(\zeta)$ e $X(\zeta^{-1})$, por construção, são ambos autovetores com o mesmo autovalor. Considerem agora uma das raízes da unidade ζ_k e o vetor $Y_k = X(\zeta_k) - X(\zeta_k^{-1})$, o qual, caso não seja nulo, também será autovetor com autovalor $\lambda(\zeta_k) = \zeta_k + \zeta_k^{-1}$. Por construção, já sabemos que $y_k^{(1)} = 0$. As outras componentes serão

$$y_k^{(\ell+1)} = \zeta_k^{\ell} - \zeta_k^{-\ell} = 2i\Im\zeta_k^{\ell} = 2i \sin \frac{k\ell\pi}{n+1}, \quad \ell = 1, 2, \ldots, 2n+1. \tag{1.108}$$

Note que para $k = 0$ e para $k = n+1$, temos todas as componentes nulas, portanto as raízes ζ_0 e ζ_{n+1} da unidade não nos interessam. Porém, para qualquer outro valor de k, teremos sempre $Y_k \neq 0$ com $y^{(n+2)} = 0$, *i.e.*, os pares $\left(2\cos\frac{k\pi}{n+1}, Y_k\right)$, com $k = 1, 2, \ldots, n$, são sempre autopares da matriz de adjacência de C_{2n+2} com $y^{(1)} = y^{(n+2)} = 0$.

Voltemos agora a construção do grafo C_{2n+2} tal que $P_n \subset C_{2n+2}$. Podemos, sem perda de generalidade, numerar os vértices de tal maneira que v_1 e v_{n+2} sejam os vértices vermelhos na construção da Fig. 1.17. Ora, já sabemos que Y_k será também autovetor, com os mesmos autovalores, da matriz de adjacência que corresponde ao grafo C_{2n+2} com as arestas de v_1 e v_{n+2} eliminadas, que corresponde a um grafo desconexo, com duas partes conexas idênticas a P_n e dois vértices livres. Acabamos de mostrar que o espectro da matriz de adjacência (1.107) é, sem nos importar com ordenamento,

$$\lambda = \left\{2\cos\frac{k\pi}{n+1}\right\}, \quad k = 1, 2, \ldots, n. \tag{1.109}$$

Podemos determinar o espectro da matriz Laplaciana L de P_n com argumentos semelhantes. Para isto, vamos interpretar o significado no contexto de grafos do produto LX para um certo vetor X. Notem, primeiro, que qualquer matriz Laplaciana pode ser decomposta como

$$L = \sum_{e(v_i, v_j)} L_{(v_i, v_j)}, \tag{1.110}$$

sendo o somatório feito sobre todas as arestas $e(v_i, v_j)$ do grafo e $L_{(v_i, v_j)}$ corresponde à matriz Laplaciana elementar do grafo que contém uma única aresta entre os vértices v_i e v_j. Notem que $L_{(v_i, v_j)}X$ é um vetor com todas

entradas nulas, exceto a i-ésima e a j-ésima, que serão, respectivamente, $x^{(i)}-x^{(j)}$ e $x^{(j)}-x^{(i)}$. Suponha agora um grafo G com matriz Laplaciana L_G, e um outro grafo H, obtido a partir de G eliminando-se um certo conjunto de arestas $e(v_i, v_j)$ de G, cuja matriz Laplaciana é L_H. Considere agora um vetor X tal que $x^{(i)} = x^{(j)}$ para todos vértices i e j que correspondam as arestas eliminadas de G. Teremos $L_G X = L_H X$, implicando que se X com essa propriedade for autovetor de L_G, será também autovetor de L_H, com o mesmo autovalor. Este é o ponto fundamental de nossa análise. Vamos

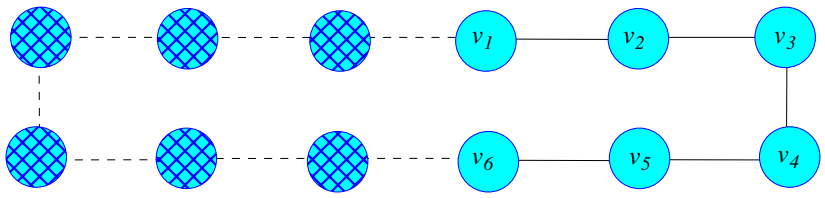

Figura 1.19: O grafo P_6 como um subconjunto de C_{12}: faça uma cópia de P_6 e conecte suas extremidades.

agora explorar o fato que $P_n \subset C_{2n}$, veja Fig. 1.19 . Os autopares de C_{2n} são $\left(2-\zeta_k-\zeta_k^{-1}, X(\zeta_k)\right)$, sendo ζ_k uma das raízes da unidade $\zeta^{2n} = 1$. Vamos considerar agora o vetor $Y_k = X(\zeta_k) + X(\zeta_k^{-1})$, que será também um autovetor de L para o grafo C_{2n}, também com autovalor $2-\zeta_k-\zeta_k^{-1}$. As componentes de Y_k serão

$$y_k^{(\ell+1)} = \zeta_k^{\ell} + \zeta_k^{-\ell} = 2\cos\frac{k\ell\pi}{n}, \quad \ell, k = 0, 1, 2, \ldots, 2n-1. \tag{1.111}$$

O caso $k = 0$ nos dá o autovetor com autovalor nulo, *i.e.*, todas as componentes de Y_0 são iguais. Notem que para qualquer outro k par, teremos sempre $y_k^{(\ell+1)} = y_k^{(\ell+n+1)}$, para $\ell = 0, 1, \ldots n-1$. Finalmente, vemos que $\left(2-2\cos\frac{k\pi}{n}, Y_{2k}\right)$ são autopares da matriz Laplaciana de C_{2n} com essa curiosa propriedade: a j-esima entrada de Y_{2k}, com $j > n$, é igual a entrada $j-n$. De maneira semelhante ao caso da matriz de adjacência, podemos numerar os vértices de C_{2n} de maneira conveniente para que Y_{2k} seja também o autovalor de um grafo desconexo correspondente a eliminação, por exemplo, das duas arestas centrais da Fig. 1.19, dando origem a um grafo composto por duas partes P_n. Desta maneira, acabamos de determinar o espectro da matriz Laplaciana de P_n. Sem nos preocuparmos com ordenação, temos

$$\mu = \left\{2-2\cos\frac{k\pi}{n} = 4\sin^2\frac{k\pi}{2n}, \quad k = 0, 2, \ldots, n-1\right\}. \tag{1.112}$$

1.5.2 Grafos regulares: algumas propriedades métricas

Grafos regulares são grafos tais que todos seus vértices têm o mesmo grau. O grafo completo K_n e o ciclo C_n são exemplos de grafos regulares com graus,

respectivamente, dados por $n-1$ e 2. Notem que 2 é o grau mínimo para um grafo regular conexo com $n > 2$. Para grafos regulares de grau k, o maior autovalor da matriz de adjacência será $\lambda_1 = k$. O espectro completo, tanto da matriz de adjacência como da Laplaciana, vai depender dos detalhes do grafo.

Vamos nos ocupar aqui de algumas propriedades métricas interessantes para grafos regulares. Especificamente, examinaremos seu raio, a partir do qual podemos inferir seu diâmetro e distâncias médias. Vamos denotar por G_k um grafo regular com grau k, chamado também de grafo k-regular. Consideremos a bola da definição 4 de raio m em torno de um vértice qualquer $v \in V(G_k)$ de um grafo k-regular de n vértices. Dá Fig. 1.20, teremos a

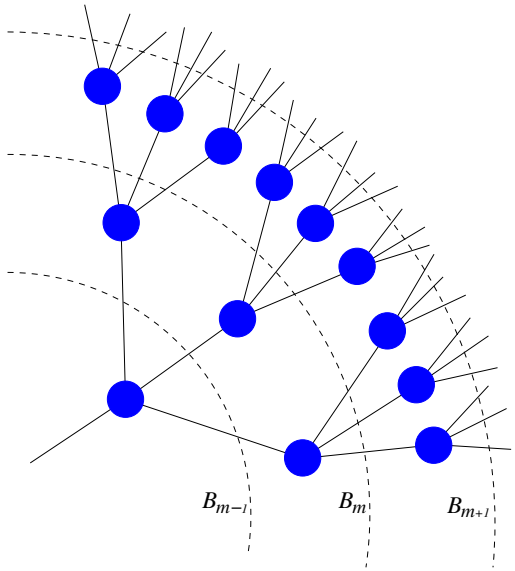

Figura 1.20: Figura esquemática das bolas B_m para um grafo regular com $k = 4$ saturando a desigualdade (1.113). Notem que até a bola B_{m+1}, trata-se de uma árvore. Eventuais ciclos só aparecerão nas bolas mais externas.

seguinte desigualdade para $b_m = |B_m(v)|$

$$b_{m+1} \leq (k-1)(b_m - b_{m-1}) + b_m = kb_m - (k-1)b_{m-1}. \tag{1.113}$$

Esta desigualdade, que é saturada exatamente para as configurações como a da Fig. 1.20, envolve uma equação a diferenças finitas linear de segunda ordem. Podemos resolvê-la explorando o seguinte lema.

Lema 2 (Gronwall para o caso discreto) *Sejam* $\{u_m\}$ *,* $\{f_m\}$ *e* $\{g_m\}$ *sequências não negativas tais que*

$$u_{m+1} \leq g_m u_m + f_m, \tag{1.114}$$

para $m \geq 0$*, com* u_0 *dado. Então*

$$u_m \leq u_m^*,$$

sendo u_m^* *a solução da equação que satura (1.114) com* $u_0^* = u_0$*.*

Para provarmos este lema, vamos considerar inicialmente a solução geral da equação que satura (1.114) com condição inicial $u_0^* = u_0$. De maneira geral, teremos

$$u_m^* = (u_0 - u_1^P)u_m^H + u_m^P, \tag{1.115}$$

sendo u_m^H e u_m^P, respectivamente, a solução da equação homogênea associada a (1.114), com $u_1^H = 1$, e uma solução particular qualquer da equação que satura (1.114). Consideremos agora a sequência v_m tal que $u_m = v_m + u_m^P$. Substituindo-se em (1.114), temos

$$v_{m+1} \leq g_m v_m. \tag{1.116}$$

Agora, introduzindo-se $v_m = c_m u_m^H$, teremos

$$(c_{m+1} - c_m)u_{m+1}^H \leq 0. \tag{1.117}$$

Como todas as sequências pertinentes são não negativos, podemos admitir que também u_m^H é não negativa, o que implica de (1.117) que c_m é não crescente e, em particular, $c_m \leq c_0$, o que finalmente nos fornece

$$u_m \leq c_0 u_m^H + u_m^P. \tag{1.118}$$

Porém, $c_0 = u_0 - u_1^P$, de onde finalmente temos o resultado do Lema 2.

Para resolver (1.113), note primeiro que, introduzindo-se a sequência não negativa $c_m = b_m - b_{m-1}$, temos

$$c_{m+1} \leq (k-1)c_m, \tag{1.119}$$

e o Lema 2 nos garante que

$$b_m \leq \alpha_0(k-1)^m + b_{m-1}. \tag{1.120}$$

Para o caso[18] $k > 2$, uma nova aplicação do Lema 2 nos fornece

$$b_m \leq \alpha_1(k-1)^m + \alpha_2. \tag{1.121}$$

[18] O caso $k = 2$ será tratado em separado.

As constantes α_1 e α_2 devem ser determinadas a partir das condições inicias. Lembrando que a configuração que deve saturar a desigualdade é o da Fig. 1.20, devemos ter $b_0 = 1$ e $b_1 = k + 1$, como pode-se ver diretamente da definição da bola 4. Teremos finalmente a seguinte solução

$$b_m \leq \frac{k(k-1)^m - 2}{k-2} \tag{1.122}$$

para a desigualdade (1.113). Podemos agora estimar o raio e o diâmetro do grafo G_k. Da definição 5, temos que $\text{raio}(G_k) = m$, sendo m o raio da menor bola que contém todos os vértices de G, de onde podemos estimar $\text{raio}(G_k)$ como

$$\frac{k(k-1)^{\text{raio}(G_k)} - 2}{k-2} \geq n, \tag{1.123}$$

o que nos fornece

$$\text{raio}(G_k) \geq \log_{k-1} n + \log_{k-1}\left(\frac{k-2}{k} + \frac{2}{nk}\right) > \log_{k-1} n, \tag{1.124}$$

sendo que a última desigualdade supõe $n > 1$. Deve-se frisar que o limite inferior para o raio (1.124) corresponde especificamente à configuração da Fig. 1.20, para a qual as bolas crescem da maneira mais rápida possível. Este resultado pode ser formulados como o seguinte teorema.

Teorema 9 *Seja G_k um grafo k-regular, $k > 2$, com n vértices. Seu raio é tal que*

$$\text{raio}(G_k) > \log_{k-1} n.$$

Este teorema merece alguns comentários. O caso $k = 2$ corresponde ao grafo ciclo C_n, e neste caso nossa abordagem não se aplica. Obviamente, neste caso sempre temos $\text{raio}(C_n) = \left\lfloor \frac{n}{2} \right\rfloor$. A desigualdade (1.113) é, para $k = 2$, uma igualdade cuja solução geral é

$$b_m = \alpha_1 m + \alpha_2. \tag{1.125}$$

As condições iniciais pertinentes são $b_0 = 1$ e $b_1 = 3$, que implicam finalmente em

$$b_m = 2m + 1 \tag{1.126}$$

de onde o raio $\text{raio}(C_n)$ pode ser diretamente determinado.

Para ilustrar o teorema 9, tomemos o caso de um grafo G_{11} com 1 milhão de vértices. Na configuração da Fig. 1.20, que satura a desigualdade (1.113), o milhão de vértices estão, efetivamente, dentro de uma bola de "seis passos". Grafos regulares podem efetivamente exibir comportamento do tipo *small world*, mas veremos adiante que podemos propor configurações ainda melhores.

Uma vez estimado o raio de um grafo, podemos avaliar seus diâmetro a partir da desigualdade (1.35). O raio e o diâmetro diferirão, no máximo, por um fator 2. No caso específico do grafo da Fig. 1.20, teremos $\mathrm{diam}(G_k) = 2\,\mathrm{raio}(G_k)$.

1.5.3 Passeios Eulerianos e caminhos Hamiltonianos

O famoso problema das 7 pontes de Königsberg, resolvido por Euler, é considerado como o problema que fundou a teoria de grafos. No século XVIII, a então cidade alemã de Königsberg, cortada pelo rio Pregel, se dividia em quatro regiões unidas por 7 pontes como mostra a Fig. 1.21. Denominaremos

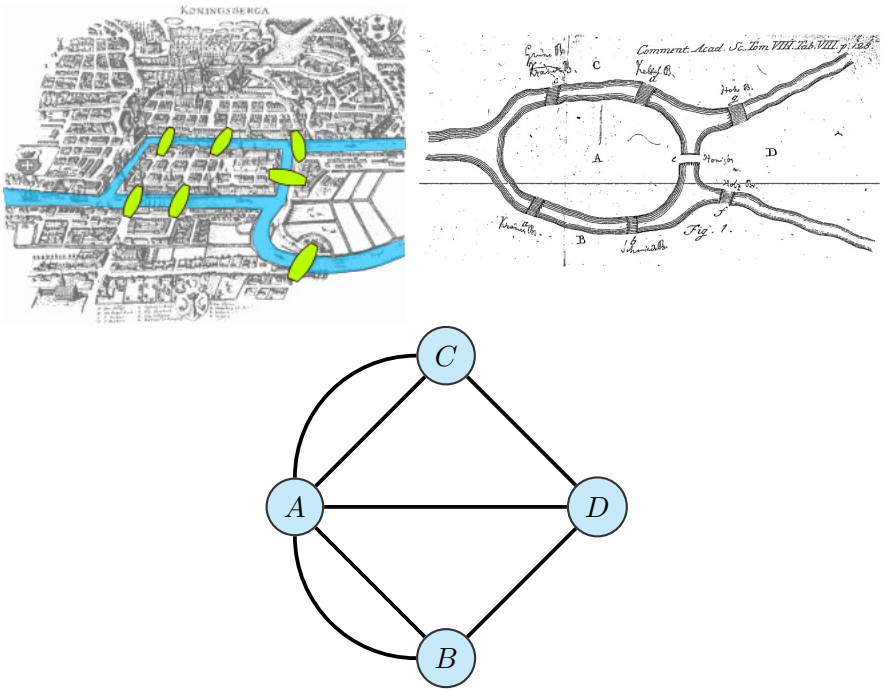

Figura 1.21: O célebre problema da 7 pontes de Königsberg. Acima: a direita, a geografia (potamologia) da cidade no século XVIII; à esquerda, esboço de Euler para o problema. Abaixo: o grafo associado às conexões das pontes.

regiões 1 a 4 e o grafo representa a conexão destas regiões via as 7 pontes. O problema das 7 pontes de de Königsberg corresponde a seguinte questão: existe algum caminho pela cidade cruzando todas as pontes uma única vez? A solução de Euler a este problema (a resposta é não) inaugura a teoria de grafos moderna.

Um passeio Euleriano é um passeio que visita todas as arestas do grafo uma única vez. Se o passeio for fechado, é denominado como ciclo Euleriano.

Um grafo Euleriano é um grafo que admite ciclos Eulerianos. Assim, o problema das 7 pontes de de Königsberg, em linguagem atual, corresponde a perguntar se o grafo da Fig. 1.21 admite um passeio Euleriano. A resposta a este problema começa com o seguinte teorema.

Teorema 10 (Euler) *Um grafo (não orientado) conexo admite um ciclo Euleriano se, e somente se, todos seus vértices tiverem grau par.*

Comecemos provando que ter todos os vértices com grau par é condição necessária para a existência do ciclo de Euler. É uma prova simples. Supondo que o ciclo exista, temos que ao chegarmos num certo vértice, devemos necessariamente sair por uma aresta diferente da que chegamos. Isso significa que cada vez que o vértice é visitado pelo passeio, devemos ter um par de arestas livres, uma para a chegada ao vértice, outra para a saída, de onde temos que todos os vértices devem ter grau par. Notem que, para o caso de passeios Eulerianos que não são ciclos, temos exatamente a mesma situação para todos os vértices, excetuando-se o primeiro e o último, que necessariamente terão um número impar de arestas incidentes, pois há as arestas do primeiro e do último passo do passeio. Isto já é suficiente para responder, negativamente, o problema das 7 pontes de de Königsberg. Uma condição necessária para um grafo conexo admitir um passeio Euleriano é que ele tenha apenas dois vértices (o primeiro e último do passeio) com graus ímpares, e o grafo das 7 pontes da Fig. 1.21 tem os 4 vértices com grau ímpar[19].

Provar que ter todos os vértices com grau par é condição suficiente para o teorema é uma tarefa um pouco mais elaborada. Provaremos mostrando como construir explicitamente um ciclo Euleriano para um grafo conexo com todos os vértices de graus pares. O algoritmo para a construção do ciclo é o seguinte. Escolhe-se aleatoriamente um vértice $v_k \in G$ e inicia-se um passeio escolhendo-se aleatoriamente as arestas adjacentes de cada vértice do passeio, de tal maneira que cada aresta é visitada uma única vez. Uma boa maneira de se visualizar o funcionamento deste algoritmo é considerar que cada aresta visitada é eliminada do grafo, ver Fig. 1.22. A primeira observação é que este passeio *sempre* irá terminar em v_k. Isto pode ser provado lembrando-se que como todos os vértices tem grau par, ao chegarmos num certo vértice, sempre haverá uma aresta disponível para sairmos. Assim, este passeio nunca poderá terminar em nenhum vértice que não seja o vértice inicial v_k. Concluído o ciclo, temos duas possibilidades: caso todas as arestas tenham sido eliminadas, o ciclo é Euleriano. Caso ainda restem arestas no grafo, o grafo remanescente (que não precisa ser conexo) tem também todos os vértices com graus pares e, portanto, podemos re-executar o algoritmo para cada uma de suas partes conexas. Como o grafo é finito, temos que após um número finito de execuções do algoritmo, terminaremos com um grafo

[19] Eliminem a aresta (A, D) e vejam que é muito fácil encontrar um passeio Euleriano!

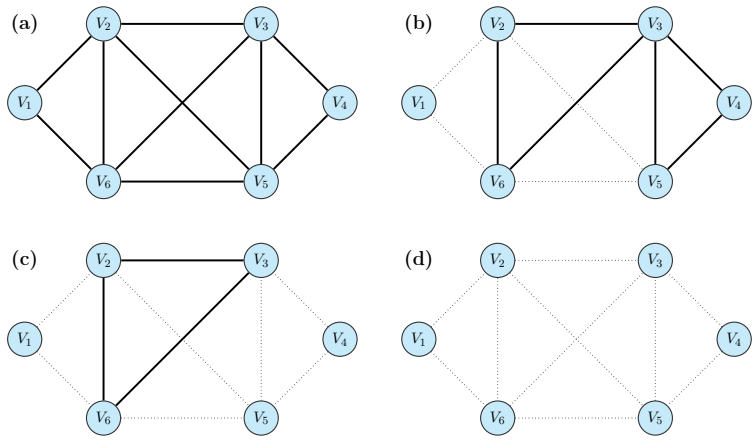

Figura 1.22: Algoritmo para construir ciclos Eulerianos em um grafo com todos os vértices de grau par, como por exemplo o grafo (a). Primeira execução do algoritmo: escolhe-se aleatoriamente um vértice, por exemplo v_1, e fazemos um passeio começando em v_1 até que ele retorne a este mesmo vértice, eliminando-se as arestas visitadas (caminho caminho $\{v_1, v_2, v_5, v_6, v_1\}$) dando origem ao grafo (b). Repete-se o algoritmo para as arestas remanescentes dando origem grafo (c), e uma última vez, dando origem ao grafo (d) sem nenhuma aresta.

sem nenhum aresta restante. Cada execução do algoritmo nos fornece um passeio fechado com vértices em comum com os ciclos obtidos anteriormente. Por exemplo, no caso da Fig. 1.22, cada execução do algoritmo nos dá os passeios $P_1 = \{v_1, v_2, v_5, v_6, v_1\}$, $P_2 = \{v_3, v_4, v_5, v_3\}$ e $P_3 = \{v_2, v_3, v_6, v_2\}$. Estes três passeios podem ser combinados no seguinte ciclo Euleriano

$$C = \{v_1, \underbrace{v_2, v_3, v_6, v_2}_{P_3}, \underbrace{v_5, v_3, v_4, v_5}_{P_2}, v_6, v_1\}. \tag{1.127}$$

A ideia é simples. Escolhemos um passeio obtido pelo algorítimo, e "insertamos" os outros passeios nos pontos em comum, dando origem a um ciclo Euleriano.

A extensão destes resultados para grafos orientados é relativamente simples. Teremos o seguinte teorema, que pode ser provado seguindo-se as mesmas linhas do caso não-orientado.

Teorema 11 *Um grafo orientado conexo admite um ciclo Euleriano se, e somente se, todos seus vértices tiverem graus de entrada e saída iguais.*

Um problema da mesma categoria dos passeios Eulerianos é o problema dos caminhos Hamiltonianos. Um caminho Hamiltoniano sobre um grafo é

um caminho que passa uma única vez sobre todos seus vértices. Um ciclo Hamiltoniano é um caminho Hamiltoniano que começa e termina no mesmo vértice. Um grafo é dito Hamiltoniano se ele admite um ciclo Hamiltoniano. A teoria dos caminhos Hamiltonianos é bastante mais complexa que a dos passeios Eulerianos, em particular não há nenhum teorema simples que estabeleça condições necessárias e suficientes para que um grafo seja Hamiltoniano.

1.5.4 Problemas 2SAT e grafos orientados

O problema de satisfatibilidade booliana (SAT) é um interessante problema de decisão com inúmeras aplicações. Como o nome sugere, trata-se de um problema envolvendo variáveis boolianas, *i.e.*, variáveis que têm apenas dois possíveis valores (também chamados estados): verdadeiro (também denotado "V" ou 1) ou falso ("F" ou 0). O problema SAT, de maneira bastante geral, pode ser formulado da seguinte maneira.

> Dada uma expressão envolvendo operações lógicas – AND ($\wedge$), OR ($\vee$), NOT ($\neg$), etc... – sobre variáveis boolianas $x_1, x_2, \ldots, x_n$, determine para que valores das variáveis a expressão é satisfeita (é verdadeira).

Dizemos que a expressão é "satisfatível" sempre que ela puder ser verdadeira, e "não-satisfatível" quando não houver nenhuma combinação de variáveis boolianas para as quais a expressão (chamada também neste contexto de instância) for verdadeira. Alguns exemplos explícitos vão ajudar a esclarecer a natureza de um problema SAT. Considerem a seguinte expressão (ou instância)

$$E = (x_1 \wedge x_2 \wedge \neg x_3) \vee x_1 \vee \neg x_4. \tag{1.128}$$

É evidente que para termos $E = 1$ necessitamos $x_1 = x_2 = 1$, $x_3 = 0$ e qualquer valor para x_4. A instância E é satisfatível e, além disso, há mais de uma solução para este problema SAT, *i.e.*, mais de um conjunto de valores para as variáveis boolianas tais que a expressão é satisfeita. Já a expressão

$$E = x_1 \wedge \neg x_1 \tag{1.129}$$

não admite nenhuma solução para $E = 1$, *i.e.*, não há nenhum estado da única variável x_1 tal que a expressão seja satisfeita, *i.e.*, teremos $E = 0$ tanto para $x_1 = 0$ como para $x_1 = 1$.

Os problemas 2SAT são uma classe particular dos problemas SAT na qual a expressão a ser satisfeita é composta por conjunções ($\wedge$) de disjunções ($\vee$) de apenas duas variáveis boolianas. Os problemas 3SAT são definidos de maneira análoga, mas com disjunções de três variáveis. O caso de k variáveis é chamado kSAT. Iremos nos ocuparemos aqui apenas dos problemas 2SAT, pois estes têm uma interessante conexão com a teoria de grafos. Do ponto de vista computacional, os problemas 2SAT são relativamente simples.

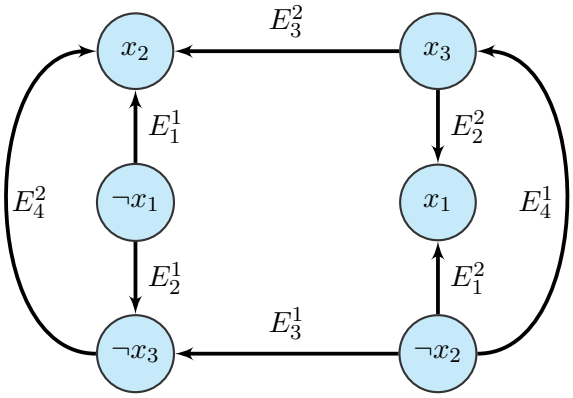

Figura 1.23: Grafo de implicações da instância 2SAT (1.130)-(1.131), com vértices e arestas identificados.

Grafo de implicações

Os problemas 2SAT possuem uma interessante estrutura de grafo orientado. Dado um problema 2SAT com n variáveis boolianas $(x_1, x_2, \ldots, x_n)$, define-se o chamado grafo de implicações como sendo o grafo orientado G com $2n$ vértices, os quais denominaremos por $V = (x_1, \neg x_1, x_2, \neg x_2, \ldots, x_n, \neg x_n)$. As arestas do grafo de implicações são definidas a partir das implicações lógicas de cada uma das disjunções da instância E. Tomemos como exemplo a instância

$$E = E_1 \wedge E_2 \wedge E_3 \wedge E_4, \tag{1.130}$$

com

$$\begin{aligned} E_1 &= (x_1 \vee x_2), \quad & E_2 &= (x_1 \vee \neg x_3), \\ E_3 &= (x_2 \vee \neg x_3), \quad & E_4 &= (x_2 \vee x_3). \end{aligned} \tag{1.131}$$

Considerem a primeira disjunção da instância, $E_1 = (x_1 \vee x_2)$. Ela será falsa se, e somente se, $x_1 = x_2 = 0$. Há, portanto, três possibilidades para que ele seja verdadeira: $x_1 = 1$ e $x_2 = 0$, $x_1 = 0$ e $x_2 = 1$, e $x_1 = x_2 = 1$. Do ponto de vista de implicação lógica, precisamos para ter $(x_1 \vee x_2) = 1$ que $\neg x_1 \Rightarrow x_2$ ou $\neg x_2 \Rightarrow x_1$. Estas implicações devem ser lidas da seguinte forma: $A \Rightarrow B$, "A implica B", significando que, se $A = 1$, teremos $B = 1$. Note que se $A \Rightarrow B$, temos sempre $\neg B \Rightarrow \neg A$. Nenhuma outra implicação lógica é necessária para termos $(x_1 \vee x_2) = 1$. Cada disjunção numa instância 2SAT nos dará sempre 2 implicações lógicas com as quais definiremos duas arestas no grafo G. Neste caso em particular, são as arestas direcionais $E_1^1 = (\neg x_1, x_2)$ e $E_1^2 = (\neg x_2, x_1)$. O grafo de implicações da instância 2SAT (1.130)-(1.131) está representado na Fig. 1.23. A utilidade do grafo de implicações para os problemas 2SAT vem do seguinte teorema.

Teorema 12 *Um problema 2SAT terá soluções se e somente se nenhuma componente fortemente conexa do grafo de implicações associado contiver simultaneamente os vértices associados a uma variável x_k e a sua negação $\neg x_k$.*

Comecemos a prova mostrando que a ausência de partes fortemente conexas do grafo contendo simultaneamente x_k e $\neg x_k$ é condição necessária. A prova é simples. As implicações lógicas são transitivas, *i.e.*, se $A \Rightarrow B$ e $B \Rightarrow C$, então $A \Rightarrow C$. Assim, os caminhos ao longo do grafo de implicações marcam variáveis que serão verdadeiras caso o caminho se inicie numa variável verdadeira. Se x_k e $\neg x_k$ estão numa mesma componente fortemente conexa, então teremos simultaneamente $x_k \Rightarrow \neg x_k$ e $\neg x_k \Rightarrow x_k$, o que não tem solução, e portanto o problema 2SAT como um todo não terá solução. É importante termos as duas condições. Se houver, por exemplo, um caminho conectando x_k a $\neg x_k$ mas não no sentido contrário, teremos a implicação $x_k \Rightarrow \neg x_k$, que não oferece problemas se $x_k = 0$, já que nesse caso não há efetivamente nenhuma implicação sobre $\neg x_k$.

Vamos provar que a condição é suficiente exibindo um algoritmo para encontrar uma solução do problema caso não haja partes fortemente conexas do grafo contendo simultaneamente x_k e $\neg x_k$. Vamos ilustrar o algoritmo com o grafo (1.23). O algoritmo requer um novo conceito.

Ordem topológica em grafos orientados

Grafos orientados que não contem ciclos, chamados também de grafos orientados acíclicos, admitem uma relação de ordem para seus vértices chamada ordem topológica. Essencialmente, trata-se de organizar os vértices numa lista de tal maneira que, se houver um caminho saindo do vértice v_i e chegando ao v_k, então $v_i \prec v_k$ (lê-se v_i precede v_k) na lista. Notem que a existência do caminho implica na precedência, e não o contrário. Tipicamente, os ordenamentos topológicos não são únicos. Uma maneira interessante de se representar um ordenamento topológico é colocar todos os vértices ao longo de uma linha reta horizontal. Os vértices estarão ordenados topologicamente se todas as arestas apontarem para da esquerda para a direita, ver Fig. 1.24

O algoritmo para a solução do problema 2SAT consiste em:

1. Identificar todas as componentes fortemente conexas do grafo de implicações. No caso do nosso grafo da Fig. 1.23, temos 8 componentes fortemente conexas com um único vértice em cada uma. Notem que todos os vértices numa mesma componente fortemente conexa terão necessariamente o mesmo estado, serão todos verdadeiros ou falsos.

2. Identificar o grafo das componentes fortemente conexas, *i.e.*, o grafo no qual os vértices são as componentes fortemente conexas e as arestas

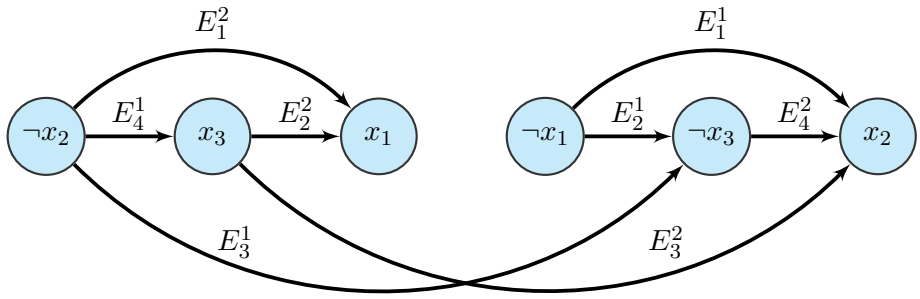

Figura 1.24: Um ordenamento topológico para o grafo da Fig. 1.23. A seqüência de vértices $\{\neg x_2, x_3, x_1, \neg x_1, \neg x_3, x_2\}$ é um ordenamento topológico, pois com todos os vértices representados numa linha horizontal, todas as arestas apontam da esquerda para a direita. Assim, se existe a aresta $v_i \Rightarrow v_k$ no grafo, então necessariamente temos $v_i \prec v_k$ na lista. Ordenamentos topológicos raramente são únicos.

são as conexões entre estas componentes. No nosso caso, é o mesmo grafo. É fácil mostrar que este grafo é sempre acíclico[20].

3. Escolha um ordenamento topológico para o grafo do item anterior. Para o nosso caso, usemos o da Fig. 1.24.

4. Finalmente, atribua 1 à variável x_k se $\neg x_k \prec x_k$, ou 0 no caso contrário. (No caso de haver componentes fortemente conexas, aplique este passo às componentes, não aos vértices que as compõe). Para o nosso caso, a solução associada ao ordenamento do item anterior é $x_0 = x_3 = 0$ e $x_2 = 1$.

Para provarmos que o algoritmo sempre retorna uma solução do problema 2SAT, lembremos que a instância 2SAT só tem dois estados possíveis: verdadeira ou falsa. Suponha que ao aplicarmos o algoritmo tenhamos como resultado que a instância é falsa. Isto requer que pelo menos uma das conjunções do tipo $x \vee y$ seja falsa, o que requer $x = y = 0$, implicando $x \prec \neg x$ e $y \prec \neg y$ na ordem topológica do passo 4 do algoritmo. Porém, as arestas $\neg x \Rightarrow y$ e $\neg y \Rightarrow x$ devem existir no grafo e, portanto, $\neg x \prec y$ e $\neg y \prec x$, implicando

$$x \prec \neg x \prec y \prec \neg y \prec x, \tag{1.132}$$

que é uma contradição e, portanto, a instância só pode ser verdadeira. Notem que cada ordenamento topológico dará uma solução para o problema 2SAT.

[20] Mostre!

1.5.5 Medidas de centralidade

1.5.6 Clusters e transitividade

1.5.7 Conectividade algébrica e o vetor de Fiedler

1.5.8 Passeios aleatórios em grafos

Um *random walk* (passeio aleatório) sobre um grafo $G(V, E)$ é um passeio $(v_1, v_2, ..., v_\ell, ...)$ no qual o vértice $v_{\ell+1}$ é escolhido aleatoriamente sobre todos os vértices adjacentes a v_ℓ. Por simplicidade, admitiremos que todos os vértices adjacentes a v_ℓ têm a mesma probabilidade Π_ℓ para serem escolhidos como o vértice seguinte no passeio. Obviamente, a probabilidade correspondente neste caso será dada por $\Pi_\ell = \frac{1}{d_\ell}$, sendo d_ℓ o grau do vértice v_ℓ. Vamos representar pelo vetor $P_s = \left(p_s^{(1)}, p_s^{(2)}, \ldots, p_s^{(n)}\right)^t$ a probabilidade de encontrarmos, no passo s, o *walker* (caminhante). Como habitual, interpretaremos cada componente de P_s como a probabilidade de encontrarmos o caminhante no vértice correspondente. Por se tratar de uma probabilidade, sempre teremos $p_s^{(i)} \geq 0$ e, além disso,

$$J_1 P_s = \sum_{j=1}^{n} p_s^{(j)} = 1, \tag{1.133}$$

sendo $J_1 = (1, 1, \ldots, 1)$. Suponha agora que um único caminhante inicie o passeio, no passo $s = 0$, num vértice $v_i \in V$. É fácil ver que P_0 é o vetor com todas componentes zero, exceto a i-ésima, que será 1. Já P_1 será o vetor com todas entradas zero, exceto as j entradas correspondentes aos vértices adjacentes a v_i, as quais serão todas iguais a $\frac{1}{d_i}$. De maneira geral, a transição da probabilidade do passo s ao passo $s + 1$ é dada por

$$P_{s+1} = \left(AD^{-1}\right) P_s, \tag{1.134}$$

sendo A e D as matrizes, respectivamente, de adjacência e dos graus do grafo G. Notem que a recorrência (1.134) é compatível com a condição (1.133),

$$J_1 P_{s+1} = (J_1 A) D^{-1} P_s = \mathcal{D} D^{-1} P_s = J_1 P_s = 1, \tag{1.135}$$

sendo $\mathcal{D} = (d_1, d_2, \ldots)$, que implica $\mathcal{D} D^{-1} = J_1$. A recorrência (1.134) pode ser facilmente resolvida como

$$P_s = \left(AD^{-1}\right)^s P_0, \tag{1.136}$$

para todo $s > 0$.

O problema de passeios aleatórios sobre grafos são casos particulares das cadeias de Markov, mas não precisaremos aqui de nada além dos conceitos introduzidos nas seções anteriores. Temos particular interesse nos casos em

que o vetor de probabilidades P_s converge para s grandes, *i.e.*, para os casos no qual existe um vetor P_∞, chamada de distribuição de probabilidade estável do problema, tal que

$$\lim_{s\to\infty} P_s = P_\infty. \tag{1.137}$$

Notem que, se existir a distribuição estável P_∞, esta deve satisfazer

$$P_\infty = \left(AD^{-1}\right) P_\infty. \tag{1.138}$$

Em outras palavras, P_∞ deve ser um autovetor com autovalor 1 da matriz de transição de probabilidade AD^{-1}. Disto, temos uma importante conclusão: para conhecermos o comportamento assintótico para $s \to \infty$ em nosso problema, devemos estudar o espectro da matriz AD^{-1}, que não é simétrica em geral. Apesar de não ser simétrica, é fácil mostrar que AD^{-1} é sempre diagonalizável. Este resultado é garantido por sua relação com a matriz de adjacência normalizada $\mathcal{A}$ da Seção 1.3.5. Notem que

$$AD^{-1} = D^{\frac{1}{2}}\mathcal{A}D^{-\frac{1}{2}}. \tag{1.139}$$

Porém, é um resultado elementar de álgebra linear que as matrizes M e $M' = S^{-1}MS$, para qualquer matriz invertível S, sempre tem o mesmo espectro. Para o nosso caso em particular, a diagonalização de AD^{-1} requer que encontremos seus autovetores Y_i com os respectivos autovetores λ_i tais que $AD^{-1}Y_i = \lambda_i Y_i$. Porém, temos

$$AD^{-1}Y_i = D^{\frac{1}{2}}\mathcal{A}D^{-\frac{1}{2}}Y_i = \lambda_i Y_i. \tag{1.140}$$

Multiplicando-se pela esquerda por $D^{-\frac{1}{2}}$, temos

$$\mathcal{A}\underbrace{\left(D^{-\frac{1}{2}}Y_i\right)}_{X_i} = \lambda_i \underbrace{\left(D^{-\frac{1}{2}}Y_i\right)}_{X_i}, \tag{1.141}$$

de onde temos que os autovalores de AD^{-1} são os mesmos de $\mathcal{A}$, e seus autovetores são $Y_i = D^{\frac{1}{2}}X_i$, sendo X_i os autovetores da matriz de adjacência normalizada $\mathcal{A}$. Assim, conhecendo o espectro de $\mathcal{A}$, podemos facilmente determinar o espectro de AD^{-1}. Vamos ordenar os autovalores λ_i de $\mathcal{A}$ como o fizemos na Seção 1.3.5, $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$. Os resultados daquela seção nos garantem que $\lambda_1 = 1$ e $\lambda_2 \neq 1$ se o grafo for conexo. De fato, a multiplicidade de λ_1 é dada pelo número de partes conexas do grafo. Além disso, sabemos também que $-1 \leq \lambda_n \leq 0$ e, em particular, $\lambda_n = -1$ se o grafo for bipartido. Como último resultado da Seção 1.3.5 que utilizaremos aqui, recordemos que, para um grafo conexo, o autovetor X_1 é (ver Eq. (1.68))

$$X_1 = \frac{1}{\sqrt{2|E(G)|}}\left(\sqrt{d_1}, \sqrt{d_2}, \ldots\right)^t, \tag{1.142}$$

de onde temos diretamente

$$Y_1 = \frac{1}{\sqrt{2|E(G)|}} \left(d_1, d_2, \dots\right)^t. \tag{1.143}$$

Caso o grafo não seja conexo, temos vetores desses tipos para cada parte conexa do grafo.

Escrevendo P_0 em termos dos autovetores Y_i, podemos escrever (1.136) como

$$P_s = \left(AD^{-1}\right)^s \underbrace{\left(\sum_{i=1}^{n} \beta_i Y_i\right)}_{P_0} = \sum_{i=1}^{n} \beta_i \left(\lambda_i\right)^s Y_i. \tag{1.144}$$

Esta expressão nos permite determinar o comportamento assintótico da solução P_s. Vamos supor que o grafo é conexo. Assim, já sabemos que $\lambda_1 = 1$, e todos os outros autovalores são menores que 1. O comportamento assintótico será determinado por Y_1 e pelos eventuais autovetores com autovalor -1 que a matriz AD^{-1} tenha. Notem que a multiplicidade do autovalor -1 de AD^{-1} é a mesmo da autovalor -1 de $\mathcal{A}$, que por sua vez é a mesma da multiplicidade do maior autovalor da matriz Laplaciana normalizada $\mathcal{L}$. Teremos

$$\lim_{s\to\infty} P_s = \lim_{s\to\infty} \sum_{i=1}^{n} \beta_i \left(\lambda_i\right)^s Y_i = \beta_1 Y_1 + (-1)^s \sum_{k\in U} \beta_k Y_k, \tag{1.145}$$

sendo U o conjunto de autovetores com autovalor -1 da matriz AD^{-1}. Já temos algumas conclusões importantes. Caso $U = \emptyset$, temos de (1.145) que P_∞ existe e corresponde ao vetor (1.143). Notem que neste caso podemos fazer $\beta_1 = 1$ se normalizarmos Y_1 de forma a termos $J_1 Y_1 = 1$. Atentem para o fato que os autovetores Y_i **não** são ortogonais, então os coeficientes β_i não podem ser interpretados como coeficientes de projeção usuais. Por outro lado, considerem o caso de um grafo bipartido, para o qual sabemos que $U = \{n\}$ e teremos

$$\lim_{s\to\infty} P_s = \beta_1 Y_1 + (-1)^s \beta_n Y_n. \tag{1.146}$$

Neste caso, P_s não converge para s grande, mas se alterna entre as distribuições $P_+ = \beta_1 Y_1 + \beta_n Y_n$ e $P_- = \beta_1 Y_1 - \beta_n Y_n$. Distribuições deste tipo são chamadas alternantes.

Uma variação interessante, por motivos que logo ficarão claros, do processo de random walk é o chamado *lazy random walk* (caminho aleatório preguiçoso). A diferença é que no lazy random walk, a cada passo, o caminhante que está no vértice v_i tem duas opções: continuar no mesmo vértice, com probabilidade α, ou ir a um dos vértices adjacentes, com probabilidade $\frac{1-\alpha}{d_i}$. Dá-se à α o nome de parâmetro de preguiça (*laziness parameter*) do

caminho. O caminho aleatório usual é o caso de preguiça nula. A recorrência para a probabilidade neste caso é

$$P_{s+1} = \left(\alpha I + (1-\alpha)AD^{-1}\right) P_s, \tag{1.147}$$

cuja solução geral será

$$P_s = \left(\alpha I + (1-\alpha)AD^{-1}\right)^s P_0. \tag{1.148}$$

Já sabemos que o comportamento assintótico da solução será determinado pelo espectro da matriz $M_{LRW} = \alpha I + (1-\alpha)AD^{-1}$. Porém, é fácil ver que se Y_i é um autovetor de AD^{-1} com autovalor λ_i, também será autovetor de M_{LRW}, mas com autovalor $\tilde{\lambda}_i = \alpha + (1-\alpha)\lambda_i$. Porém, neste caso, o maior autovalor de M_{LRW} será sempre $\tilde{\lambda}_1 = 1$, com multiplicidade 1 se o grafo for conexo, enquanto o menor autovalor será tal que $-1 + 2\alpha \leq \tilde{\lambda}_n \leq 0$. Assim, para qualquer $\alpha > 0$, temos que a distribuição estável P_∞ sempre existe e é dada pelo vetor Y_1 da equação (1.143). Como vemos, a introdução da "preguiça" no processo garante que a distribuição estável sempre existe. O valor $\alpha = \frac{1}{2}$ é a escolha mais comum e que, frequentemente, garante boas taxas de convergência.

Exercícios

1. Dê um exemplo de um grafo que não possui distribuição estável P_∞ para random walks e discuta tudo o que puder sobre a distribuição alternante que surge assintoticamente na equação (1.136). (Dica: tenha em mente a frase atribuída a Einstein: *"everything should be made as simple as possible, but no simpler"*.[21])

2. Usando o pacote `NetworkX`, disponível no Python, crie um grafo aleatório do tipo Erdős-Rényi, conexo, com $n = 50$ vértices. Certifique-se que seu espectro garanta a existência da distribuição estável P_∞. (Dica: não é necessários escrever o código para a criação do grafo de Erdős-Rényi, use o comando `erdos_renyi_graph` do `NetworkX`.)

   (a) Escreva um código que, dado um vértice inicial v_1, determine um passeio aleatório com N passos sobre G. Armazene a posição final do passeio, v_N.

   (b) Execute M vezes o seu código com o mesmo vértice inicial, e faça um histograma das posições finais v_N de cada uma dessas execuções. Compare com a previsão teórica de P_∞. (Dica: o `numpy`, pacote fundamental disponível no Python, tem um comando para construir histogramas: `histogram`. Use-o.)

[21] Aparentemente, Einstein nunca disse isso exatamente dessa forma, leiam mais aqui `https://www.nature.com/articles/d41586-018-05004-4`.

(c) Determine, a partir de seus experimentos numéricos, qual a influência de N e M na convergência da distribuição determinada numericamente.

(d) Repita o item (b), mas a cada execução escolha um vértice inicial aleatório. Compare com o caso do mesmo vértice inicial. Comente.

(e) Escreva um código como o do item (a), mas para um lazy random walk. Refaça o item (b) para este caso, com diferentes valores de α. Comente.

Capítulo 2

Grafos aleatórios

Chamamos de grafo aleatório uma estrutura composta por um conjunto de vértices $V = (v_1, v_2, \dots)$ para os quais sabemos que há uma certa probabilidade de existir uma aresta conectando dois vértices distintos quaisquer $v_i, v_j \in V$. Um grafo aleatório pode ser definido mais rigorosamente como um certo espaço de probabilidade, mas não nos aprofundaremos nestes pontos aqui e ficaremos, sempre que possível, com as definições e ideias mais intuitivas.

Apenas para fixar notação, chamaremos de variável aleatória qualquer quantidade real cujo valor dependa de algum processo aleatório e que, portanto, não podemos precisar seu valor, mas sabemos suas probabilidades associadas. Seja $D_x(s)$ a probabilidade da variável x ter valor s, *i.e.*,

$$D_x(s) = \text{Prob}\left[x = s\right]. \tag{2.1}$$

Chamamos a função $D_x(s)$ de distribuição de probabilidade da variável aleatória x. Pela definição de probabilidade, sabemos que $0 \leq D_x(s) \leq 1$ e que

$$\sum_{x_k \in \Omega} D_x(x_k) = 1, \tag{2.2}$$

sendo $\Omega = (x_1, x_2, \dots, x_k, \dots)$ o conjunto de todos os possíveis valores de x. Como nossas variáveis aleatórias assumem valores reais, podemos admitir sem perda de generalidade que o conjunto Ω é ordenado de tal maneira que $x_i < x_{i+1}$ para todo i, o que nos permite introduzir também a noção de distribuição acumulada $C_x(s)$ para a variável x

$$C_x(s) = \text{Prob}\left[x \leq s\right] = \sum_{x_k \in \Omega}^{x_k \leq s} D_x(x_k). \tag{2.3}$$

No caso de variáveis contínuas, os somatórios devem ser substituído por integrações nos intervalos pertinentes. Sempre iremos supor que as somatórias

e/ou integrais envolvidas estão bem definidas, no sentido de convergirem adequadamente. Definimos o valor esperado[1] $\hat{x}$ da variável aleatória x como

$$\hat{x} = \mathbb{E}[x] = \sum_{x_k \in \Omega} x_k D_x(x_k), \tag{2.4}$$

e sua variância σ_x^2 como

$$\sigma_x^2 = \mathbb{E}\left[(x - \hat{x})^2\right] = \sum_{x_k \in \Omega} (x_k - \hat{x})^2 D_x(x_k), \tag{2.5}$$

com as mesmas ressalvas para o caso contínuo. A interpretação mais simples para $\hat{x}$ é a de valor médio esperado para a variável aleatória x. Para compreender o significado deste valor médio esperado, considere um procedimento no qual, a cada passo t, retorne um valor aleatório para $x(t)$, independente dos valores nos passos anteriores. Calculemos a média dos valores aleatórios após n destes passos

$$x_{\text{avg}}(n) = \frac{1}{n} \sum_{t=1}^{n} x(t). \tag{2.6}$$

A cada passo, os possíveis valores de $x(t)$ estão sujeitos a mesma distribuição de probabilidade $D_x(s)$. A variável $x_{\text{avg}}(n)$, sendo uma média de variáveis aleatórias, também será aleatória. Porém, este é exatamente o caso em que podemos invocar o Teorema central do limite[2], para concluir que, para n grande, a distribuição de probabilidade para x_{avg} será uma gaussiana com média $\hat{x}$ e variância σ_x^2/n. Quanto maior n, mais "concentrada" esta distribuição será em torno da média $\hat{x}$, o que nos permite escrever

$$x_{\text{avg}} = \lim_{n \to \infty} x_{\text{avg}}(n) = \hat{x}. \tag{2.7}$$

Esta identificação entre a média x_{avg} de (muitos) sucessivos valores de uma variável aleatória e seu valor esperado $\hat{x}$ é o germe do fundamental conceito de ergodicidade, sobre o qual existe vasta literatura física e matemática. Por ora, ficaremos com os conceitos mais simples e intuitivos representados por (2.7).

Vamos agora considerar os dois tipos de grafos aleatórios que, provavelmente, são os mais estudados atualmente: os de Erdős-Rényi e os de Barabasi-Albert.

2.1 Grafos de Erdős-Rényi

Os grafos de Erdős-Rényi são os modelos mais simples que podemos imaginar de grafos aleatórios. Grosso modo, correspondem a grafos com um número n

[1] Também chamada de esperança ou expectância.

[2] Para estabelecer a convergência no sentido de probabilidade de $x_{\text{avg}}(n)$ para $\hat{x}$, bastaria invocar a Lei dos grandes números.

de vértices fixos nos quais a probabilidade de existência de uma aresta entre dois vértices diferentes, aleatoriamente escolhidos, é homogênea[3]. Há duas maneiras distintas de se introduzir grafos aleatórios com esta propriedade. Considerem, inicialmente, o caso de um grafo com n vértices e E arestas, distribuídas aleatoriamente, de maneira homogênea, entre pares de vértice diferentes. Chamamos esta construção de $G(n, E)$. A segunda maneira de se construir um grafo com propriedades semelhantes consiste em considerar um grafo com n vértices para os quais a probabilidade existência de uma aresta será dada por p, com $0 < p \leq 1$.[4] Estes grafos são denominados $G(n, p)$ e, por construção, não têm um número fixo de arestas, ao contrário do primeiro caso. Há, de fato, uma relação entre as duas definições, e a exploraremos em várias situações.

É fácil ver que o caso $p = 1$ corresponde ao grafo completo K_n. Na primeira definição, este é o caso correspondente à $E = \binom{n}{2} = \frac{1}{2}n(n-1)$, que é o número de arestas de K_n, o número máximo de arestas que um grafo de n vértices pode acomodar. Note que podemos calcular facilmente a probabilidade p' de que dois vértices aleatórios em $G(n, E)$ pertençam a uma aresta. O resultado é

$$p' = \frac{2E}{n(n-1)}, \tag{2.8}$$

uma probabilidade homogênea, que não depende dos vértices escolhidos. Vamos agora determinar o número esperado de arestas $\hat{E}$ em $G(n, p)$ para compreendermos um pouco melhor a relação entre as duas definições. Para isso, vamos primeiro determinar a distribuição de probabilidade para os graus dos vértices em $G(n, p)$, *i.e.*, a probabilidade $D_i(k)$ de que um vértice v_i aleatório de $G(n, p)$ tenha grau $d_i = k$,

$$D_i(k) = \text{Prob}[d_i = k]. \tag{2.9}$$

Ao escolhermos um vértice aleatório v_i, obviamente restarão ainda $n - 1$ vértices no grafo. O vértice v_i terá grau $d_i = k$ se houver exatamente k arestas que o contém. A probabilidade de que o vértice v_i esteja conectado somente a um certo conjunto de k vértices fixos é dada por $p^k(1-p)^{n-k-1}$. Há $\binom{n-1}{k}$ maneiras diferentes do vértice v_i se conectar a k dos $n-1$ vértices restantes do grafo, o que nos permite concluir que

$$\boxed{D_i(k) = B(n, k) = \binom{n-1}{k} p^k (1-p)^{n-k-1}.} \tag{2.10}$$

[3]Homogênea neste contexto significa que a probabilidade de existência da aresta é a mesma para qualquer par de vértices.

[4]Não vamos considerar aqui o caso $p = 0$, nem o $E = 0$, pois corresponderiam a grafos aleatórios triviais: apenas os casos sem nenhuma aresta.

Trata-se, obviamente, na conhecida distribuição binomial e, como esperado, ela independe do vértice v_i. A distribuição de probabilidade $D_i(k)$ nos permite calcular $\hat{d}_i$, o valor esperado do grau para o vértice v_i em um grafo aleatório de de Erdős-Rényi $G(n,p)$, e o resultado é a conhecida esperança da binomial

$$\hat{d}_i = \mathbb{E}\left[d_i\right] = \sum_{k=0}^{n-1} kB(n,k) = (n-1)p, \tag{2.11}$$

cuja prova simples decorre das propriedades elementares dos binômios de Newton:

$$(p+q)^m = \sum_{k=0}^{m} \binom{m}{k} p^k q^{m-k}. \tag{2.12}$$

Diferenciando-se ambos os lados em relação a p e depois multiplicando-se por p, temos

$$mp(p+q)^{m-1} = \sum_{k=0}^{m} \binom{m}{k} kp^k q^{m-k}. \tag{2.13}$$

Fazendo-se agora $q = 1-p$, tem-se

$$mp = \sum_{k=0}^{m} \binom{m}{k} kp^k (1-p)^{m-k}, \tag{2.14}$$

de onde, comparando-se com (2.11), temos finalmente

$$\hat{d}_i = (n-1)p. \tag{2.15}$$

A variância associada é simplesmente

$$\sigma^2 = \mathbb{E}\left[d_i^2\right] - \mathbb{E}\left[d_i\right]^2 = np(1-p), \tag{2.16}$$

e pode ser calculada de maneira análoga.

Há uma outra quantidade relacionada a $\hat{d}_i$ que nos será bastante útil. Trata-se do grau médio dos vértices de $G(n,p)$, $d_{\text{avg}}(n) = \frac{1}{n}\sum_{i=1}^{n} d_i$, e é claro que será uma variável aleatória, pois é a média das variáveis aleatórias independentes d_i, cujas distribuições de probabilidade são dadas por (2.10). Porém, pelo mesmo argumento do Teorema central do limite explorado em (2.7), podemos esperar que para n grande possamos escrever

$$d_{\text{avg}} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{E}\left[d_i\right] = (n-1)p, \tag{2.17}$$

sempre que np for fixo, o que garante que o valor esperado de d_i e sua variância sejam finitas no limite $n \to \infty$. Podemos também calcular o valor esperado para o número de arestas em $G(n,p)$ como

$$\hat{E} = \mathbb{E}\left[\frac{1}{2}\sum_{i=1}^{n} d_i\right] = \frac{n}{2} d_{\text{avg}} = \frac{n(n-1)p}{2}, \tag{2.18}$$

que é perfeitamente compatível com (2.8). A relação entre $G(n,p)$ e $G(n,E)$, ou melhor, a relação entre as propriedades estatísticas de $G(n,p)$ e de $G(n,E)$, são tão mais precisas quanto maior for n com np fixo, como vemos do Teorema central do limite. Nesse contexto, podemos examinar o limite da distribuição (2.10) para o caso de n grande com $d_{\text{avg}} = \lambda = (n-1)p$ fixo. Este é outro resultado bem conhecido, o limite será a distribuição de Poisson $P_\lambda(k)$. Para demonstrá-lo, notem que a distribuição binomial (2.10) pode ser escrita em termos de λ como

$$\begin{aligned} D_i(k) &= \frac{(n-1)!}{k!(n-k-1)!}\left(\frac{\lambda}{n-1}\right)^k\left(1-\frac{\lambda}{n-1}\right)^{n-k-1} \\ &= \frac{\lambda^k}{k!}\frac{m!}{m^k(m-k)!}\left(1-\frac{\lambda}{m}\right)^{m-k}, \end{aligned} \tag{2.19}$$

com $m = n-1$. O limite que nos interessa é $n \to \infty$ com λ e k fixos, que pode ser determinado de maneira elementar

$$\lim_{n\to\infty} D_i(k) = P_\lambda(k) = \frac{\lambda^k e^{-\lambda}}{k!}. \tag{2.20}$$

Notem que qualquer propriedade estatística de $G(n,p)$ que possa ser obtida de maneira semelhante ao caso do número de arestas E dado por (2.18), convergirá da maneira prevista pelo Teorema central do limite, para n grande e d_{avg} fixo, para a quantidade equivalente definida em $G(n,E)$, numa situação completamente análoga à relação entre entre médias e valores esperados expressa por (2.7).

2.1.1 Algumas propriedades dos grafos de Erdős-Rényi

A distribuição de graus (2.10), ou sua verão $n \to \infty$ dada por (2.20), já nos fornece informações interessantes sobre o grafo de Erdős-Rényi. Por exemplo, o valor $D_i(0)$ nos dá a probabilidade de existirem vértices desconectados da rede ($d_i = 0$). No limite $n \to \infty$, da distribuição de Poisson (2.20), sabemos que $d_i(0) = e^{-d_{\text{avg}}}$. Porém, essencialmente este mesmo resultado vale para n finito, dentro de algumas condições. Para demonstrarmos este fato, notem primeiro que de (2.10) temos

$$D_i(0) = (1-p)^{n-1} \leq e^{-(n-1)p} = e^{-d_{\text{avg}}}, \tag{2.21}$$

onde usamos a propriedade da convexidade da função exponencial, que implica $1-x \leq e^{-x}$ para todo $x \in \mathbb{R}$, sendo a igualdade verificada apenas para $x = 0$. Há várias maneiras para se estimar um limite inferior para $D_i(0)$. Uma simples é a seguinte. Para x pequeno o suficiente, temos

$$e^{-(1+\epsilon)x} \leq 1-x \leq e^{-x} \tag{2.22}$$

para $\epsilon > 0$. A pergunta é: podemos estimar os valores de x para os quais (2.22) é verificada para um $\epsilon > 0$ arbitrário? A resposta é sim, e podemos estimar x considerando a função

$$f(x) = \log(1-x) + (1+\epsilon)x, \tag{2.23}$$

definida para $x \in [0, 1)$. Por construção, temos $f(0) = 0$ e $f(1^-) \to -\infty$. Também por construção, $f(x) \geq 0$ exatamente na região na qual $e^{-(1+\epsilon)x} \leq 1 - x$. Ocorre que o máximo de $f(x)$ pode ser facilmente localizado, corresponde ao ponto $x = \frac{\epsilon}{1+\epsilon}$. Assim, temos o seguinte Lema.

Lema 3 *Seja $\epsilon > 0$. Para $0 \leq x \leq \frac{\epsilon}{1+\epsilon}$, tem-se:*

$$e^{-(1+\epsilon)x} \leq 1 - x \leq e^{-x}.$$

O Lema 3 nos permite escrever, de maneira análoga à desigualdade (2.21),

$$e^{-(1+\epsilon)d_{\text{avg}}} \leq D_i(0) \leq e^{-d_{\text{avg}}}, \tag{2.24}$$

para $0 < p \leq \frac{\epsilon}{1+\epsilon}$, com $\epsilon > 0$, de onde temos que para redes com $d_{\text{avg}} = 10$, a probabilidade de existirem vértices desconectados é inferior a 10^{-4}. Note que para um grafo com $n = 1000$ vértices, um tamanho relativamente modesto para várias aplicações, bastaria uma probabilidade $p = 10^{-2}$ para termos $d_{\text{avg}} \approx 10$. Por outro lado, com ϵ pequeno e $d_{\text{avg}} = 1$, uma ordem de magnitude menor que o exemplo anterior, temos mais de $1/3$ de probabilidade de termos vértices desconectados, uma probabilidade 3 ordens de magnitude maior. Para um grafo com $n = 1000$ vértices, basta escolher p e $\epsilon \approx 10^{-3}$ para termos $d_{\text{avg}} \approx 1$. Este tipo de comportamento se assemelha muito às transições de fase e comportamento crítico em Mecânica Estatística.

É fácil entendermos porque $d_{\text{avg}} = 1$ representa uma espécie de valor crítico, abaixo do qual devem aparecer muitos vértices isolados. A Figura 2.1 representa um grafo aleatório com $d_{\text{avg}} = 1$. Trata-se de um grafo regular, todos seus vértices tem grau 1. Está é uma situação atípica, muito pouco provável. Porém, se mantivermos o mesmo número de arestas, para aumentarmos o grau de qualquer vértice, teremos que necessariamente deixar algum vértice isolado. Grafos com $d_{\text{avg}} = 1$ não têm um número suficiente de arestas para poder conectar todos seus vértices e fatalmente serão frequentes os vértices isolados.

Matriz de adjacência

Não é difícil determinarmos a matriz de adjacência esperada para $G(n, p)$. A entrada a_{ij} da matriz de adjacência de um grafo tem valores 0 ou 1, dependendo se há ou não uma aresta entre os vértices v_i e v_j. Para o caso de grafo de Erdős-Rényi, qualquer entrada a_{ij} será uma variável aleatória

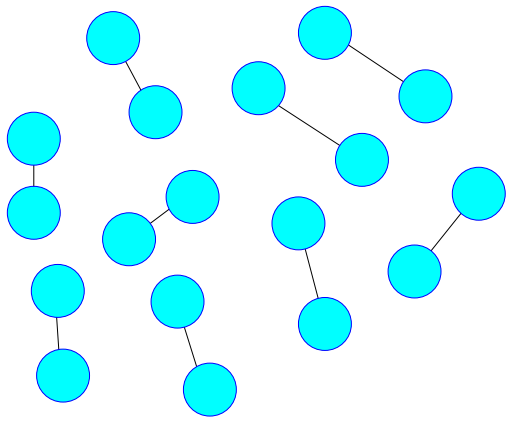

Figura 2.1: Grafo com $d_{\text{avg}} = 1$.

cujos valores possíveis são são 0 e 1, com probabilidades associadas dadas, respectivamente por $1-p$ e p. É claro que o valor esperado será $\hat{a}_{ij} = p$, para quaisquer pares de vértices, o que nos permite escrever a matriz de adjacência esperada. A matriz de adjacência esperada será portanto

$$\hat{A} = pA_K, \tag{2.25}$$

onde A_K é a matriz de adjacência para o grafo completo K_n, da qual conhecemos o espectro da seção 1.5.1. Os autovalores de $\hat{A}$ serão portanto $p(n-1)$ e $-p$, este último com multiplicidade $n-1$.

Das seções anteriores, sabemos que $\operatorname{Tr} A^2 = 2E$ para qualquer grafo. De (2.25), temos

$$\operatorname{Tr} \hat{A}^2 = n(n-1)p^2 = 2p\hat{E}, \tag{2.26}$$

o que mostra que a matriz de adjacência esperada $\hat{A}$ não expressa bem esta propriedade estatística dos grafos de Erdős-Rényi. Para compreendermos melhor o que está ocorrendo, vamos relembrar quem é a matriz esperada $\hat{A}$. Suponha que sejam sorteados de $G(n,p)$, m grafos aleatórios, cada um deles com matriz de adjacência A_j, $j = 1, \ldots, m$. A matriz esperada (2.25) surge da média

$$\hat{A} = \frac{1}{m}\sum_{j=1}^{m} A_j, \tag{2.27}$$

no limite de grande m. Para o grafo sorteado no passo j, seu número de arestas será dado por $\operatorname{Tr} \hat{A}_j^2$. O número médio de arestas no conjunto de grafos sorteados será

$$\hat{E} = \frac{1}{m}\sum_{j=1}^{m} \operatorname{Tr} A_j^2 \neq \operatorname{Tr} \hat{A}^2. \tag{2.28}$$

De fato, temos que

$$\hat{A}^2 = \left(\frac{1}{m}\sum_{j=1}^{m} A_j\right)^2 \neq \frac{1}{m}\sum_{j=1}^{m} A_j^2 = \widehat{A^2}. \tag{2.29}$$

Triângulos em $G(n,p)$

Como outro exemplo de propriedade estatística de grafos, vamos determinar o número esperado de triângulos contidos em $G(n,p)$. Um triângulo corresponde, obviamente, a três vértices conectados por arestas. Dados três vértices distintos em $G(n,p)$, a probabilidade de que eles formem um triângulo é p^3. Num grafo com n vértices, existirão $\binom{n}{3}$ triplas distintas de vértices. Desta maneira, teremos que o número esperado de triângulos N_Δ em $G(n,p)$ é dado por

$$N_\Delta = \binom{n}{3}p^3 = \frac{n(n-1)(n-2)p^3}{6} = \frac{d_{\text{avg}}^3 - p^2 d_{\text{avg}}}{6}, \tag{2.30}$$

de onde vemos, novamente, um comportamento abrupto ao variarmos d_{avg}. Em $G(n,p)$, teremos 1000 vezes mais triângulos para $d_{\text{avg}} \approx 10$ do que para $d_{\text{avg}} \approx 1$.

Uma outra pergunta relacionada a esta é: qual a probabilidade de haver ao menos um triângulo em $G(n,p)$? Há diversas maneiras de se responder esta questão. Uma delas é atentar para o fato de que a probabilidade de que três vértices distintos não formem um triângulo é $1-p^3$. Como há $\binom{n}{3}$ triplas distintas de vértices em $G(n,p)$, a probabilidade de que nenhuma delas acomode um triângulo é $(1-p^3)^{\binom{n}{3}}$, de onde temos que a probabilidade Π_Δ de existir ao menos um triângulo em $G(n,p)$ será

$$\Pi_\Delta = 1 - (1-p^3)^{\binom{n}{3}}. \tag{2.31}$$

Analisemos o limite de n grande, para o qual $p \approx \frac{d_{\text{avg}}}{n}$ e $\binom{n}{3} \approx \frac{n^3}{6}$. Teremos

$$\lim_{n\to\infty} \Pi_\Delta = \lim_{n\to\infty} 1 - \left(1 - \frac{d_{\text{avg}}^3}{n^3}\right)^{\frac{n^3}{6}} = 1 - e^{-\frac{1}{6}d_{\text{avg}}^3} \approx 1 - e^{-N_\Delta}. \tag{2.32}$$

As diferenças para $d_{\text{avg}} \approx 10$ e $d_{\text{avg}} \approx 1$ são ainda mais gritantes. No primeiro caso, a probabilidade de existir pelo menos um triângulo é altíssima (difere de 1 em menos de uma parte em 10^{73}), enquanto no segundo caso a probabilidade é de cerca de 15%.

Conectividade de $G(n,p)$

Este é um problema clássico e consideravelmente mais complexo. A questão é determinar a probabilidade do grafo $G(n,p)$ ser conexo. Abordaremos

este problema explorando a noção de partição de um grafo. Suponha que k vértices de $G(n,p)$ são escolhidos. Teremos dois conjuntos: V_k, contendo os k vértices escolhidos e V_{n-k} contendo os $n-k$ restantes. Qual a probabilidade que esta partição seja disjunta? Como há $k(n-k)$ possíveis arestas entre V_k e V_{n-k}, a probabilidade de não haver nenhuma aresta entre V_k e V_{n-k} é $(1-p)^{k(n-k)}$. Como há $\binom{n}{k}$ distintas partições deste tipo, o número N_k de partições disjuntas esperadas deste tipo será

$$N_k = \binom{n}{k}(1-p)^{k(n-k)}. \tag{2.33}$$

O número total esperado de partições disjuntas será

$$N_{\text{Tot}} = \sum_{k=1}^{\lfloor \frac{n}{2} \rfloor} N_k = \sum_{k=1}^{\lfloor \frac{n}{2} \rfloor} \binom{n}{k}(1-p)^{k(n-k)}. \tag{2.34}$$

Agora algumas estimativas. Note que

$$\binom{n}{k} = \frac{n(n-1)(n-2)\cdots(n-k+1)}{k!} \leq n^k. \tag{2.35}$$

Lembrando da convexidade da função exponencial ($1-p \leq e^{-p}$), podemos obter o seguinte limite superior para N_{Tot}

$$N_{\text{Tot}} \leq \sum_{k=1}^{\lfloor \frac{n}{2} \rfloor} e^{-k[(n-k)p-\log n]} \leq \sum_{k=1}^{\lfloor \frac{n}{2} \rfloor} \left(e^{-(d_{\text{avg}}-\log n)}\right)^k. \tag{2.36}$$

O último somatório em (2.36) é uma série geométrica que pode ser facilmente calculada, dando finalmente

$$N_{\text{Tot}} \leq \frac{e^{-\mu} - e^{-(\lfloor \frac{n}{2} \rfloor + 1)\mu}}{1-e^{-\mu}}, \tag{2.37}$$

com

$$\mu = d_{\text{avg}} - \log n. \tag{2.38}$$

Note que há um comportamento abrupto evidente. Para $\mu < 0$, que corresponde a obviamente a $d_{\text{avg}} < \log n$, o limite superior para N_{Tot} diverge para n grande. Por outro lado, se $d_{\text{avg}} > \log n$ temos efetivamente um limite superior que decai exponencialmente com $\mu = d_{\text{avg}} - \log n$, sugerindo que não há partições disjuntas se μ for suficientemente grande e que, portanto, um grafo $G(n,p)$ com $d_{\text{avg}} > \log n$ provavelmente é conexo. Este talvez seja o comportamento mais famoso dos grafos de Erdős-Rényi.

Voltemos a questão da probabilidade Π_C do grafo $G(n,p)$ ser conexo. A probabilidade de que uma partição (V_k, V_{n-k}) tenha pelo menos uma aresta

entre V_k e V_{n-k} é $1-(1-p)^{k(n-k)}$. A probabilidade Π_k de que *todas* as partições (V_k, V_{n-k}) tenham pelo menos uma aresta entre V_k e V_{n-k} será

$$\Pi_k = \left(1-(1-p)^{k(n-k)}\right)^{\binom{n}{k}} \tag{2.39}$$

de onde temos

$$\Pi_C = \prod_{k=1}^{\lfloor \frac{n}{2} \rfloor} \Pi_k. \tag{2.40}$$

Essa expressão é um tanto complicada e portanto vamos estimar um limite superior para Π_C e verificar seu comportamento para $d_{\text{avg}} < \log n$. Note inicialmente que

$$\Pi_k \leq e^{-\binom{n}{k}(1-p)^{k(n-k)}} = e^{-N_k}, \tag{2.41}$$

sendo N_k o número esperado de partições disjuntas (2.33) de $G(n,p)$, de onde temos finalmente

$$\Pi_C \leq e^{-N_{\text{Tot}}} \leq \exp\left(-\frac{e^{-\mu} - e^{-\left(\lfloor \frac{n}{2} \rfloor + 1\right)\mu}}{1-e^{-\mu}}\right). \tag{2.42}$$

É evidente que $\Pi_C \to 0$ para $d_{\text{avg}} < \log n$.

Distância típica em $G(n,p)$

Podemos ter uma estimativa da distância típica entre dois vértices arbitrários de $G(n,p)$ examinando a distribuição de probabilidade de distâncias entre dois vértices v_i e v_j distintos

$$\mathcal{D}_{ij}(s) = \text{Prob}\left[\text{dist}(v_i, v_j) = s\right]. \tag{2.43}$$

A distância típica será aquela para qual a distribuição é máxima e corresponderá a distância mais frequente que encontraremos entre dois vértices aleatórios de $G(n,p)$. Para não sobrecarregar a notação, abandonaremos os índices i, j em todos os desenvolvimentos deste item. Uma quantidade que nos será útil é o número esperado N_k de caminhos de k passos entre dois vértices aleatórios v_i e v_j distintos de $G(n,p)$. Sabemos que $N_1 = p$ e

$$N_k = p^k \prod_{j=2}^{k} (n-j) \tag{2.44}$$

para $k > 1$. Para para todo $k > 0$, teremos

$$\left(\frac{n-k}{n-1}\right)^k \frac{d_{\text{avg}}^k}{n-1} \leq N_k \leq \frac{d_{\text{avg}}^k}{n-1}, \tag{2.45}$$

de onde vemos que para n grande podemos efetivamente considerar

$$N_k \approx \frac{d_{\text{avg}}^k}{n}. \tag{2.46}$$

Vamos agora determinar a distribuição de probabilidade das distâncias $\mathcal{D}(s)$. Notem que

$$\mathcal{D}(1) = \text{Prob}\left[\exists \text{ caminho de 1 passo entre } (i,j)\right] = p, \tag{2.47}$$

e que

$$\begin{aligned}
\mathcal{D}(s) &= \prod_{k=1}^{s-1} \text{Prob}\left[\nexists \text{ caminho de } k \text{ passos entre } (i,j)\right] \times \\
&\qquad \text{Prob}\left[\exists \text{ caminho de } s \text{ passos entre } (i,j)\right], \\
&= \prod_{k=1}^{s-1} (1-p^k)^{\prod_{j=2}^{k}(n-j)} \left(1-(1-p^s)^{\prod_{j=2}^{s}(n-j)}\right).
\end{aligned} \tag{2.48}$$

Para n grande, lembrando que $(n-1)p = d_{\text{avg}}$ é finito, temos

$$(1-p^s)^{\prod_{j=2}^{s}(n-j)} \approx e^{-N_s}, \tag{2.49}$$

de onde temos finalmente

$$\mathcal{D}(s) = \exp\left(-\sum_{k=1}^{s-1} N_k\right)\left(1-e^{-N_s}\right) = e^{\frac{d_{\text{avg}}}{n(d_{\text{avg}}-1)}}\left(e^{-\frac{d_{\text{avg}}^s}{n(d_{\text{avg}}-1)}} - e^{-\frac{d_{\text{avg}}^{s+1}}{n(d_{\text{avg}}-1)}}\right). \tag{2.50}$$

A distribuição (2.50) tem algumas propriedades curiosas. Estamos interessados basicamente no limite de n grande, com $d_{\text{avg}} \ll n$. Lembrem-se que para que $G(n,p)$ seja conexo, precisamos ter $d_{\text{avg}} > \log n$. A primeira exponencial será 1 no limite $\frac{d_{\text{avg}}}{n} \to 0$. O termo entre parêntesis será zero tanto no limite $\frac{d_{\text{avg}}^s}{n} \to 0$ quanto para $\frac{d_{\text{avg}}^s}{n}$ grande. A Fig. 2.2 ilustra o aspecto típico da distribuição (2.50). Podemos facilmente determinar o ponto de máximo da distribuição (2.50). A condição $\mathcal{D}'(s) = 0$ será

$$e^{\frac{d_{\text{avg}}^s}{n}} = d, \tag{2.51}$$

cuja solução é

$$s_* = \log_{d_{\text{avg}}}\left(n \log d_{\text{avg}}\right) \approx \log_{d_{\text{avg}}} n \tag{2.52}$$

para n grande. Notem que é um comportamento semelhante ao do grafo regular considerado na seção 1.5.2. O máximo da distribuição será

$$\mathcal{D}(s_*) = d_{\text{avg}}^{-\frac{1}{d_{\text{avg}}-1}} - d_{\text{avg}}^{-\frac{d_{\text{avg}}}{d_{\text{avg}}-1}} \tag{2.53}$$

para n grande.

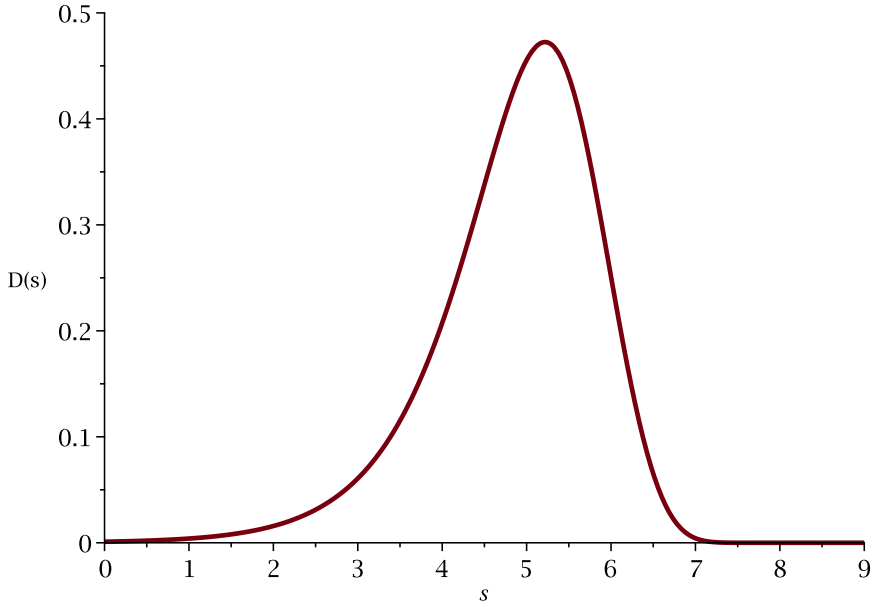

Figura 2.2: Aspecto da distribuição (2.50), para $n = 1000$ e $d_{\text{avg}} = 4$. Nota-se claramente que a distância típica neste caso é próxima de 5. Notem que $4^5 = 1024$ e que $4^{-\frac{1}{3}} - 4^{-\frac{4}{3}} \approx 0.47$, vejam (2.52) e (2.53).

O paradoxo das amizades

Este paradoxo, que não é específico de grafos de Erdős-Rényi, corresponde a uma antiga observação sociológica que pode ser expressa como "em média, uma pessoa tem menos amigos do que seus amigos têm". Trata-se de propriedade geral exibida por qualquer grafo que não seja regular. Para entendermos este curioso fenômeno, vamos um grafo G com distribuição de graus homogênea P_k. A interpretação desta distribuição é simples: ao escolhermos aleatoriamente um vértice de G, a probabilidade de que este tenha grau k é P_k. Com isso, podemos calcular o grau médio do grafo da maneira usual, como $\langle k \rangle = \sum_k kP_k$.

Vamos agora considerar um problema diferente. Escolhido, aleatoriamente ou não, um vértice de G com grau $k' > 0$, qual a probabilidade que uma de suas arestas específica esteja conectada um outro vértice de grau k? Bem, a maneira mais simples para responder esta questão é lembrar que uma aresta conecta dois vértices. Vamos chamar as conexões das arestas com os vértices de terminais[5]. O número total de terminais no grafo é $\sum_i k_i = 2E$ É fácil determinarmos a probabilidade de que a aresta em questão esteja

[5]Em inglês, se utiliza normalmente a expressão *stub* para os terminais de uma aresta.

conectada a um vértice específico de grau k. Será simplesmente

$$p = \frac{k}{2E - k'}, \tag{2.54}$$

que corresponde aos k terminais do vértice, dentro de todos os $2E - k'$ terminais disponíveis num grafo sem auto-ligações. Mas a questão nos interessa não é determinar a probabilidade de uma certa aresta estar conectada a um certo vértice de grau k, mas sim a de estar conectada a algum vértice de grau k. Para isto, basta lembrar que num grafo de n vértices, há nP_k vértices com grau k, de onde temos que a nossa probabilidade é

$$P_k^E = \frac{nkP_k}{2E - k'}, \tag{2.55}$$

a qual também é chamada de distribuição de excesso de graus do grafo. Antes de tomarmos os limites de um grafo grande, convém relembrar que probabilidade é essa. Trata-se da probabilidade de, dado um vértice de grau $k' > 0$, uma de suas arestas específicas esteja conectada a um vértice de grau k. O limite de grandes n e E implica que $\frac{2E-k'}{n} \approx \langle k \rangle$, de onde temos finalmente

$$P_k^E = \frac{kP_k}{\langle k \rangle}. \tag{2.56}$$

Podemos calcular agora o valor esperado para o grau desse vértice

$$\langle k \rangle_E = \sum_k kP_k^E = \frac{\langle k^2 \rangle}{\langle k \rangle}, \tag{2.57}$$

lembrando que se trata do grau esperado do vértice conectado a uma aresta específica de um certo vértice escolhido inicialmente. Porém, não há nada especial com essa aresta, portanto podemos afirmar que o valor esperado do grau de qualquer vizinho do vértice inicial também será dado por (2.57). Porém, notem que

$$\langle k \rangle_E - \langle k \rangle = \frac{\langle k^2 \rangle - \langle k \rangle^2}{\langle k \rangle} = \frac{\sigma_k^2}{\langle k \rangle} \geq 0, \tag{2.58}$$

sendo a igualdade verificada apenas para grafos regulares ($\sigma_k^2 = 0$). Assim, vemos que o fenômenos que "em média, uma pessoa tem menos amigos do que seus amigos têm", é de fato uma propriedade de qualquer grafo que não seja regular e, portanto, tenha uma distribuição de graus com variança não nula.

2.2 Grafos de Barabasi-Albert

Os grafos aleatórios de Barabasi-Albert são os grafos aleatórios mais simples que exibem o comportamento chamado de "livre de escala", que corresponde

a uma distribuição de probabilidade de graus do tipo lei de potência. São definidos a partir de um procedimento recursivo chamado anexação preferencial (*preferential attachment*). A ideia é que dado um grafo G com k vértices e E arestas, adiciona-se um novo vértice v_{k+1} com m novas arestas. O ponto fundamental do procedimento da anexação preferencial é que o novo vértice tenha maior probabilidade de se conectar ao vértices de maior grau de G. Especificamente, a anexação preferencial está baseada na seguinte probabilidade para que o novo vértice se conecte a um vértice v_i do grafo inicial G

$$\Pi_i = \frac{d_i}{\sum_{j=1}^{k} d_j} = \frac{d_i}{2E}, \tag{2.59}$$

sendo d_i o grau do vértice $v_i \in G$. O grafo de Barabasi-Albert BA corresponde ao grafo que surgirá após a iteração de muitos destes passos. O resultado final não depende do grafo inicial, que normalmente se toma como um grafo qualquer do tipo $G(n_0, E_0)$. Podemos definir o grafo de Barabasi-Albert a partir de um algoritmo.

Definição 7 *Algoritmo de anexação preferencial de Barabasi-Albert.*

Data: $G(n_0, E_0)$*: grafo semente inicial (usualmente Erdős-Rényi conexo);* $m \leq n_0$*: número de arestas de cada novo vértice;* $n \gg n_0$*: número de passos que serão executados.*

Result: *Grafo de Barabasi-Albert* BA_n *(*$n \to \infty$*).*

1 $\mathrm{BA}_0 = G(n_0, E_0)$;
2 **for** $t = 0$ **to** $n - 1$ **do**
3 *Adiciona-se um vértice ao grafo* BA_t*, dando origem ao grafo* BA_{t+1} *;*
4 *Este novo vértice tem* $m \leq n_0$ *arestas disponíveis, as quais são distribuídas entre os vértices de* BA_t *de acordo com a probabilidade*

$$\Pi_i(t) = \frac{d_i(t)}{\sum_{j=1}^{n_0+t} d_j(t)} = \frac{d_i(t)}{2(E_0 + mt)};$$

5 **end**
6 **return** BA_n*;*

Vamos estudar o comportamento assintótico do algorítimo para $n \gg n_0$. Note que na iteração t, o grafo terá $|\mathrm{BA}_t| = n_0 + t$ vértices e $|E(\mathrm{BA}_s)| = E_0 + mt$ arestas. Seja $N_k(t)$ o número de vértices do grafo BA_t no passo t. Com a hipótese que o grafo semente $G(n_0, E_0)$ é conexo e, portanto, não tem vértices com grau zero, a anexação preferencial garante que o grafo final

também será livre de vértices de grau zero. Podemos, portanto, sem perda de generalidade, considerar $k > 0$. É fácil ver que

$$N_k(t+1) - N_k(t) = \frac{m(k-1)N_{k-1}}{2(E_0+mt)} - \frac{mkN_k}{2(E_0+mt)} + \delta_k^m. \tag{2.60}$$

Vamos considerar termo a termo nesta equação. Do lado direito, temos simplesmente ΔN_k, *i.e.*, a variação no número de vértices com grau k da transição do passo t ao $t+1$. O primeiro termo do lado direito, nos dá a fração dos vértices de grau $k-1$ que podem ser escolhidos no procedimento da anexação preferencial. A cada vértice com grau $k-1$ selecionado na anexação preferencial, devemos ter $\Delta N_k = 1$, pois um novo vértice com grau k surge no grafo. De maneira análoga, a seleção de um vértice de grau k implica em $\Delta N_k = -1$. O último termo, o do delta de Kronecker, corresponde aos vértices que são inseridos a cada passo do procedimento, sempre com grau m.

Estamos interessados na distribuição de probabilidade de graus $P_k(t)$ do nosso grafo. Por definição, temos

$$P_k(t) = \frac{N_k(t)}{\sum_k N_k(t)} = \frac{N_k(t)}{n_0+t}. \tag{2.61}$$

Vamos supor agora que o limite $\lim_{t\to\infty} P_k(t) = P_k$ exista[6]. Neste caso, temos

$$\lim_{t\to\infty} N_k = tP_k \tag{2.62}$$

e, portanto, $\Delta N_k = P_k$. Para o grau médio do grafo, temos

$$\langle k \rangle = \lim_{t\to\infty} \sum_k kP_k(t) = \lim_{t\to\infty} \frac{2(E_0+mt)}{n_0+t} = 2m. \tag{2.63}$$

Tomando-se o limite $t \to \infty$ em (2.60), temos

$$\left(1+\frac{k}{2}\right) P_k - \frac{(k-1)P_{k-1}}{2} = \delta_k^m. \tag{2.64}$$

Antes de discutirmos a solução da equação a diferenças (2.64), convém fazermos alguns comentários. Primeiro, somando em ambos os lados e rearranjando-se os termos, temos temos

$$\begin{aligned} \sum_{k=1}^{\ell} P_k &= 1 - \frac{1}{2}\left(\sum_{k=1}^{\ell} kP_k - \sum_{k=1}^{\ell}(k-1)P_{k-1}\right) \\ &= 1 - \frac{\ell P_\ell}{2}. \end{aligned} \tag{2.65}$$

[6]Não precisamos desta hipótese, podemos provar que tal limite existe, veja mais detalhes aqui.

Agora, vamos multiplicar ambos os lados por k e somar. Após rearranjarmos os termos, teremos

$$\begin{aligned}\sum_{k=1}^{\ell} kP_k &= m - \frac{1}{2}\left(\sum_{k=1}^{\ell} k^2 P_k - \sum_{k=1}^{\ell}(k-1)^2 P_k - \sum_{k=1}^{\ell}(k-1)P_k\right) \\ &= m - \frac{\ell^2 P_\ell}{2} + \frac{1}{2}\sum_{k=1}^{\ell}(k-1)P_k, \end{aligned} \tag{2.66}$$

que pode ser escrito como

$$\frac{1}{2}\sum_{k=1}^{\ell-1} kP_k = m - \ell P_\ell - \frac{\ell^2 P_\ell}{2}. \tag{2.67}$$

Supondo $\lim_{\ell\to\infty} \ell^2 P_\ell = 0$, temos de (2.65) e (2.67)

$$\sum_{k=1}^{\infty} P_k = 1 \quad \text{e} \quad \langle k \rangle = 2m, \tag{2.68}$$

em perfeita concordância com a hipótese que P_k é uma distribuição de probabilidade com média finita.

Podemos agora retornar a solução de (2.64). Primeiro, notem que para $k = 1$ temos

$$\frac{3}{2}P_1 = \delta_1^m. \tag{2.69}$$

Assim, a não ser que $m = 1$, devemos ter $P_1 = 0$. Para $k = 2$, teremos

$$2P_2 - \frac{P_1}{2} = \delta_2^m, \tag{2.70}$$

de onde temos que, se $m > 2$, teremos $P_1 = P_2 = 0$. De fato, sempre teremos $P_k = 0$ para todo $k < m$, e para $k = m$ devemos ter

$$P_m = \frac{2}{m+2}. \tag{2.71}$$

Assim, podemos escrever (2.64) como a relação de recorrência

$$P_{k+1} = \frac{k}{k+3}P_k, \tag{2.72}$$

válida para $k \geq m$, com a condição inicial (2.71). A solução geral será

$$\begin{aligned} P_{m+\ell} &= \left(\frac{m+\ell-1}{m+\ell+2}\right)\cdots\left(\frac{m+1}{m+4}\right)\left(\frac{m}{m+3}\right)\left(\frac{2}{m+2}\right) \\ &= 2\frac{(m+\ell-1)!}{(m+\ell+2)!}\frac{(m+1)!}{(m-1)!} \\ &= \frac{2m(m+1)}{(m+\ell+2)(m+\ell+1)(m+\ell)}. \end{aligned} \tag{2.73}$$

Pode-se mostrar[7] que $\sum_{\ell=0}^{\infty} P_{m+\ell} = 1$, corroborando novamente a consistência da análise. Podemos escrever finalmente a solução de (2.64) como

$$P_k = \begin{cases} 0, & \text{para } k < m, \\ \dfrac{2m(m+1)}{k(k+1)(k+2)}, & \text{para } k \geq m. \end{cases} \tag{2.74}$$

Podemos obter o comportamento de P_k para $k \gg m$ da seguinte maneira

$$P_k = \frac{2m(m+1)}{k^3} \frac{1}{\left(1+\frac{1}{k}\right)\left(1+\frac{2}{k}\right)} = \frac{2m(m+1)}{k^3} + O\left(k^{-4}\right), \tag{2.75}$$

de onde temos a famosa lei de potência $P_k \propto k^{-\gamma}$, com $\gamma = 3$, dos modelos de Barabasi-Albert.

2.2.1 Distâncias em redes livres de escala

Para avaliarmos o raio de uma rede livre de escala, vamos utilizar uma configuração semelhante a da Fig. 1.20 que empregamos no caso de grafos regulares. Como naquele caso, a nossa configuração nos proporcionará o crescimento mais rápido possível para o número de vértices das bolas de raio m e, portanto, poderemos estimar o raio mínimo de uma rede desse tipo. A configuração a que nos referimos é a seguinte. Comecemos com o vértice de maior grau $k_{\max}$ do grafo. Ele será a bola de raio zero B_0. A bola B_1 terá $k_{\max} + 1$ vértices. Além do vértice de B_0, ela conterá os $k_{\max}$ vértices restantes de maior grau. A bola B_2 é construída de maneira análoga, conectando as arestas que emanam de B_1 com os vértices ainda livres, em ordem decrescente de graus. Assim como no caso da Fig. 1.20, todas essas bolas são compostas por árvores. Eventuais ciclos só devem aparecer nas camadas finais. A bola B_ℓ contém todos os vértices com distância igual ou inferior a ℓ de B_0, o vértice de maior grau do grafo. Seja K_ℓ o grau do vértice de menor grau da bola B_ℓ. Como no caso da Fig. 1.20, vamos denominar o número de vértices na bola B_ℓ por $b_\ell = |B_\ell|$. Se o grafo tem N vértices e distribuição de graus P_k, podemos estimar a fração $f_\ell = \frac{b_\ell}{N}$ dos vértices na bola B_ℓ como

$$f_\ell = \sum_{k=K_\ell}^{k_{\max}} P_k. \tag{2.76}$$

Por outro lado, a bola $B_{\ell+1}$, como no caso da figura 1.20, será a bola B_ℓ acrescida dos vértices nos quais terminam as arestas que "emanam" de B_ℓ,

[7] Mostre! Dica: explore a expansão em frações parciais do somando.

i.e., teremos

$$
\begin{aligned}
f_{\ell+1} - f_\ell &= \sum_{k=K_\ell}^{K_{\ell-1}} (k-1)P_k \qquad (2.77)\\
&= \sum_{k=K_\ell}^{k_{\max}} (k-1)P_k - \sum_{k=K_{\ell-1}}^{k_{\max}} (k-1)P_k \\
&= \sum_{k=K_\ell}^{k_{\max}} kP_k - \sum_{k=K_{\ell-1}}^{k_{\max}} kP_k - f_\ell + f_{\ell-1}
\end{aligned}
$$

de onde finalmente temos

$$
f_{\ell+1} - f_{\ell-1} = \sum_{k=K_\ell}^{k_{\max}} kP_k - \sum_{k=K_{\ell-1}}^{k_{\max}} kP_k \qquad (2.78)
$$

Vamos precisar agora de algumas expressões explícitas e faremos algumas aproximações. Vamos considerar uma distribuição de graus do tipo lei de potências $P_k = ak^{-\gamma}$, com $\gamma > 2$ e $k \geq k_{\min} > 0$, e aproximar os somatórios por integrais com o limite $k_{\max} \to \infty$. Teremos

$$
\sum_{k=k_0}^{k_{\max}} P_k \approx a \int_{k_0}^{\infty} \frac{dk}{k^\gamma} = \frac{ak_0^{1-\gamma}}{\gamma - 1} = \left(\frac{k_0}{k_{\min}}\right)^{1-\gamma}, \qquad (2.79)
$$

onde já usamos que o fator de normalização é $a = \frac{\gamma-1}{k_{\min}^{1-\gamma}}$. Da mesma forma, teremos

$$
\sum_{k=k_0}^{k_{\max}} kP_k \approx \frac{\gamma-1}{k_{\min}^{1-\gamma}} \int_{k_0}^{\infty} \frac{kdk}{k^\gamma} = \frac{\gamma-1}{\gamma-2} \frac{k_0^{2-\gamma}}{k_{\min}^{1-\gamma}}. \qquad (2.80)
$$

Com as mesmas aproximações, notem que

$$
\langle k \rangle = \sum_{k=k_{\min}}^{k_{\max}} kP_k \approx \frac{\gamma-1}{k_{\min}^{1-\gamma}} \int_{k_{\min}}^{\infty} \frac{kdk}{k^\gamma} = \frac{\gamma-1}{\gamma-2} k_{\min}, \qquad (2.81)
$$

de onde temos finalmente

$$
\sum_{k=k_0}^{k_{\max}} kP_k \approx \langle k \rangle \left(\sum_{k=k_0}^{k_{\max}} P_k \right)^{\frac{\gamma-2}{\gamma-1}}. \qquad (2.82)
$$

Com estes resultados, podemos escrever (2.78) como

$$
f_{\ell+1} - f_{\ell-1} = \langle k \rangle \left(f_\ell^{\frac{\gamma-2}{\gamma-1}} - f_{\ell-1}^{\frac{\gamma-2}{\gamma-1}} \right). \qquad (2.83)
$$

Esta relação de recorrência não linear não possui solução exata simples. Porém, alguns de seus limites são instrutivos. Consideremos, inicialmente, o caso $\gamma \to \infty$, que de fato corresponde a decaimentos que **não** são do tipo lei de potência. Neste limite, a relação será uma equação idêntica a (1.113)

$$f_{\ell+1} - \langle k \rangle f_\ell + (\langle k \rangle - 1) f_{\ell-1} = 0. \tag{2.84}$$

Esta relação de recorrência linear de coeficientes constantes têm soluções do tipo $f_\ell = \lambda^\ell$. Usando este *ansatz*[8] em (2.84), temos

$$\lambda^2 - \langle k \rangle \lambda + \langle k \rangle - 1 = 0, \tag{2.85}$$

cuja solução será $\lambda = \langle k \rangle - 1$ ou $\lambda = 1$, implicando que a solução geral de (2.84) para $\langle k \rangle \neq 2$ será

$$f_\ell = A(\langle k \rangle - 1)^\ell + B, \tag{2.86}$$

sendo A e B constantes arbitrárias a serem determinadas pelas condições iniciais. A situação com $\langle k \rangle = 2$ é idêntica ao caso correspondente de (1.113). Para determinarmos as condições iniciais, lembremos que nosso grafo tem N vértices, $b_0 = 1$ e $b_1 = k_{\max}$. Como estamos interessados no limite $N \to \infty$, termos $f_0 = 0$, que implica $B = -A$. A solução será

$$f_\ell = \frac{k_{\max}}{N(\langle k \rangle - 2)} \left((\langle k \rangle - 1)^\ell - 1) \right), \tag{2.87}$$

sendo, tipicamente, $f_1 = \frac{k_{\max}}{N} \ll 1$. Como no caso dos grafos regulares, podemos estimar o raio R de nosso grafo como sendo o menor valor de ℓ para o qual tenhamos $f_\ell \geq 1$, *i.e.*,

$$(\langle k \rangle - 1)^R = N \frac{\langle k \rangle - 2}{k_{\max}}, \tag{2.88}$$

de onde temos

$$R \propto \log_{\langle k \rangle - 1} N, \tag{2.89}$$

de notável semelhança com o Teorema 8 da seção 5.

Vamos examinar um outro limite de (2.83). É natural esperarmos que f_ℓ cresça rapidamente para ℓ pequenos, pois pela construção de nosso grafo as primeiras bolas tendem a ser bastante "povoadas". Vamos considerar então que podemos desprezar $f_{\ell-1}$ se comparada a f_ℓ e $f_{\ell+1}$. Nesse caso, ficamos

[8] Da Wikipedia: *In physics and mathematics, an ansatz (German: [anzats], meaning: "initial placement of a tool at a work piece") is an educated guess or an additional assumption made to help solve a problem, and which is later verified to be part of the solution by its results.*

com a seguinte equação aproximada[9]

$$f_{\ell+1} = \langle k \rangle f_\ell^{\frac{\gamma-2}{\gamma-1}}. \tag{2.90}$$

Apesar de ser não linear, esta equação tem solução exata simples. Ela pode ser linearizada facilmente tomando-se o logaritmo em ambos lados

$$\log f_{\ell+1} = \frac{\gamma-2}{\gamma-1} \log f_\ell + \log\langle k \rangle, \tag{2.91}$$

cuja solução geral é simples

$$\log f_\ell = A \left(\frac{\gamma-2}{\gamma-1} \right)^\ell + \log\langle k \rangle^{\gamma-1}, \tag{2.92}$$

sendo A uma constante arbitrária. Como no caso anterior, A pode ser determinado impondo-se a condição $f_1 = \frac{k_{\max}}{N}$. Temos

$$A = \log \left(\frac{k_{\max}}{N \langle k \rangle^{\gamma-1}} \right)^{\frac{\gamma-1}{\gamma-2}}. \tag{2.93}$$

Lembrando de nossa definição de raio R, queremos o menor valor de ℓ para o qual $f_\ell = 1$. Neste caso, temos

$$\left(\frac{\gamma-1}{\gamma-2} \right)^R = -\frac{A}{\log\langle k \rangle^{\gamma-1}} = \frac{\gamma-1}{\gamma-2} \log_{\langle k \rangle^{\gamma-1}} N + O(1), \tag{2.94}$$

sendo o $O(1)$ entendido com termos que não dependem de N. Para N grandes, temos o seguinte comportamento para R

$$R = \log_{\frac{\gamma-1}{\gamma-2}} \log_{\langle k \rangle^{\gamma-1}} N + O(1), \tag{2.95}$$

que mostra que as bolas b_ℓ podem crescer muito rapidamente para redes livres de escala.

2.3 Exercícios

Erdős-Rényi Explore computacionalmente o problema do números de triângulos no grafo $G(n,p)$. Você deve escrever um código (recomenda-se fortemente o uso do NetworkX) que, dado um grafo, determine o número de triângulos contidos e teste a fórmula (169). Você deve analisar uma amostra de m grafos de Erdős-Rényi $G(n,p)$. Determine, a partir de seus experimentos numéricos, como n e m influenciam a convergência do número de triângulos para o valor previsto em (169).

[9] A mesma equação pode ser obtida aproximando-se

$$\sum_{k=K_\ell}^{K_{\ell-1}} (k-1) P_k \approx \sum_{k=K_\ell}^{K_{\ell-1}} k P_k$$

em (2.77), o que é equivalente a hipótese $K_\ell \gg 1$, confiram.

Barabasi-Albert

1. Demonstre as afirmações indicadas nas notas de rodapé 7 e 9.
2. Faça um código que implemente o algoritmo de anexação preferencial de Barabasi-Albert. Atenção: **NÃO USE** o comando do Networkx para gerar o grafo, implemente você mesmo o algoritmo.
3. Usando o seu algoritmo, verifique os detalhes de convergência da distribuição de graus de grafos BA para os valores previstos em (213). Teste a dependência em todos os parâmetros do modelo de anexação preferencial.